



计算机网络（第 5 版）

第 5 章 运输层



第 5 章 运输层

5.1 运输层协议概述

5.1.1 进程之间的通信

5.1.2 运输层的两个主要协议

5.1.3 运输层的端口

5.2 用户数据报协议 UDP

5.2.1 UDP 概述

5.2.2 UDP 的首部格式



第 5 章 运输层（续）

5.3 传输控制协议 TCP 概述

5.3.1 TCP 最主要的特点

5.3.2 TCP 的连接

5.4 可靠传输的工作原理

5.4.1 停止等待协议

5.4.2 连续 ARQ 协议

5.5 TCP 报文段的首部格式



第 5 章 运输层（续）

5.6 TCP 可靠传输的实现

5.6.1 以字节为单位的滑动窗口

5.6.2 超时重传时间的选择

5.6.3 选择确认 SACK

5.7 TCP 的流量控制

5.7.1 利用滑动窗口实现流量控制

5.7.1 必须考虑传输效率



第 5 章 运输层（续）

5.8 TCP 的拥塞控制

5.8.1 拥塞控制的一般原理

5.8.2 几种拥塞控制方法

5.8.3 随机早期检测 RED

5.9 TCP 的运输连接管理

5.9.1 TCP 的连接建立

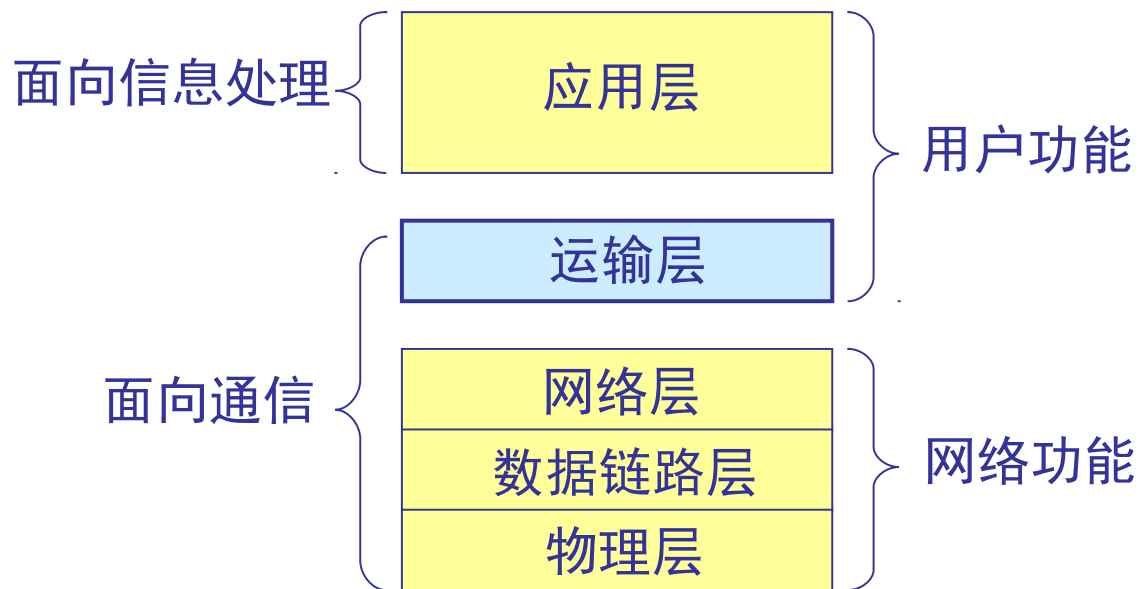
5.9.2 TCP 的连接释放

5.9.3 TCP 的有限状态机

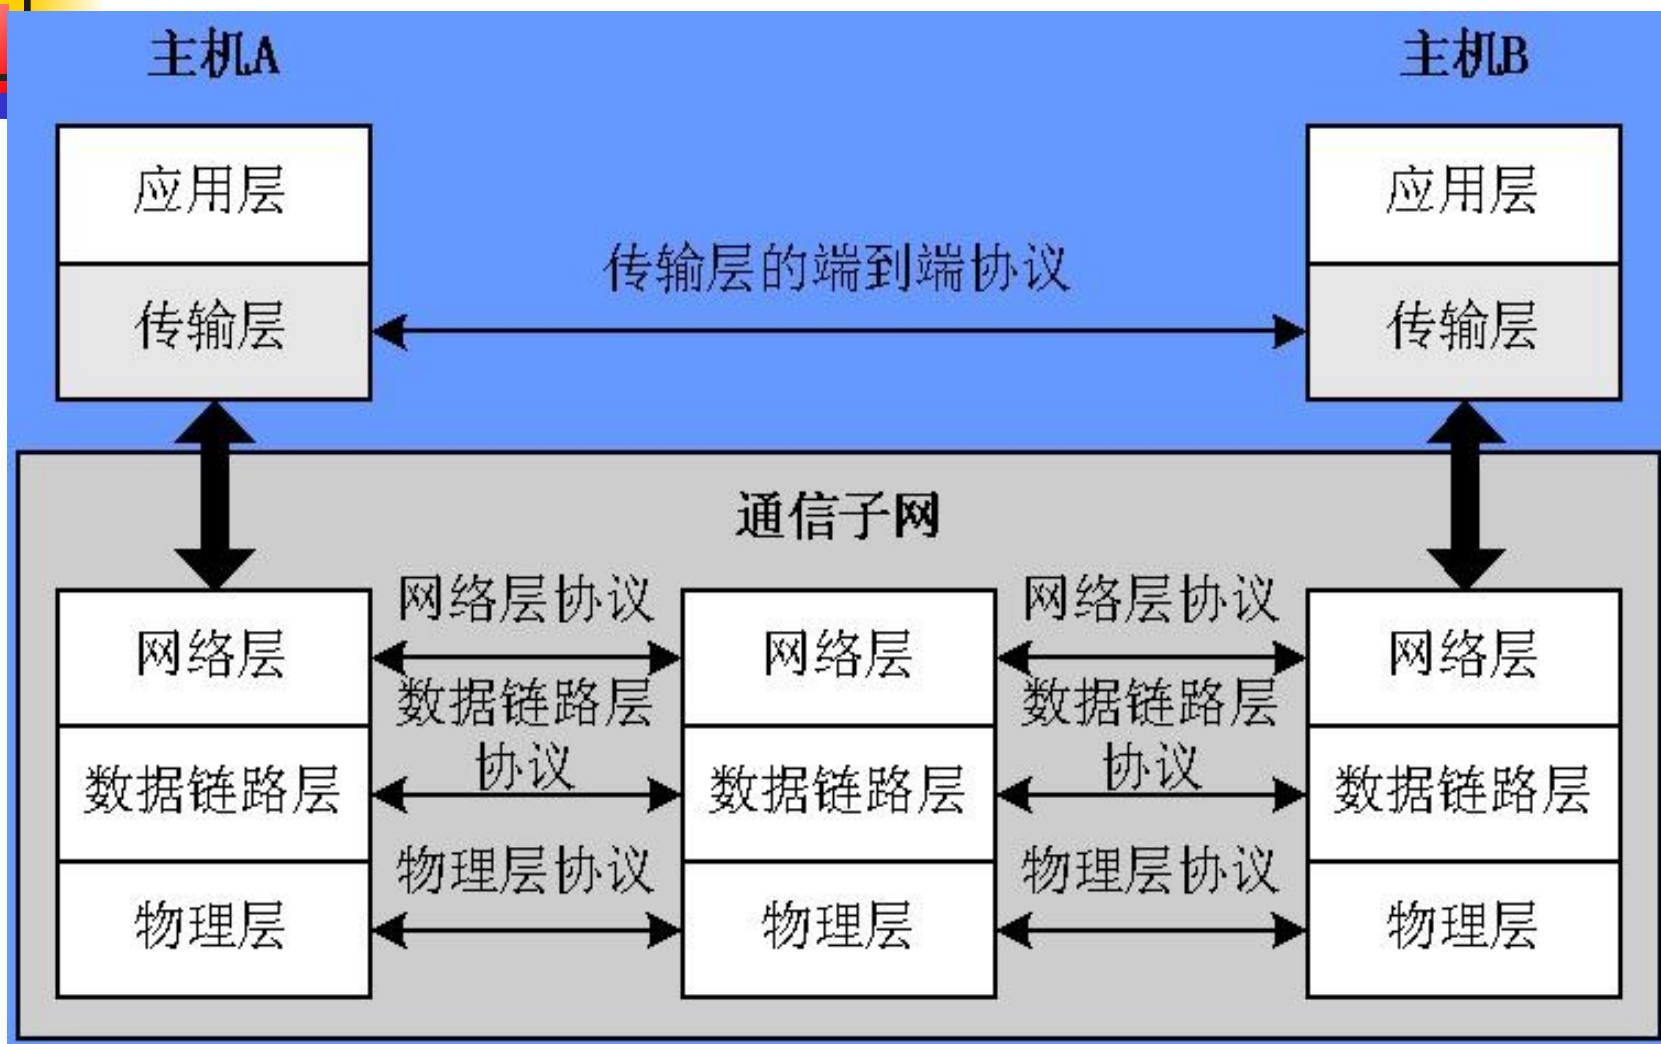
5.1 运输层协议概述

5.1.1 进程之间的通信

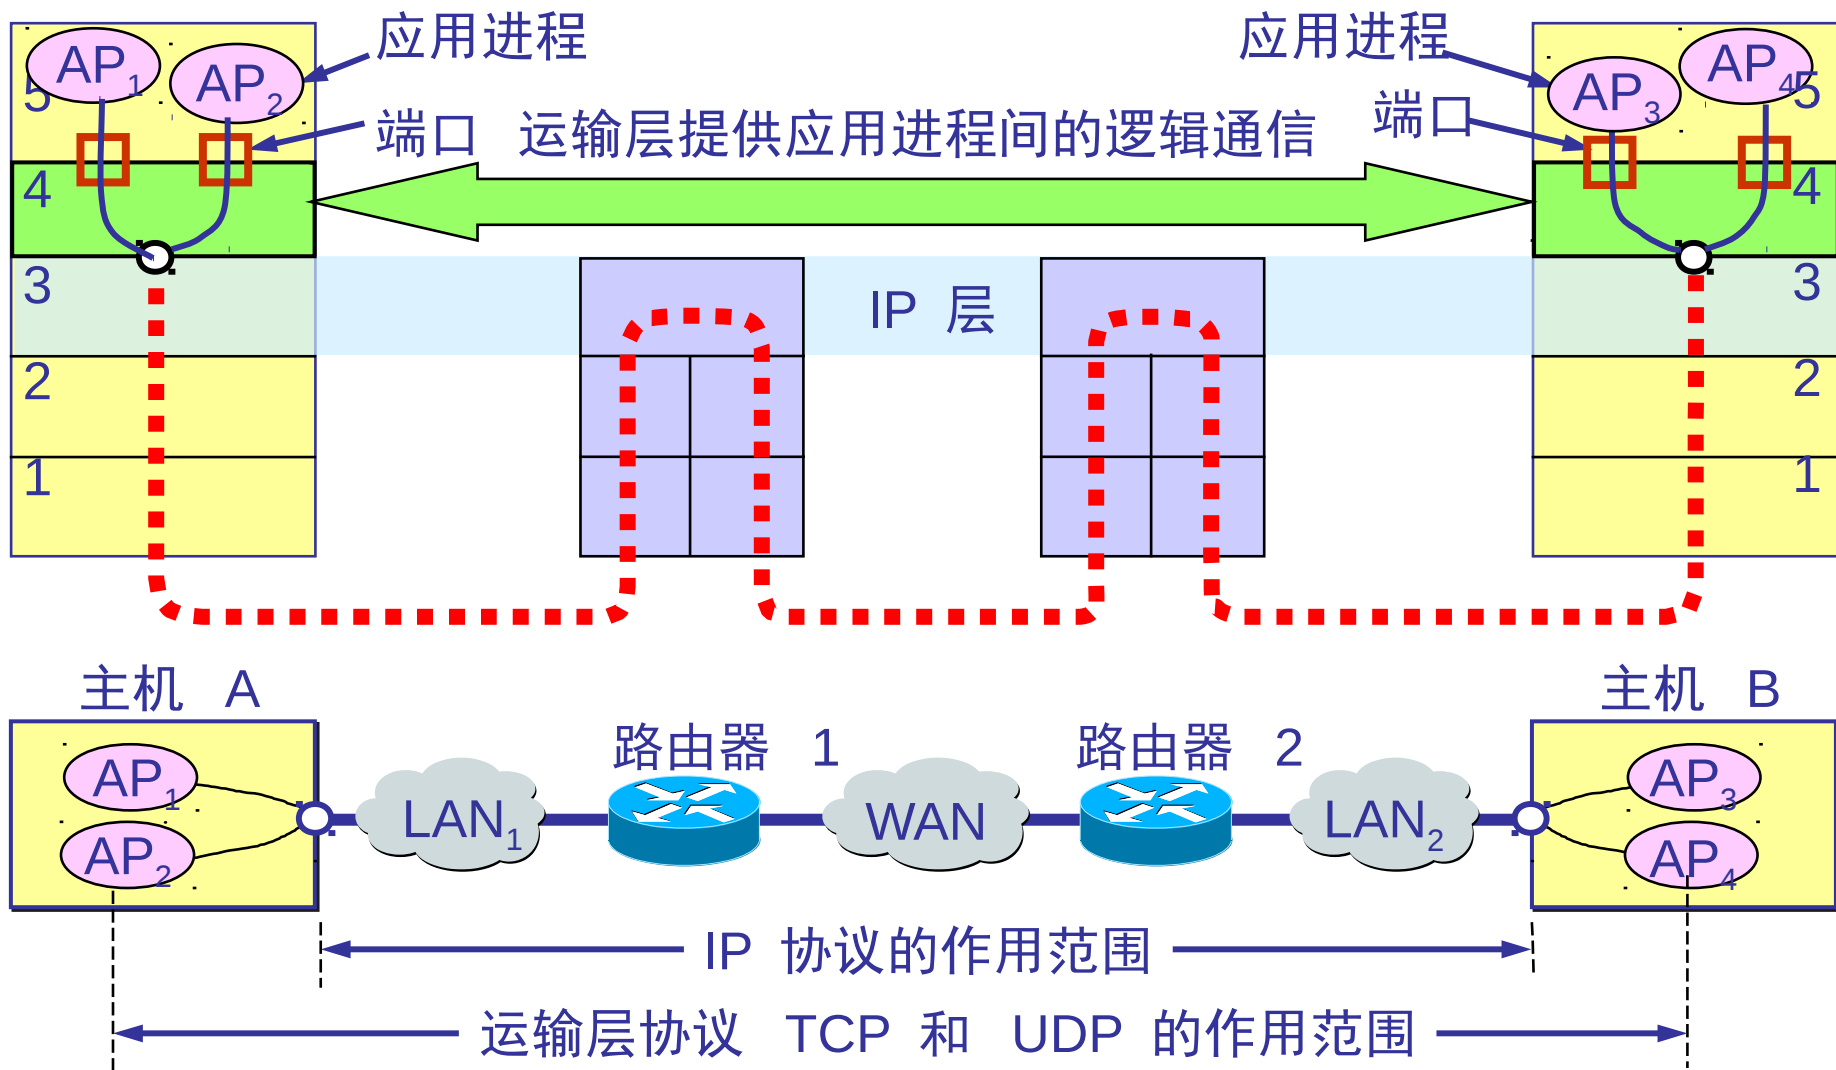
从通信和信息处理的角度看，传输层于网络层之上，应用层之下，为应用层提供通信服务。它属于面向通信部分的最高层，同时也是用户功能中的最低层。



传输层的端-端通信



运输层为相互通信的应用进程提供了逻辑通信

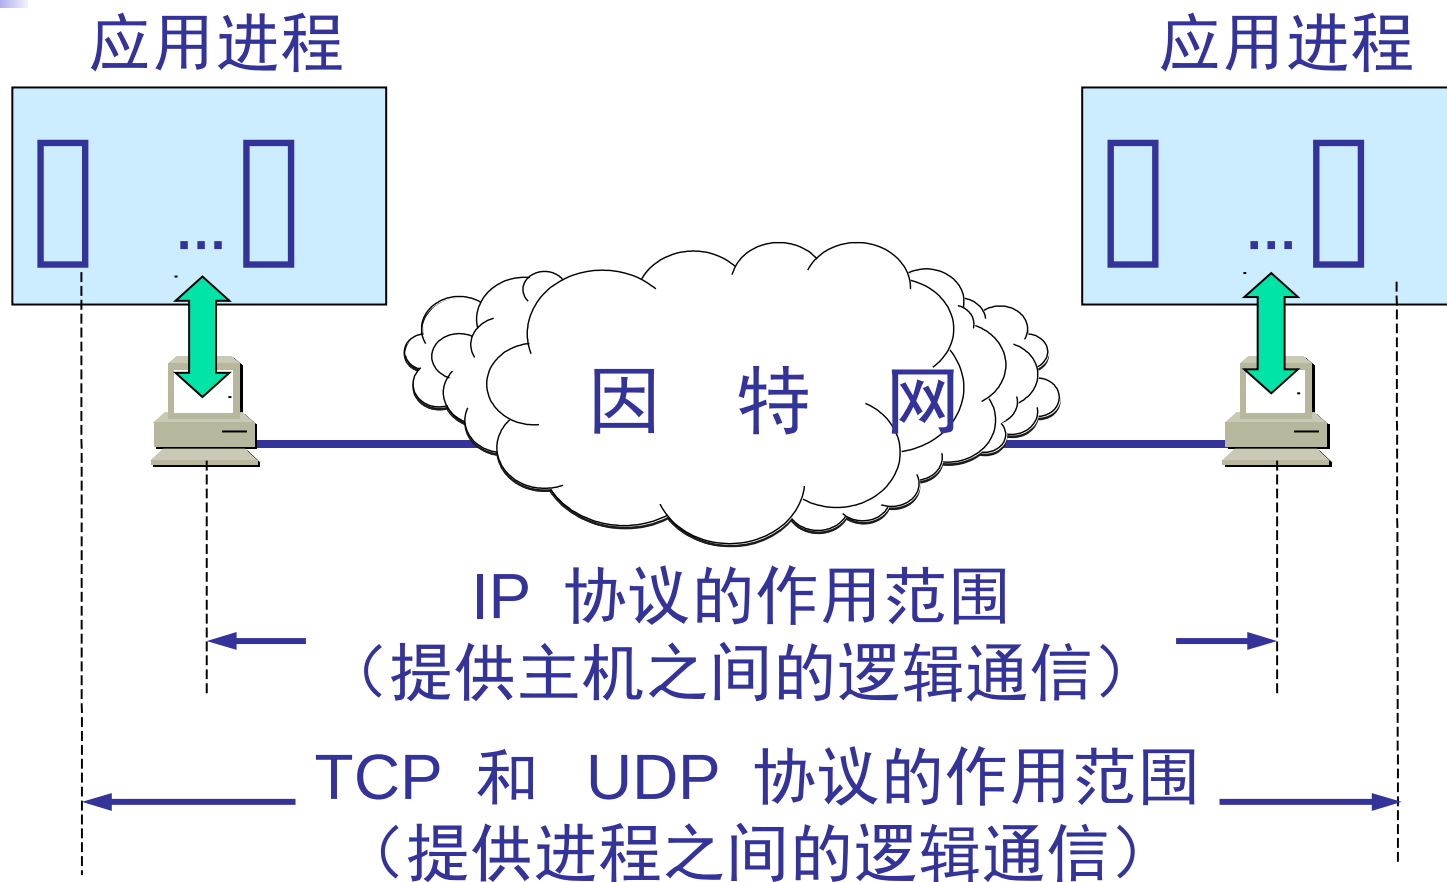




传输层提供的服务

- 传输层为不同主机上运行的进程提供逻辑通信。
 - 网络层则为不同主机提供逻辑通信。
 - 例子
 - 相隔较远的两所房子 A 和 B, 住者两家人, 每家 5 口人, 每月通过传统邮局一人给一人通信, A 家信负责人小王, B 家信负责人小李, 每月分别收集、分发信笺
 - 主机 (终端系统)----- 房子
 - 进程 ----- 人
 - 应用程序消息 ----- 信封里的信
 - 网络层协议 ----- 邮递服务 (包括邮递员)
 - 传输层协议 ----- A 家负责人小王, B 家负责人小李
- 若小王、小李病了, 分别换两个人, 则可能提供不同的服务

运输层协议和网络层协议的主要区别





应用进程之间的通信

- ◆ 计算机网络最本质的活动是实现分布在不同地理位置的主机之间的进程通信，以实现各种网络服务功能。
- 应用进程之间的通信又称为端到端的通信。
- 运输层的一个很重要的功能就是复用和分用。
- “逻辑通信”的意思是：运输层之间的通信好像是沿水平方向传送数据。但事实上这两个运输层之间并没有一条水平方向的物理连接。



运输层的主要功能

- 运输层为应用进程之间提供端到端的逻辑通信（但网络层是为主机之间提供逻辑通信）。
- 运输层还要对收到的报文进行差错检测。
- 运输层需要有两种不同的运输协议，即面向连接的 TCP 和无连接的 UDP。



两种不同的运输协议

- 运输层向高层用户**屏蔽**了下面网络核心的细节（如网络拓扑、所采用的路由选择协议等）。
- 当运输层采用面向连接的 TCP 协议时，尽管下面的网络是不可靠的（只提供尽最大努力服务），但这种逻辑通信信道就相当于一**条全双工的可靠信道**。
- 当运输层采用无连接的 UDP 协议时，这种逻辑通信信道是一**条不可靠信道**。



5.1.2 运输层的两个主要协议

TCP/IP 的运输层有两个不同的协议
：

- (1) 用户数据报协议 UDP
(User Datagram Protocol)
- (2) 传输控制协议 TCP
(Transmission Control Protocol)



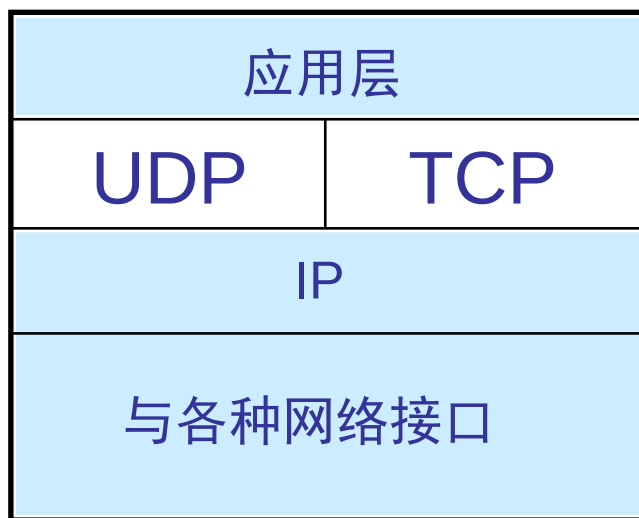
TCP 与 UDP

- 两个对等运输实体在通信时传送的数据单位叫作 **运输协议数据单元** TPDU (Transport Protocol Data Unit) 。
- TCP 传送的数据单位协议是 **TCP 报文段** (segment)
- UDP 传送的数据单位协议是 **UDP 报文或用户数据报**。



TCP/IP 体系中的运输层协议

运输层





TCP 与 UDP

- UDP 在传送数据之前不需要先建立连接。对方的运输层在收到 UDP 报文后，不需要给出任何确认。虽然 UDP 不提供可靠交付，但在某些情况下 UDP 是一种最有效的工作方式。
- TCP 则提供面向连接的服务。TCP 不提供广播或多播服务。由于 TCP 要提供可靠的、面向连接的运输服务，因此不可避免地增加了许多的开销。这不仅使协议数据单元的首部增大很多，还要占用许多的处理机资源。



还要强调两点

- 运输层的 UDP 用户数据报与网际层的 IP 数据报有很大区别。IP 数据报要经过互连网中许多路由器的存储转发，但 UDP 用户数据报是在运输层的端到端抽象的逻辑信道中传送的。
- TCP 报文段是在运输层抽象的端到端逻辑信道中传送，这种信道是可靠的全双工信道。但这样的信道却不知道究竟经过了哪些路由器，而这些路由器也根本不知道上面的运输层是否建立了 TCP 连接。



5.1.3 运输层的端口

- 运行在计算机中的进程是用**进程标识符**来标志的。
- 运行在应用层的各种应用进程却不应当让计算机操作系统指派它的进程标识符。这是因为在因特网上使用的计算机的操作系统种类很多，而不同的操作系统又使用不同格式的进程标识符。
- 为了使运行不同操作系统的计算机的应用进程能够互相通信，就**必须用统一的方法**对 TCP/IP 体系的应用进程进行标志。



端口号 (protocol port number) 简称为端口 (port)

- 解决这个问题的方法就是在运输层使用协议端口号 (protocol port number)，或通常简称为端口 (port)。
- 虽然通信的终点是应用进程，但我们可以把端口想象是通信的终点，因为我们只要把要传送的报文交到目的主机的某一个合适的目的端口，剩下的工作（即最后交付目的进程）就由 TCP 来完成。



软件端口与硬件端口

- 在协议栈层间的抽象的协议端口是**软件端口**。
- 路由器或交换机上的端口是**硬件端口**。
- 硬件端口是不同硬件设备进行交互的接口，而软件端口是应用层的各种协议进程与运输实体进行层间交互的一种地址。



TCP 的端口

- 端口用一个 16 位端口号进行标志。
- 端口号只具有本地意义，即端口号只是为了标志本计算机应用层中的各进程。在因特网中不同计算机的相同端口号是没有联系的。



三类端口

- **熟知端口**，数值一般为 0~1023 。
- **登记端口号**，数值为 1024~49151，为没有熟知端口号的应用程序使用的。使用这个范围的端口号必须在 IANA 登记，以防止重复。
- **客户端口号或短暂端口号**，数值为 49152~65535，留给客户进程选择暂时使用。当服务器进程收到客户进程的报文时，就知道了客户进程所使用的动态端口号。通信结束后，这个端口号可供其他客户进程以后使用。

5.2 用户数据报协议 UDP

5.2.1 UDP 概述

- UDP 只在 IP 的数据报服务之上增加了很少一点的功能，即端口的功能和差错检测的功能。
- 虽然 UDP 用户数据报只能提供不可靠的交付，但 UDP 在某些方面有其特殊的优点。



UDP 的主要特点

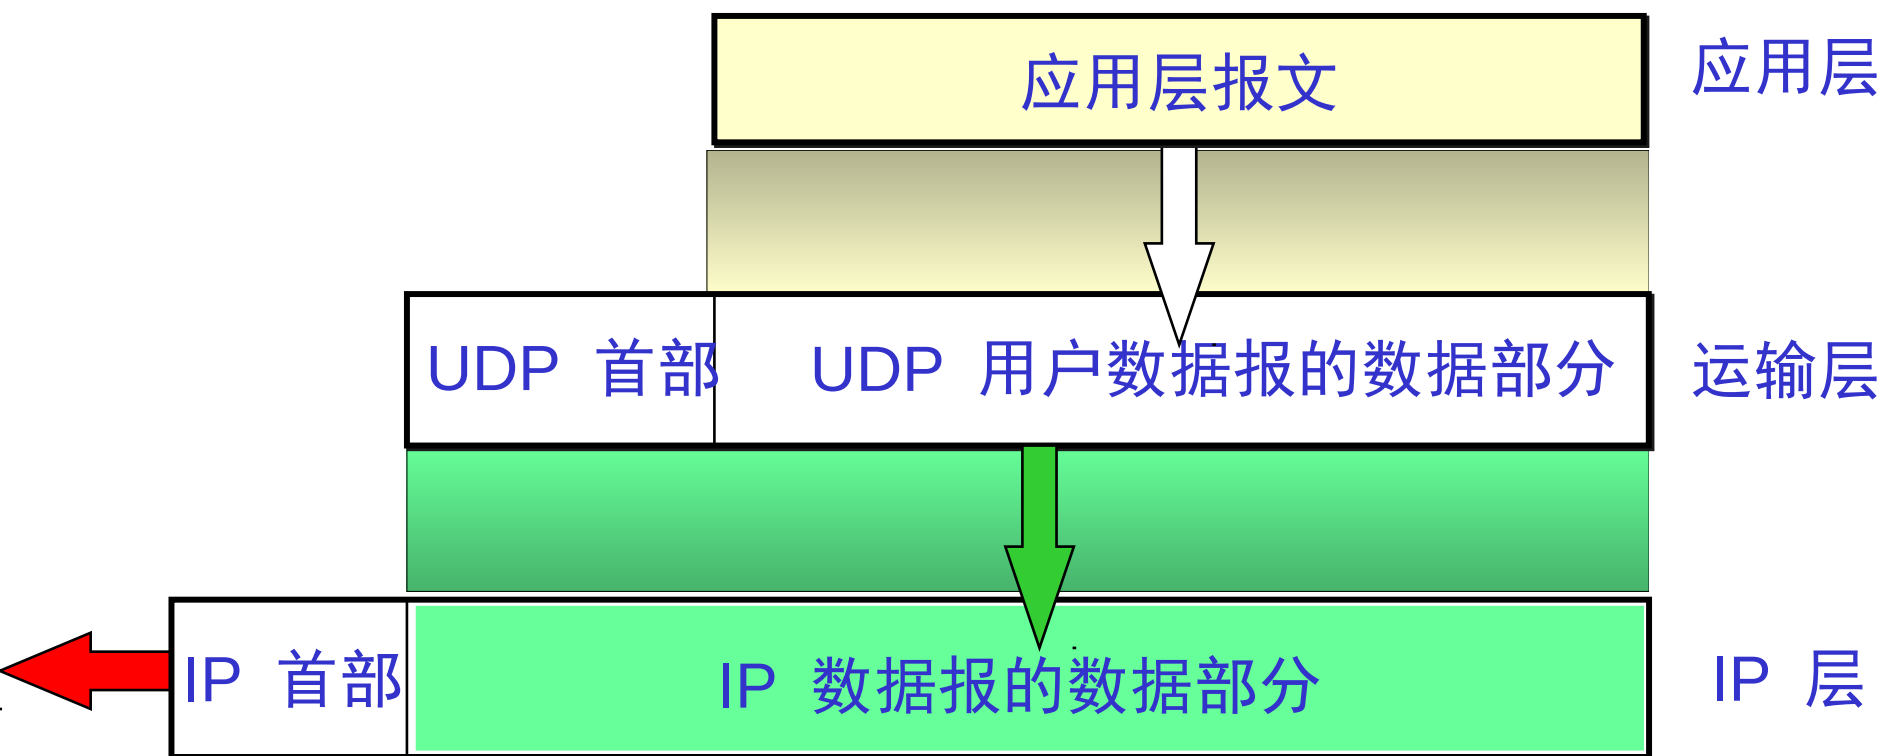
- UDP 是无连接的，即发送数据之前不需要建立连接。
- UDP 使用尽最大努力交付，即不保证可靠交付，同时也不使用拥塞控制。
- UDP 是面向报文的。UDP 没有拥塞控制，很适合多媒体通信的要求。
- UDP 支持一对一、一对多、多对一和多对多的交互通信。
- UDP 的首部开销小，只有 8 个字节。



面向报文的 UDP

- 发送方 UDP 对应用程序交下来的报文，在添加首部后就向下交付 IP 层。UDP 对应用层交下来的报文，既**不合并**，也**不拆分**，而是保留这些报文的边界。
- 应用层交给 UDP 多长的报文，UDP 就照样发送，即一次发送一个报文。
- 接收方 UDP 对 IP 层交上来的 UDP 用户数据报，在去除首部后就原封不动地交付上层的应用进程，一次交付一个完整的报文。
- 应用程序必须选择合适大小的报文。

UDP 是面向报文的



5.2.2 UDP 的首部格式

字节

4

4

1

1

2

源 IP 地址

目的 IP 地址

0

17

UDP 长度

字节

12

2

2

2

2

伪首部

源端口

目的端口

长 度

检验和

UDP 用户数据报

首 部

数

据

发送在前

首 部

数

据

IP 数据报



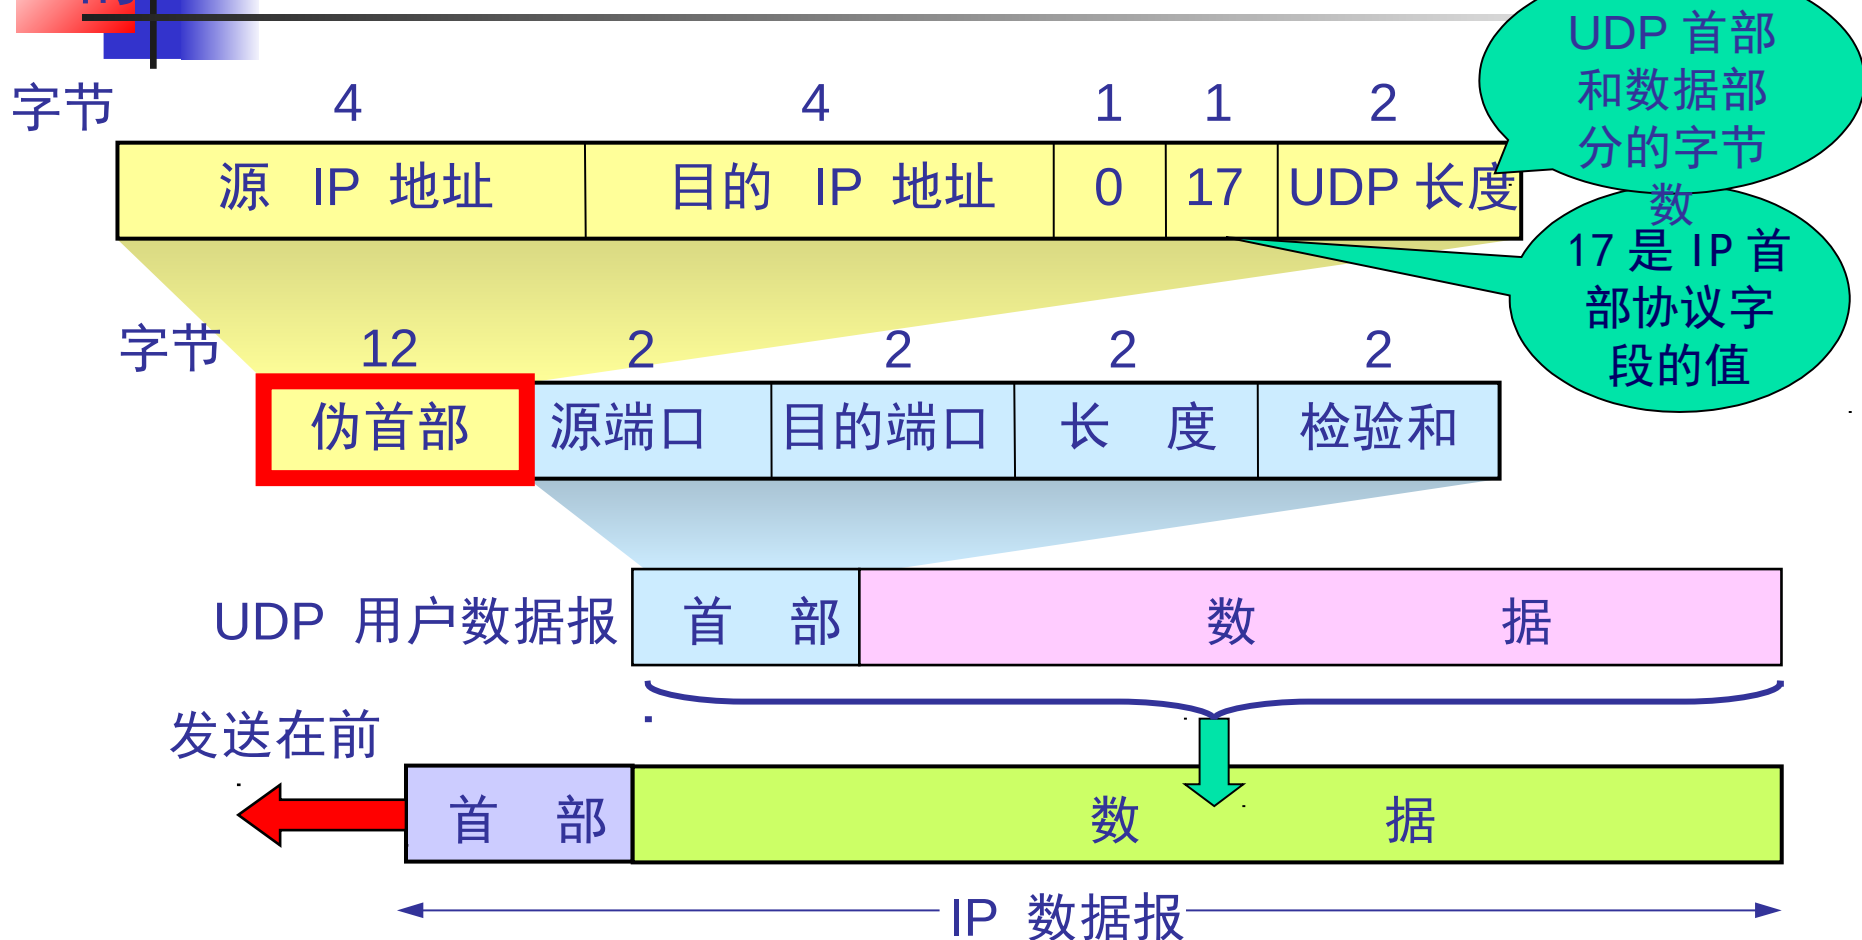
UDP 使用的熟知端口号

| 端口号 | 服务进程 | 说明 |
|-----|-------------|----------------|
| 53 | Name server | 域名服务 |
| 67 | Bootps | 下载引导程序信息的服务器端口 |
| 68 | Bootpc | 下载引导程序信息的客户机端口 |
| 69 | TFTP | 简单文件传输协议 |
| 111 | RPC | 远程过程调用 |
| 123 | NTP | 网络时间协议 |
| 161 | SNMP | 简单网络管理协议 |

用户数据报 UDP 有两个字段：数据字段和首部
字段。首部字段有 8 个字节，由 4 个字段组
成，每个字段都是两个字节。



在计算检验和时，临时把“伪首部”和 UDP 用户数据报连接在一起。伪首部仅仅是为了计算检验和，**并不传输**。将伪首部结构参与校验的目的是为了进一步证实数据送到了正确的目的。

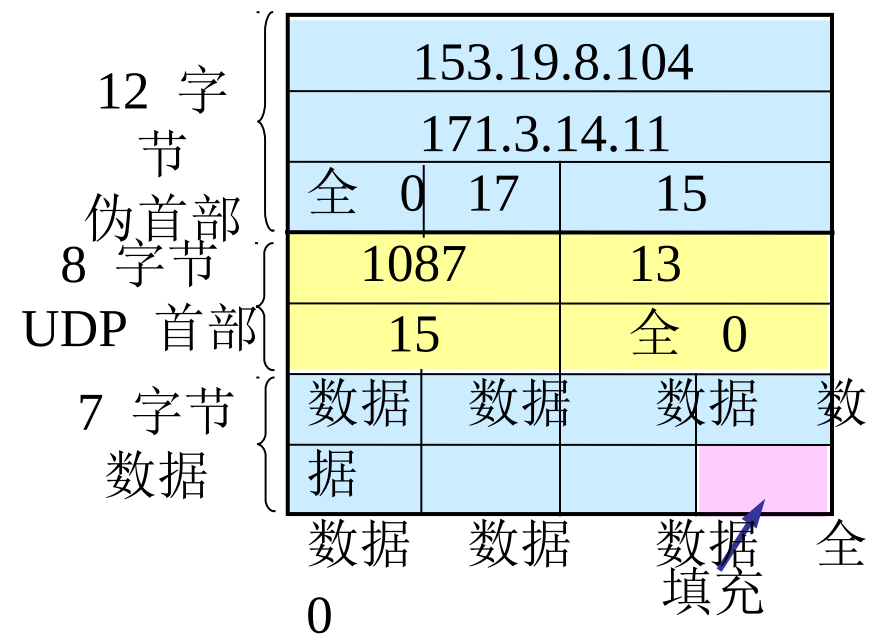




UDP 协议的校验

- 因为 IP 只对 IP 分组头进行校验，如果 UDP 也不对数据进行校验，那么就要由应用层来检测链路层上的传输错误了。
- 如果接收方判断收到的数据报有错，则只是简单地将数据报丢弃，并不向源报告错误。

计算 UDP 检验和的例子



10011001 00010011 → 153.19
 00001000 01101000 → 8.104
 10101011 00000011 → 171.3
 00001110 00001011 → 14.11
 00000000 00010001 → 0 和 17
 00000000 00001111 → 15
 00000100 00111111 → 1087
 00000000 00001101 → 13
 00000000 00001111 → 15
 00000000 00000000 → 0 (检验和)
 01010100 01000101 → 数据
 01010011 01010100 → 数据
 01001001 01001110 → 数据
 01000111 00000000 → 数据和 0 (填充)

按二进制反码运算求和

将得出的结果求反码

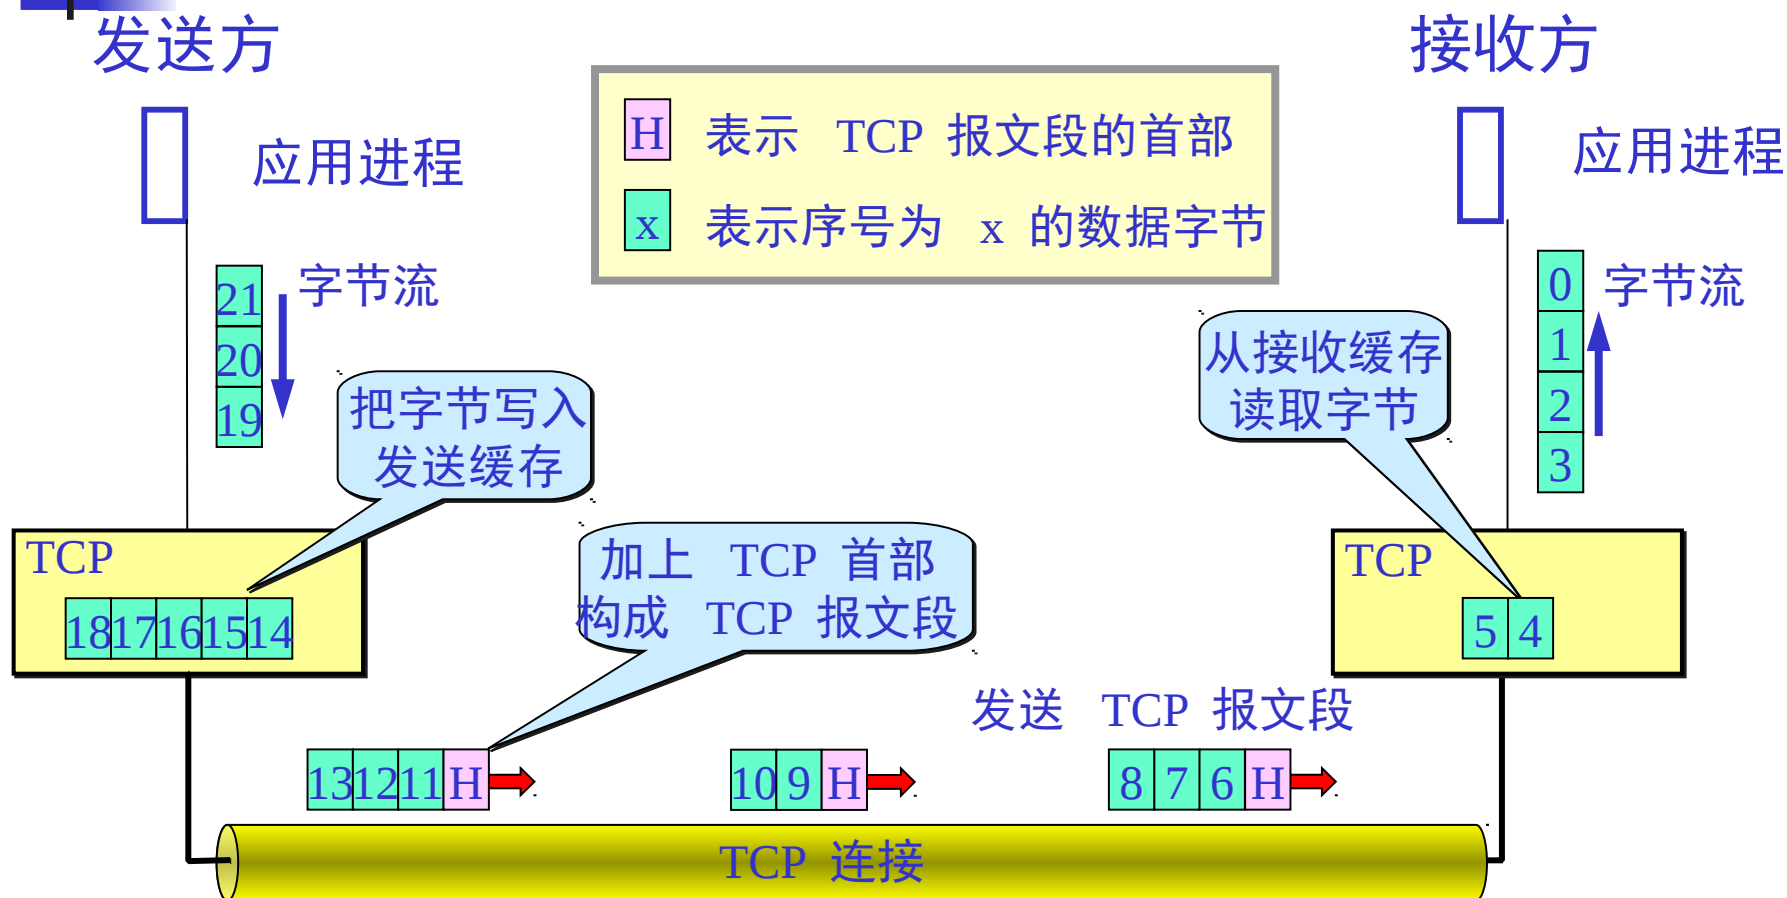
10010110 11101101 → 求和得出的结果
 01101001 00010010 → 检验和

5.3 传输控制协议 TCP 概述

5.3.1 TCP 最主要的特点

- TCP 是面向连接的运输层协议。
- 每一条 TCP 连接只能有两个端点，每一条 TCP 连接只能是点对点的（一对一）。
- TCP 提供可靠交付的服务。
- TCP 提供全双工通信。
- TCP 连接是一个字节流而不是一个报文流，它不保留报文的边界。

TCP 面向流的概念





应当注意

- TCP 连接是一条**虚连接**而不是一条真正的物理连接。
- TCP 对应用进程一次把多长的报文发送到 TCP 的缓存中是不关心的。
- TCP 根据对方给出的**窗口值**和当前**网络拥塞的程度**来决定一个报文段应包含多少个字节（UDP 发送的报文长度是应用进程给出的）。
- TCP 可把太长的数据块划分短一些再传送。TCP 也可等待积累有足够多的字节后再构成报文段发送出去。



5.3.2 TCP 的连接

- TCP 是面向连接的，且每一条 TCP 连接有两个端点。
- TCP 连接的端点不是主机，不是主机的 IP 地址，不是应用进程，也不是运输层的协议端口。TCP 连接的端点叫做套接字 (socket) 或插口。
- 端口号拼接 (concatenated with) IP 地址即构成了套接字。



套接字 (socket)

套接字 socket = (IP 地址 : 端口号)

(5-1)

- 每一条 **TCP** 连接唯一地被通信两端的两个端点（即两个套接字）所确定。即：

TCP 连接 ::= {socket1, socket2}

= {(IP1: port1), (IP2: port2)} (5-2)



同一个名词 socket 有多种不同的意思

- 应用编程接口 API 称为 socket API, 简称为 socket 。
- socket API 中使用的一个函数名也叫作 socket 。
- 调用 socket 函数的端点称为 socket 。
- 调用 socket 函数时其返回值称为 socket 描述符, 可简称为 socket 。
- 在操作系统内核中连网协议的 Berkeley 实现, 称为 socket 实现。

5.4 可靠传输的工作原理

5.4.1 停止等待协议


过程：

- ① 发送方发完一帧后，停止发送，并启动定时器，等待对方应答。
- ② 接收者收到帧，若正确则应答 ACK，错误则应答 NAK。
- ③ 发送者若收到 ACK，接着发送下一帧；若收到 NAK、或超时，则重发该帧。

■ 需解决的问题：

- 重复帧 丢失帧 错误帧

停止等待协议（正常）



(a) 无差错情况



请注意

- 在发送完一个分组后，必须暂时保留已发送的分组的副本。
- 分组和确认分组都必须进行编号。
- 超时计时器的重传时间应当比数据在分组传输的平均往返时间更长一些。



帧的编号问题

- 任何一个编号系统的序号所占用的比特数一定是有限的。因此，经过一段时间后，发送序号就会重复。
- 序号占用的比特数越少，数据传输的额外开销就越小。
- 对于停止等待协议，由于每发送一个数据帧就停止等待，因此用一个比特来编号就够了。
 - 一个比特可表示 0 和 1 两种不同的序号。


停等协议 -1

如超时重发帧如何区分？

◆ 每一个数据帧带上不同的发送序号。每发送一个新的数据帧就把它发送序号加 1。


◆ 若结点 B 收到发送序号相同的数据帧，应丢弃重复帧，

◆ 但结点 B 还必须向 A 发送确认帧 ACK。




(b) 超时重传

确认丢失和确认迟到



(a) 确认丢失



(b) 确认迟到




可靠通信的实现

- 使用上述的**确认和重传机制**，我们就可以在**不可靠的传输网络上实现可靠的通信**。
- 这种可靠传输协议常称为**自动重传请求 ARQ** (Automatic Repeat reQuest) 。
- ARQ 表明重传的请求是**自动**进行的。接收方不需要请求发送方重传某个出错的分组 。

信道利用率

- 停止等待协议的优点是简单，但缺点是信道利用率太低。



RTT: 往返时间。

T_D : A 发送分组需要的时间

。

T_A : B 发送确认需要的时间




信道的利用率 U

$$U = \frac{T_D}{T_D + \text{RTT} + T_A} \quad (5-3)$$


流水线传输

- 发送方可连续发送多个分组，不必每发完一个分组就停顿下来等待对方的确认。
- 由于信道上一一直有数据不间断地传送，这种传输方式可获得很高的信道利用率。



5.4.2 连续 ARQ 协议


发送窗口



(a) 发送方维持发送窗口（发送窗口是 5）

发送窗口

向前



(b) 收到一个确认后发送窗口向前滑动



累积确认

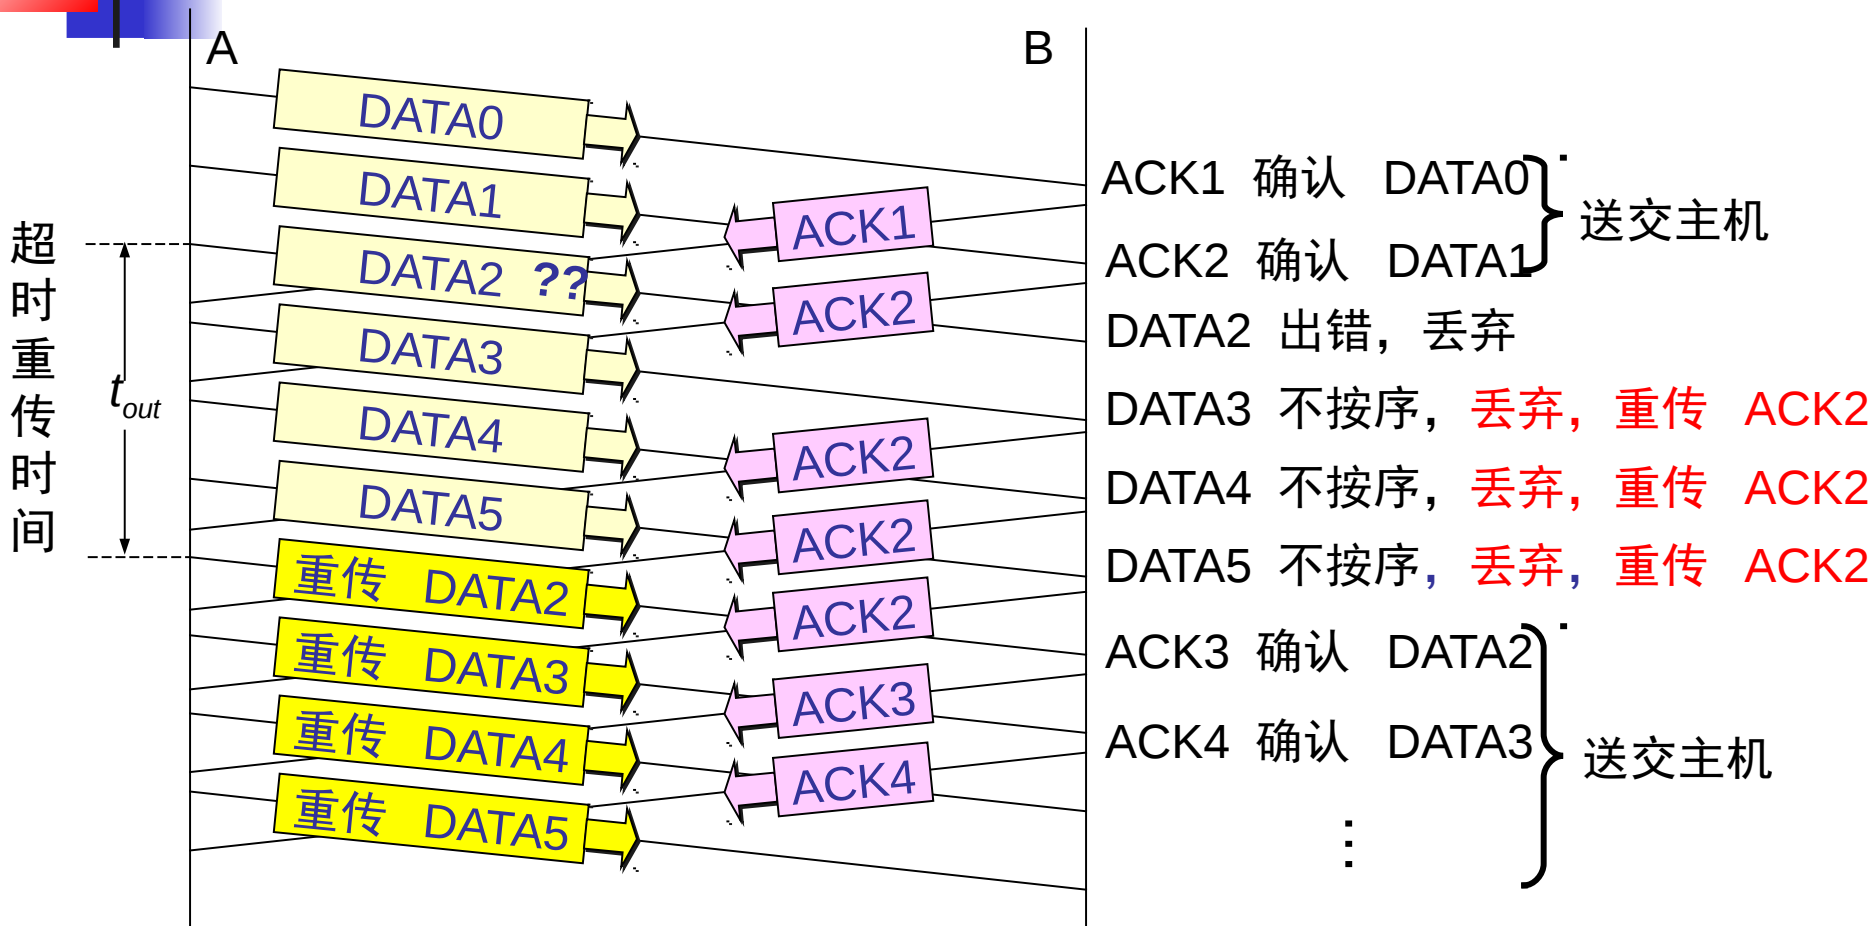
- 接收方一般采用**累积确认**的方式。即不必对收到的分组逐个发送确认，而是对按序到达的最后一个分组发送确认，这样就表示：**到这个分组为止的所有分组都已正确收到了。**
- 累积确认有的优点是：容易实现，即使确认丢失也不必重传。缺点是：不能向发送方反映出接收方已经正确收到的所有分组的信息。



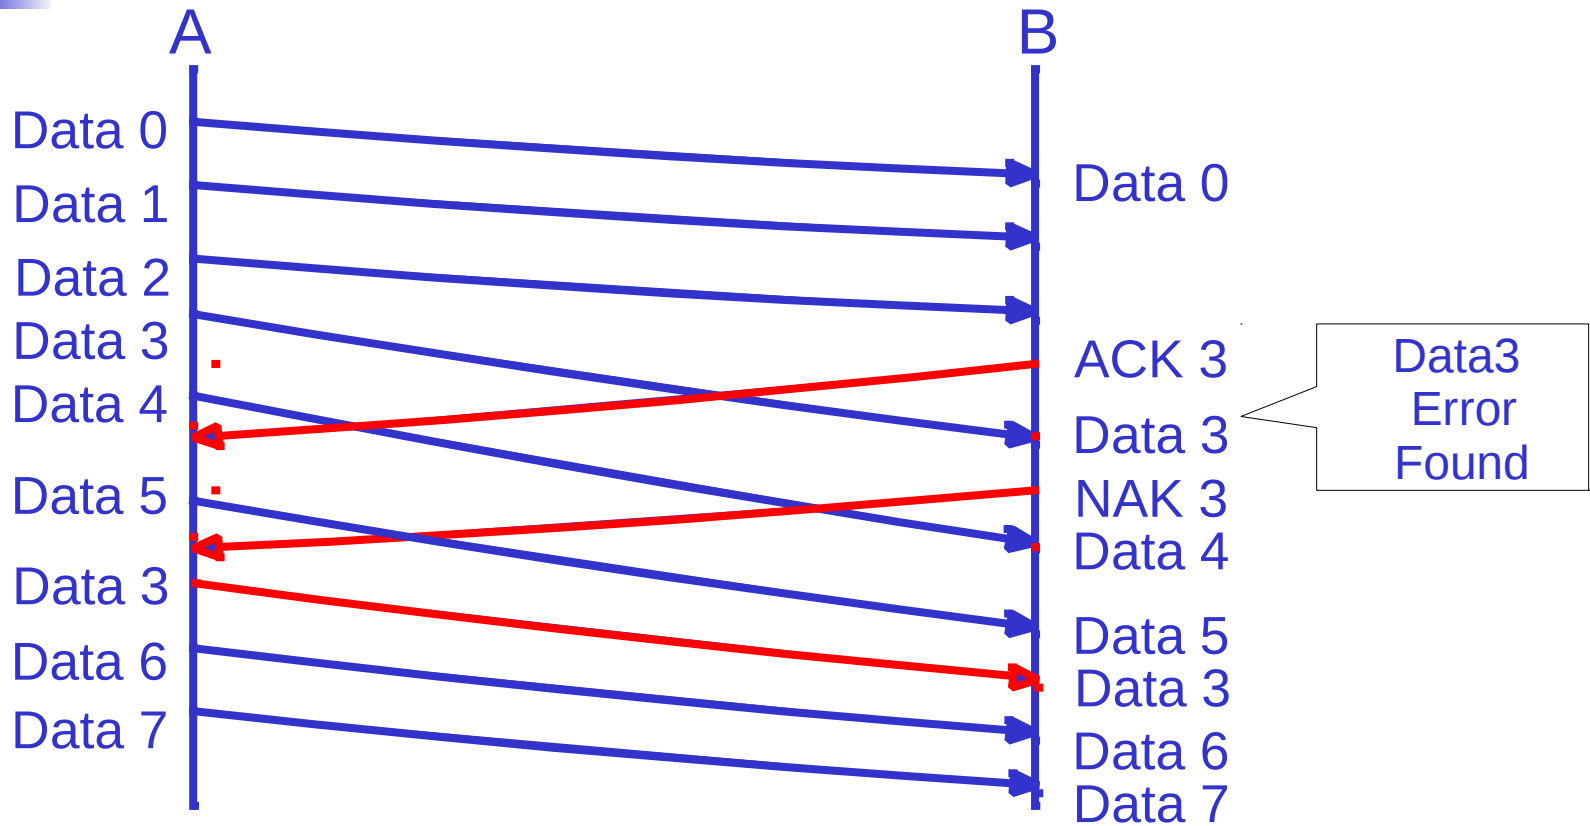
Go-back-N（回退 N）

- 如果发送方发送了前 5 个分组，而中间的第 3 个分组丢失了。这时接收方只能对前两个分组发出确认。发送方无法知道后面三个分组的下落，而只好把后面的三个分组都再重传一次。
- 这就叫做 Go-back-N（回退 N），表示需要再退回来重传已发送过的 N 个分组。
- 可见当通信线路质量不好时，连续 ARQ 协议会带来负面的影响。

回退 N 方式的工作原理



选择重发 (Selective Repeat)



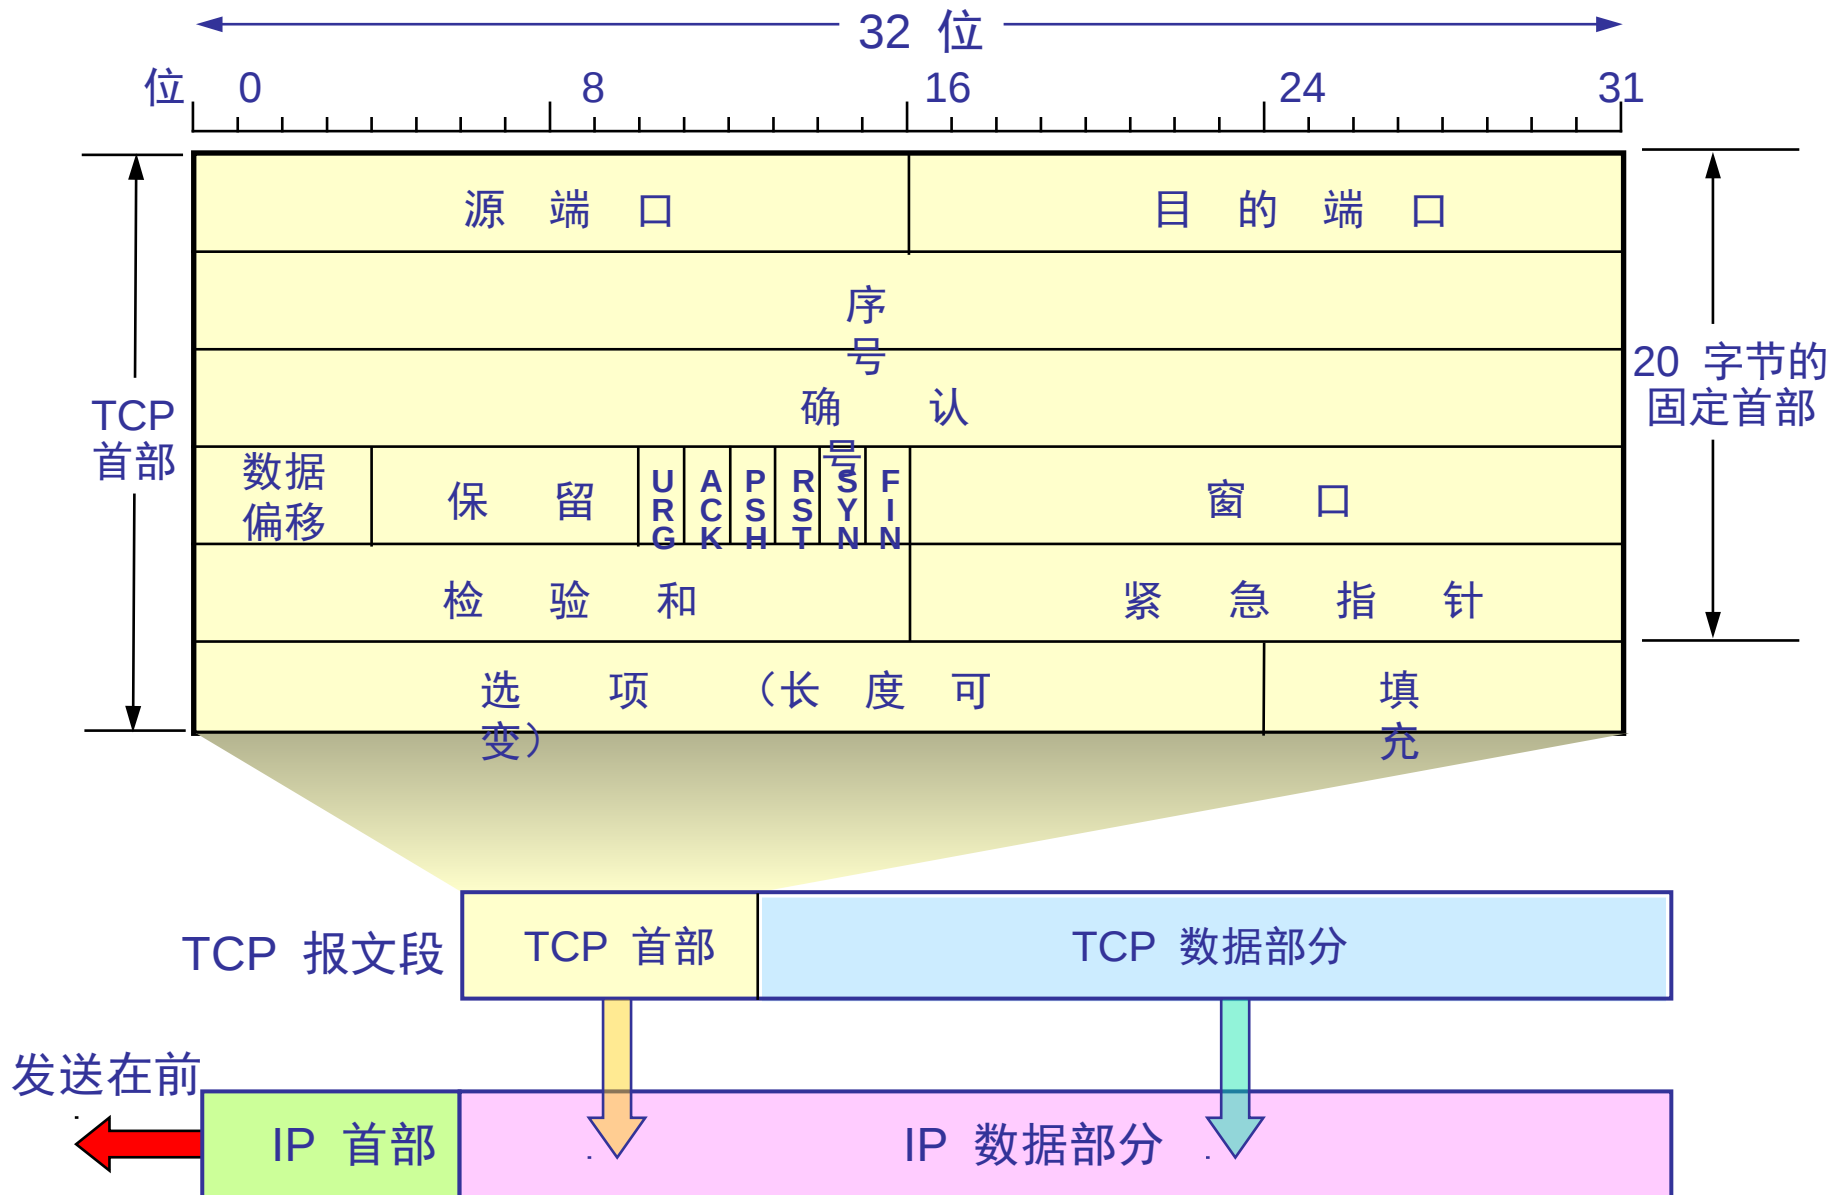
传输错误时的选择重发

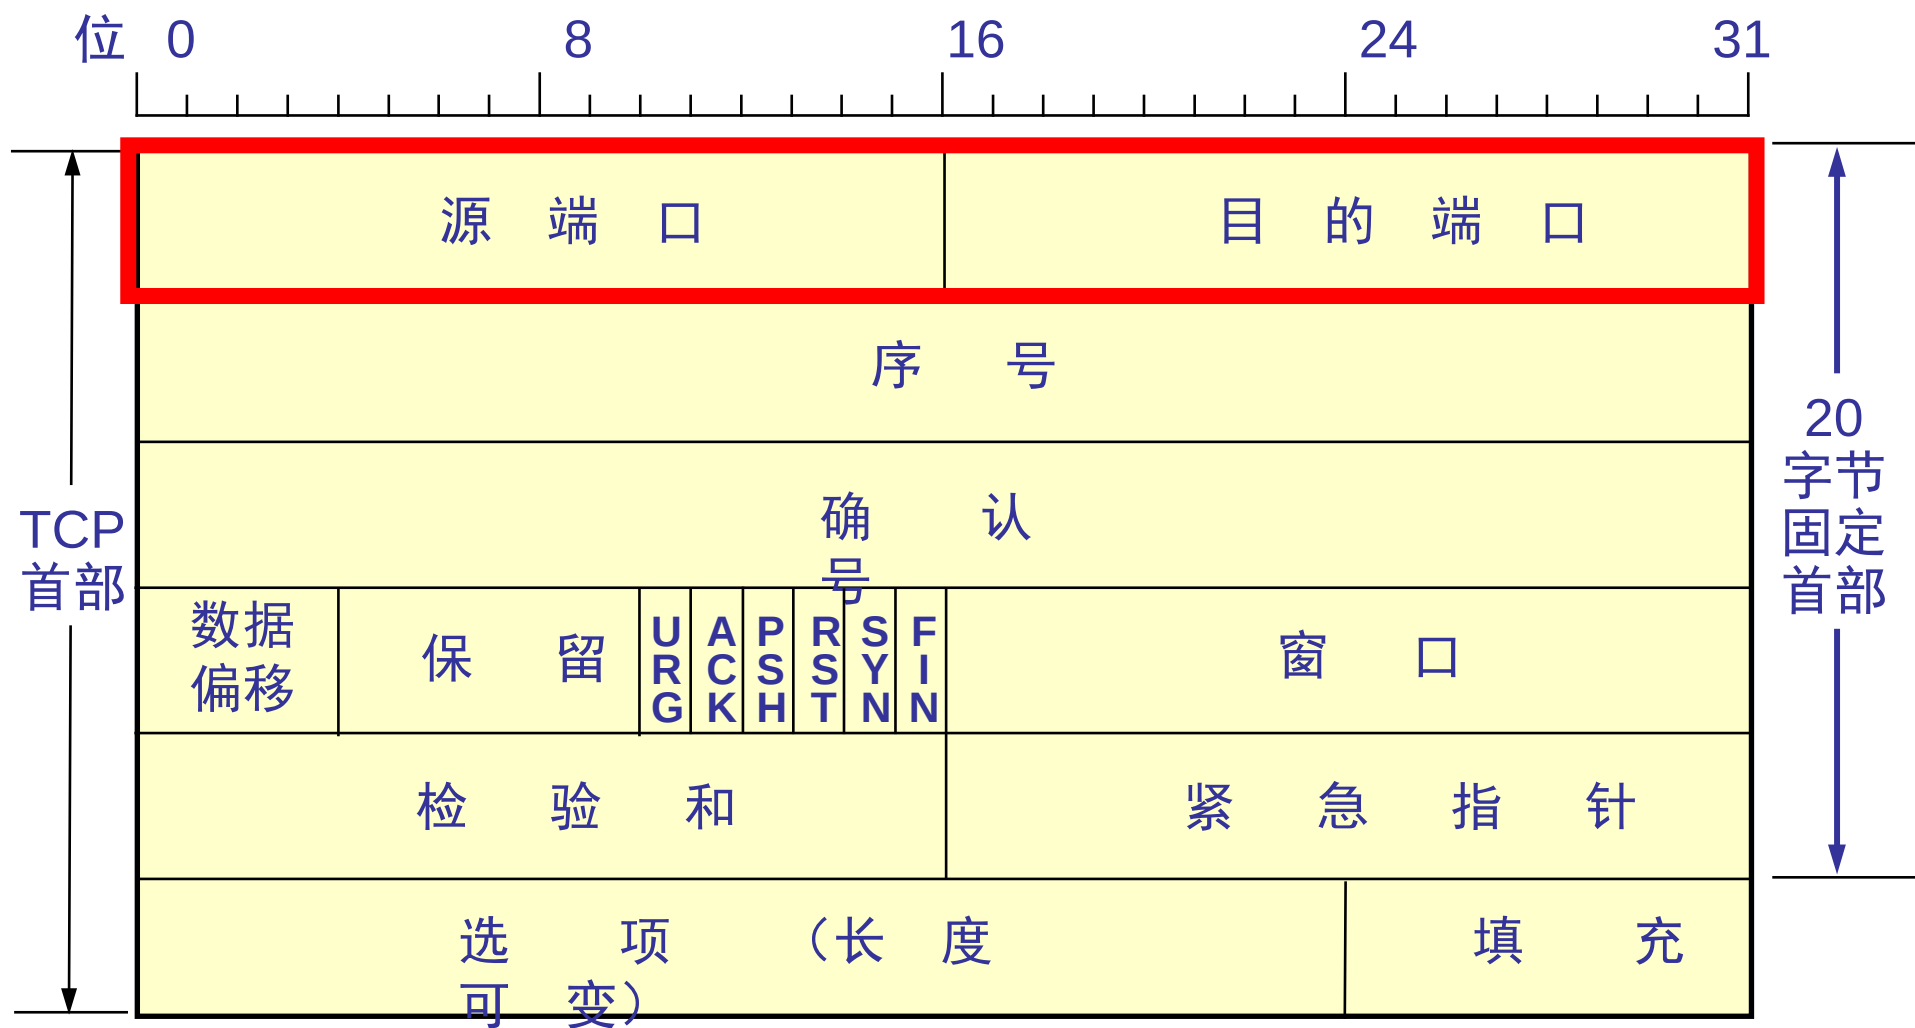


TCP 可靠通信的具体实现

- TCP 连接的每一端都必须设有两个窗口——一个发送窗口和一个接收窗口。
- TCP 的可靠传输机制用字节的序号进行控制。TCP 所有的确认都是基于序号而不是基于报文段。
- TCP 两端的四个窗口经常处于动态变化之中。
- TCP 连接的往返时间 RTT 也不是固定不变的。需要使用特定的算法估算较为合理的重传时间。

5.5 TCP 报文段的首部格式





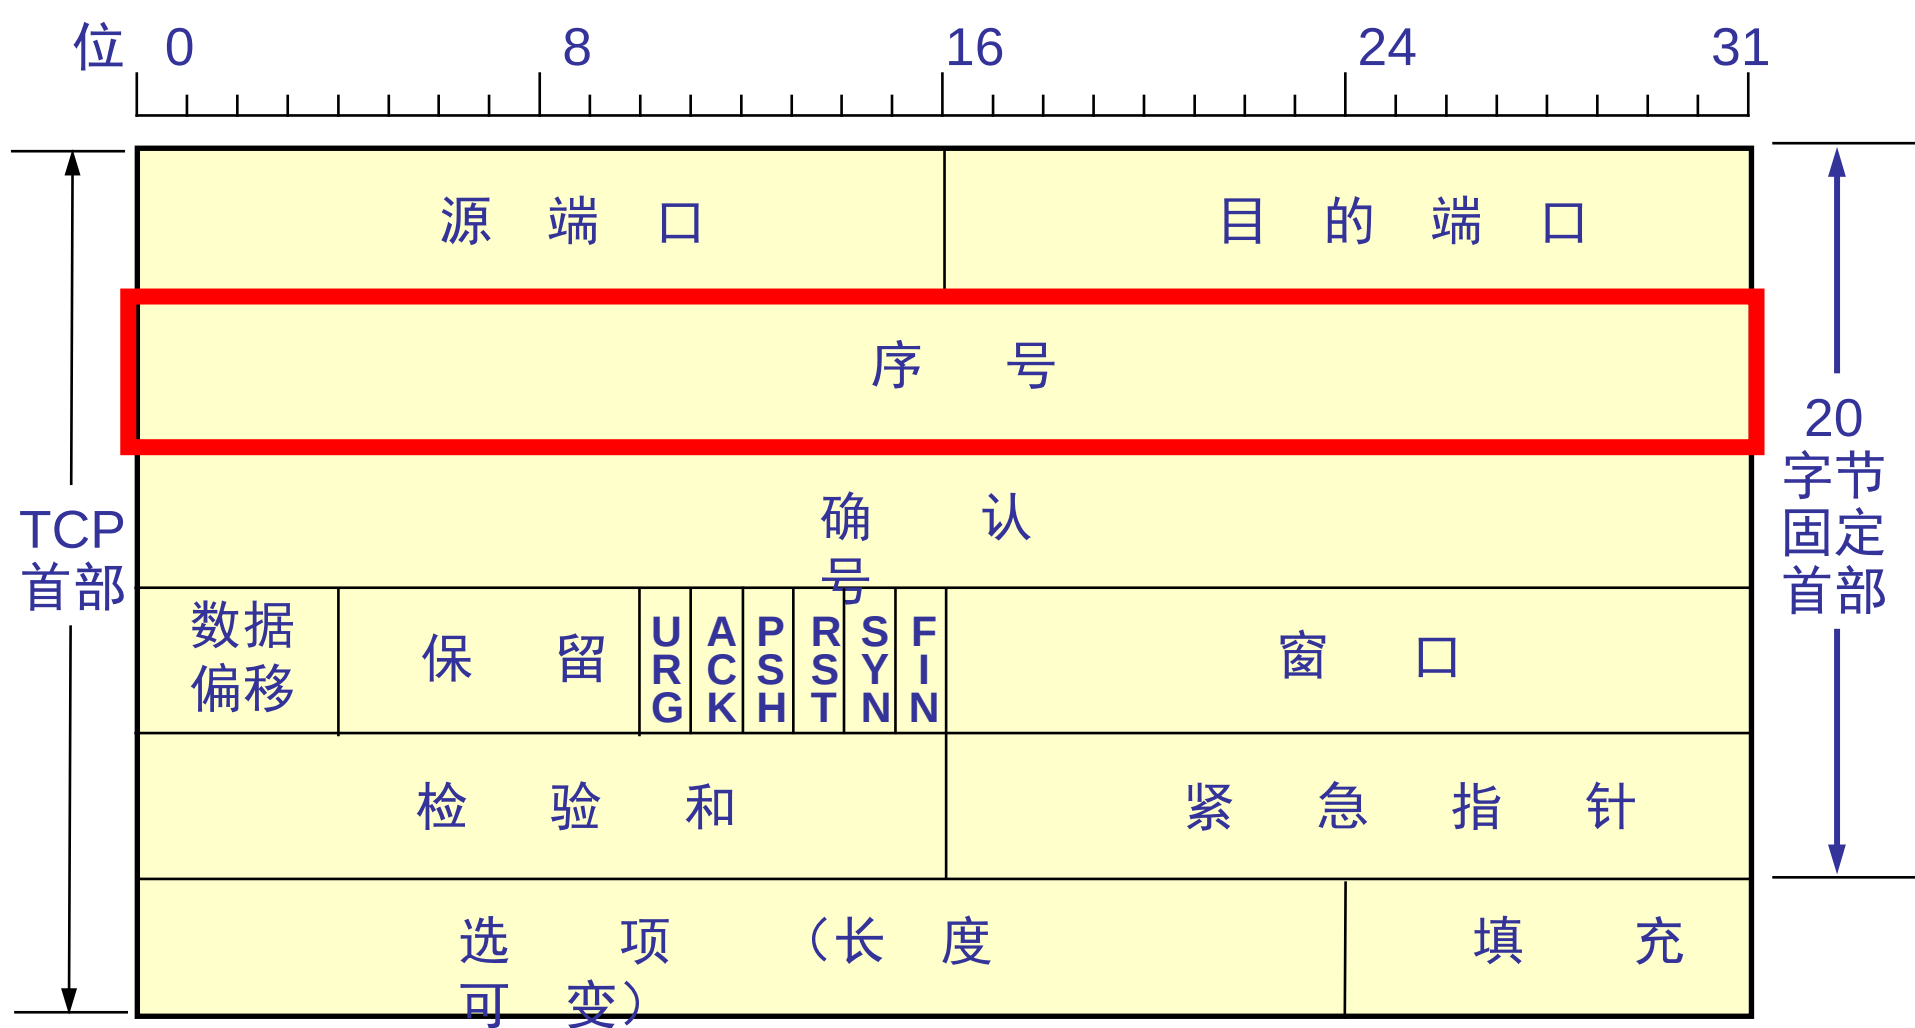
源端口和目的端口字段——各占 2 字节。端口是运输层与应用层的服务接口。运输层的复用和分用功能都要通过端口才能实现。



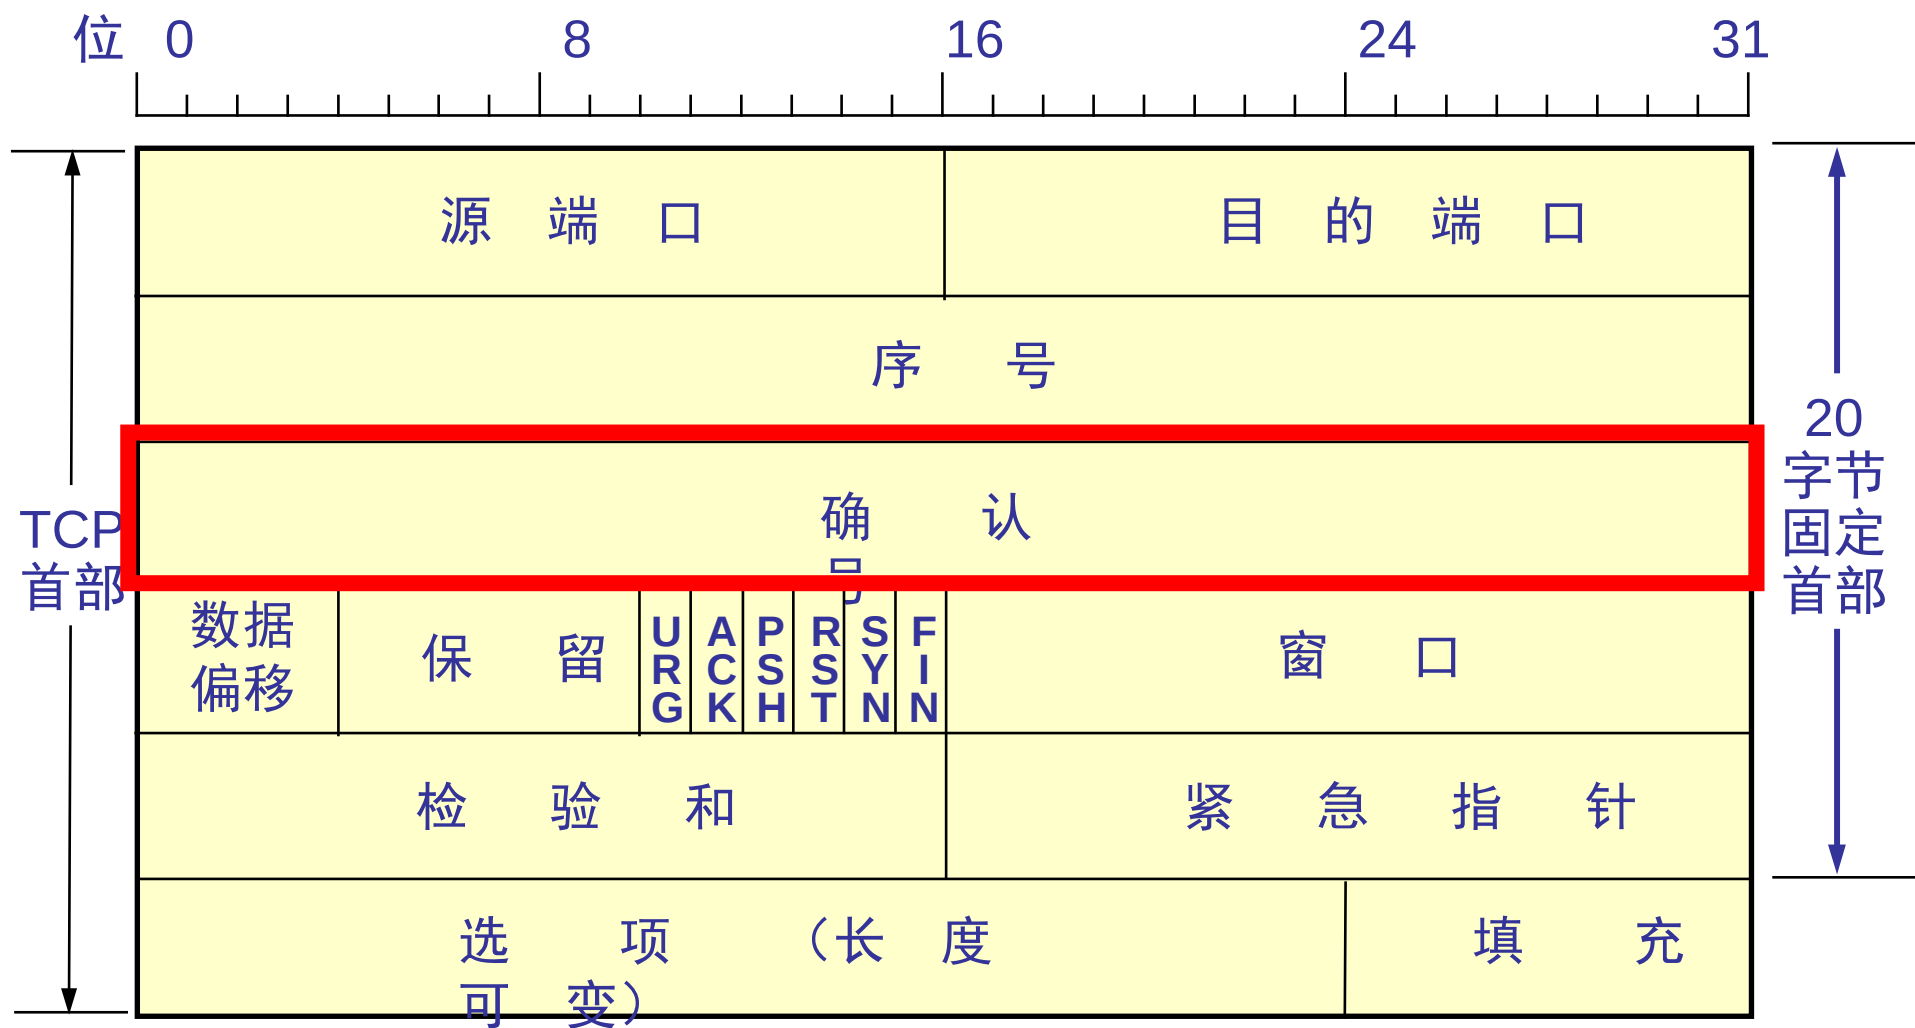
TCP 的端口号分配

TCP 常用的熟知端口号

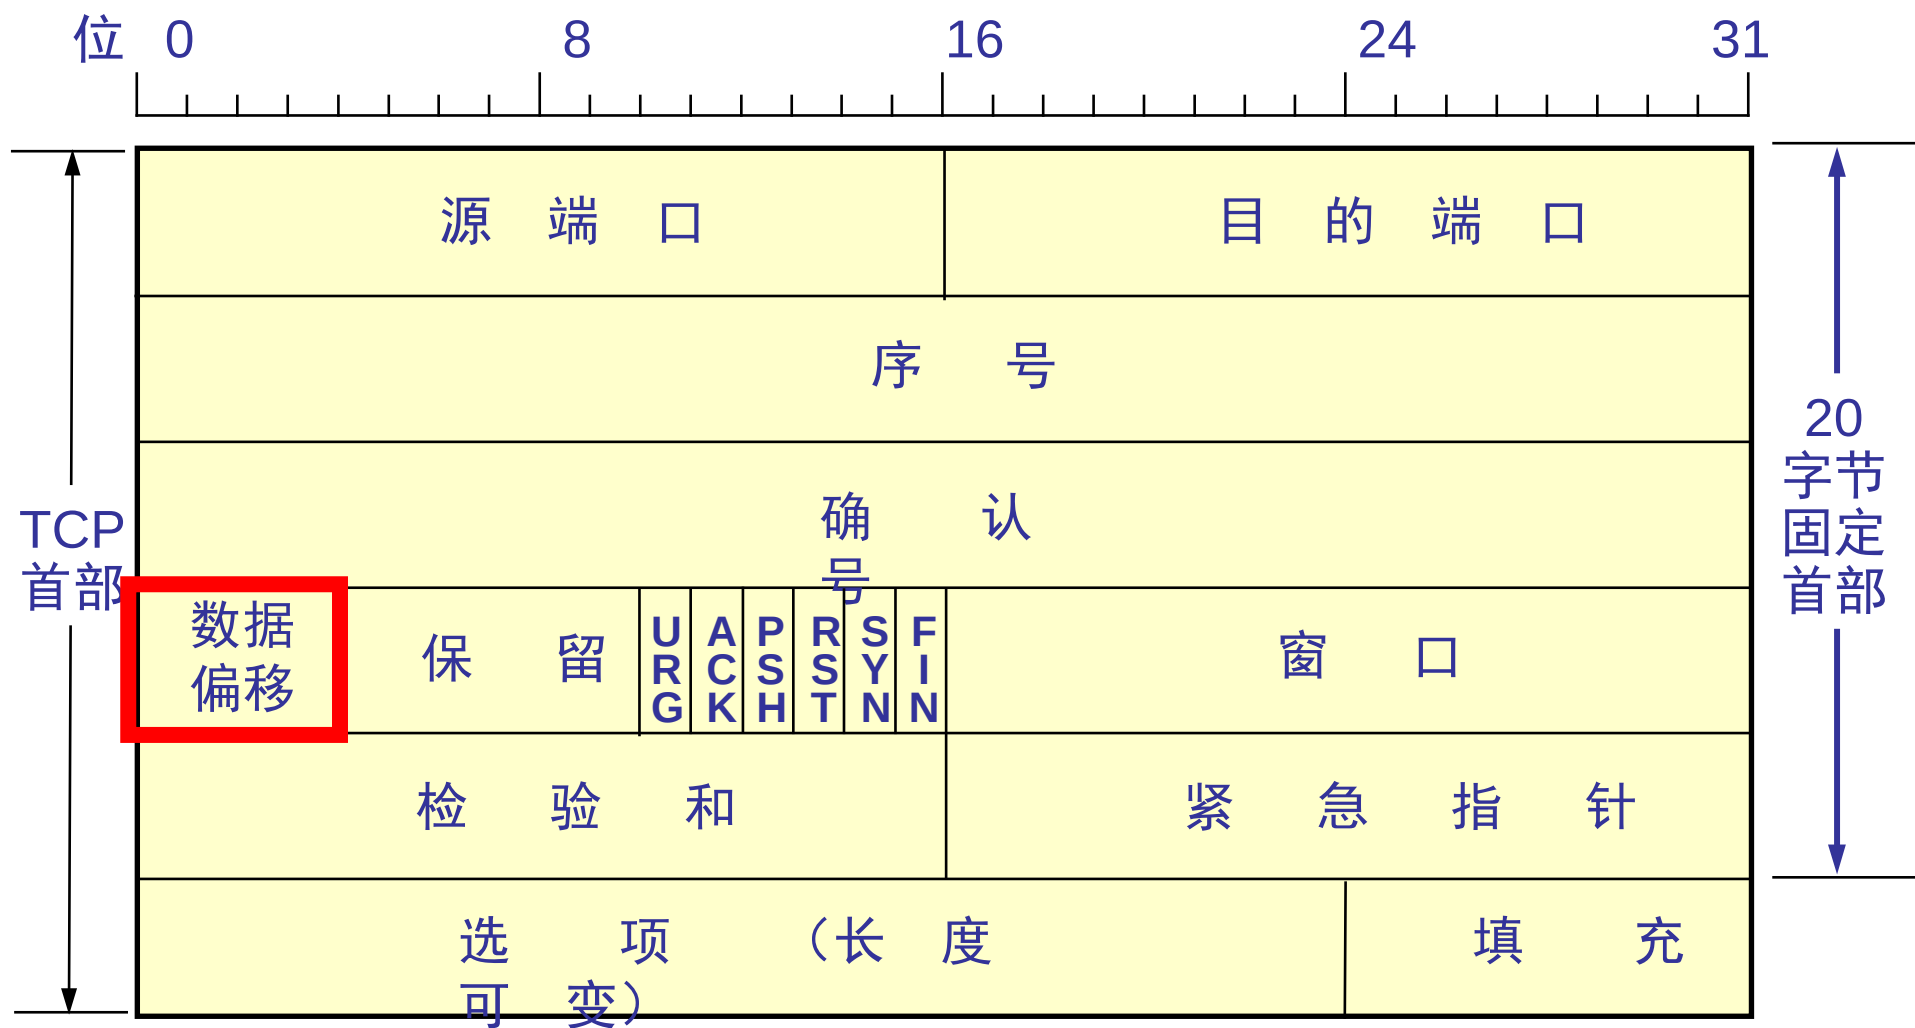
| 端口号 | 服务进程 | 说明 |
|-----|--------|--------------|
| 20 | FTP | 文件传输协议（数据连接） |
| 21 | FTP | 文件传输协议（控制连接） |
| 23 | Telnet | 虚拟终端网络 |
| 25 | SMTP | 简单邮件传输协议 |
| 53 | DNS | 域名服务器 |
| 80 | HTTP | 超文本传输协议 |
| 111 | RPC | 远程过程调用 |



序号字段——占 4 字节。TCP 连接中传送的数据流中的每一个字节都编上一个序号。序号字段的值则指的是本报文段所发送的数据的第一个字节的序号。



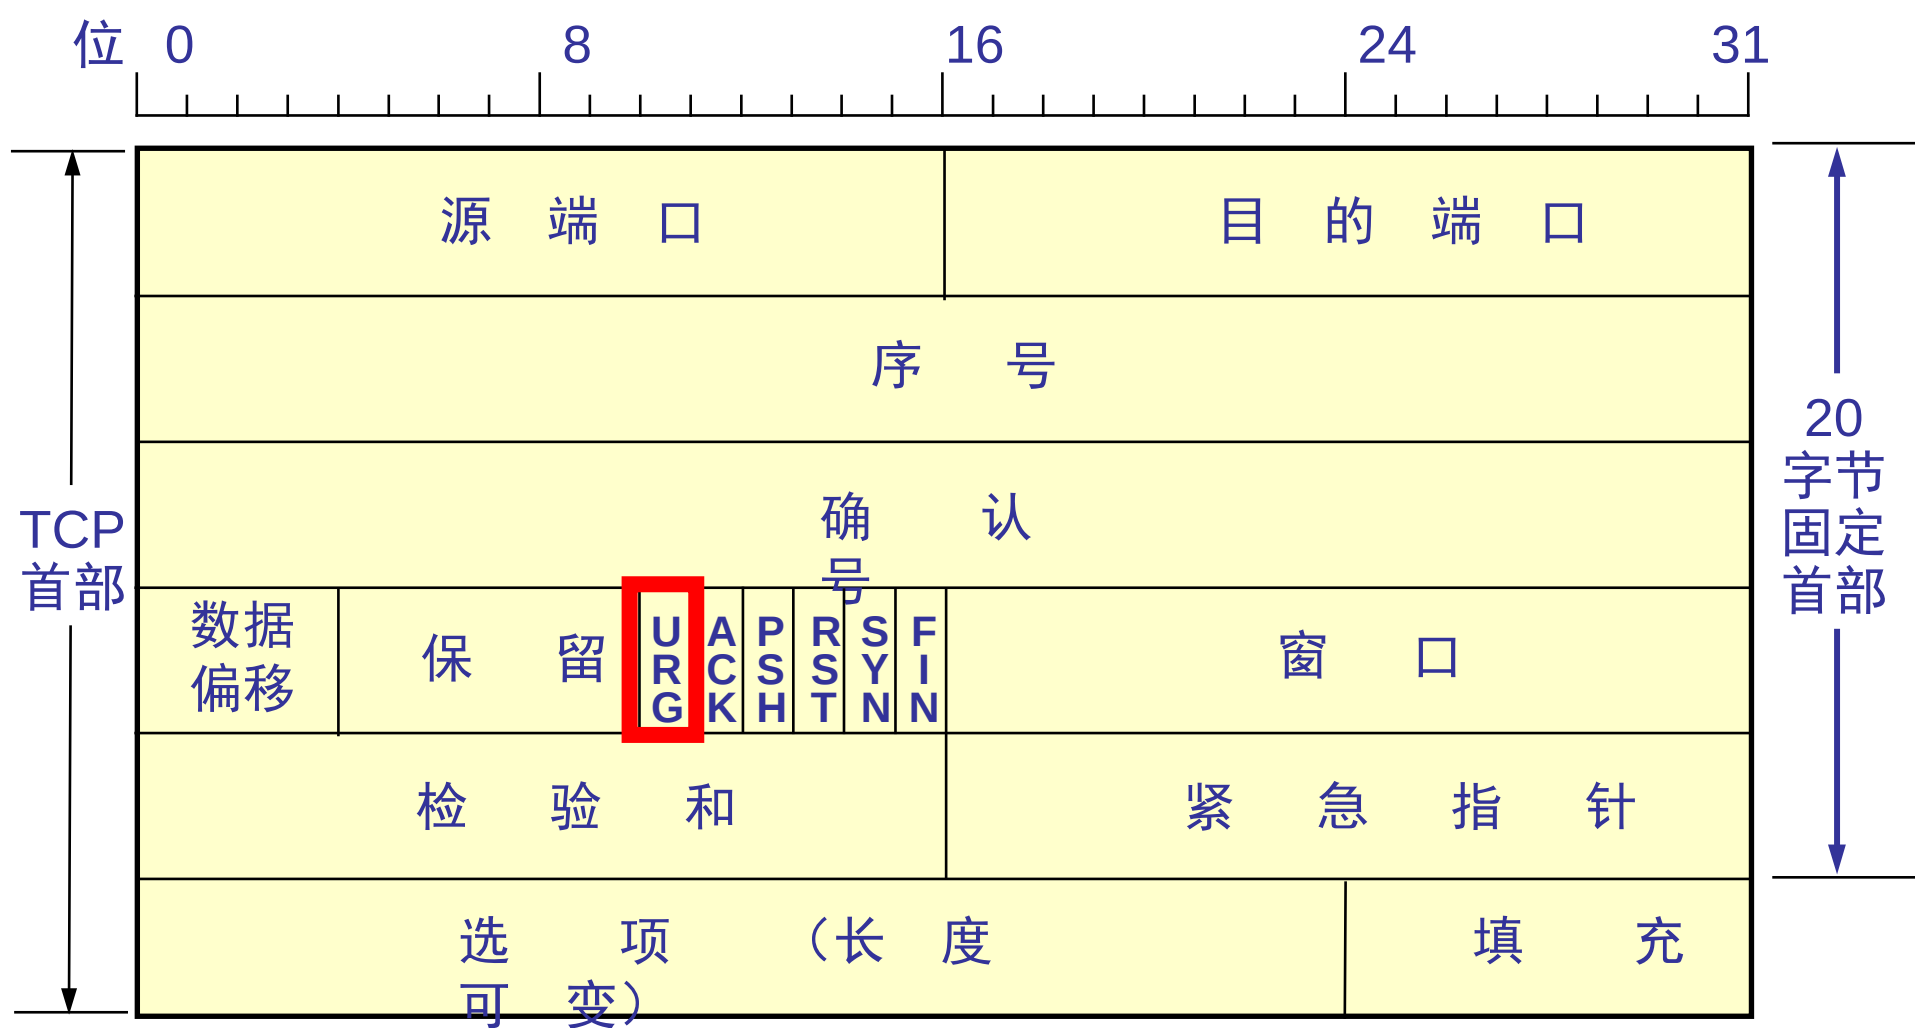
确认号字段——占 4 字节，是期望收到对方的下一个报文段的数据的第一个字节的序号。



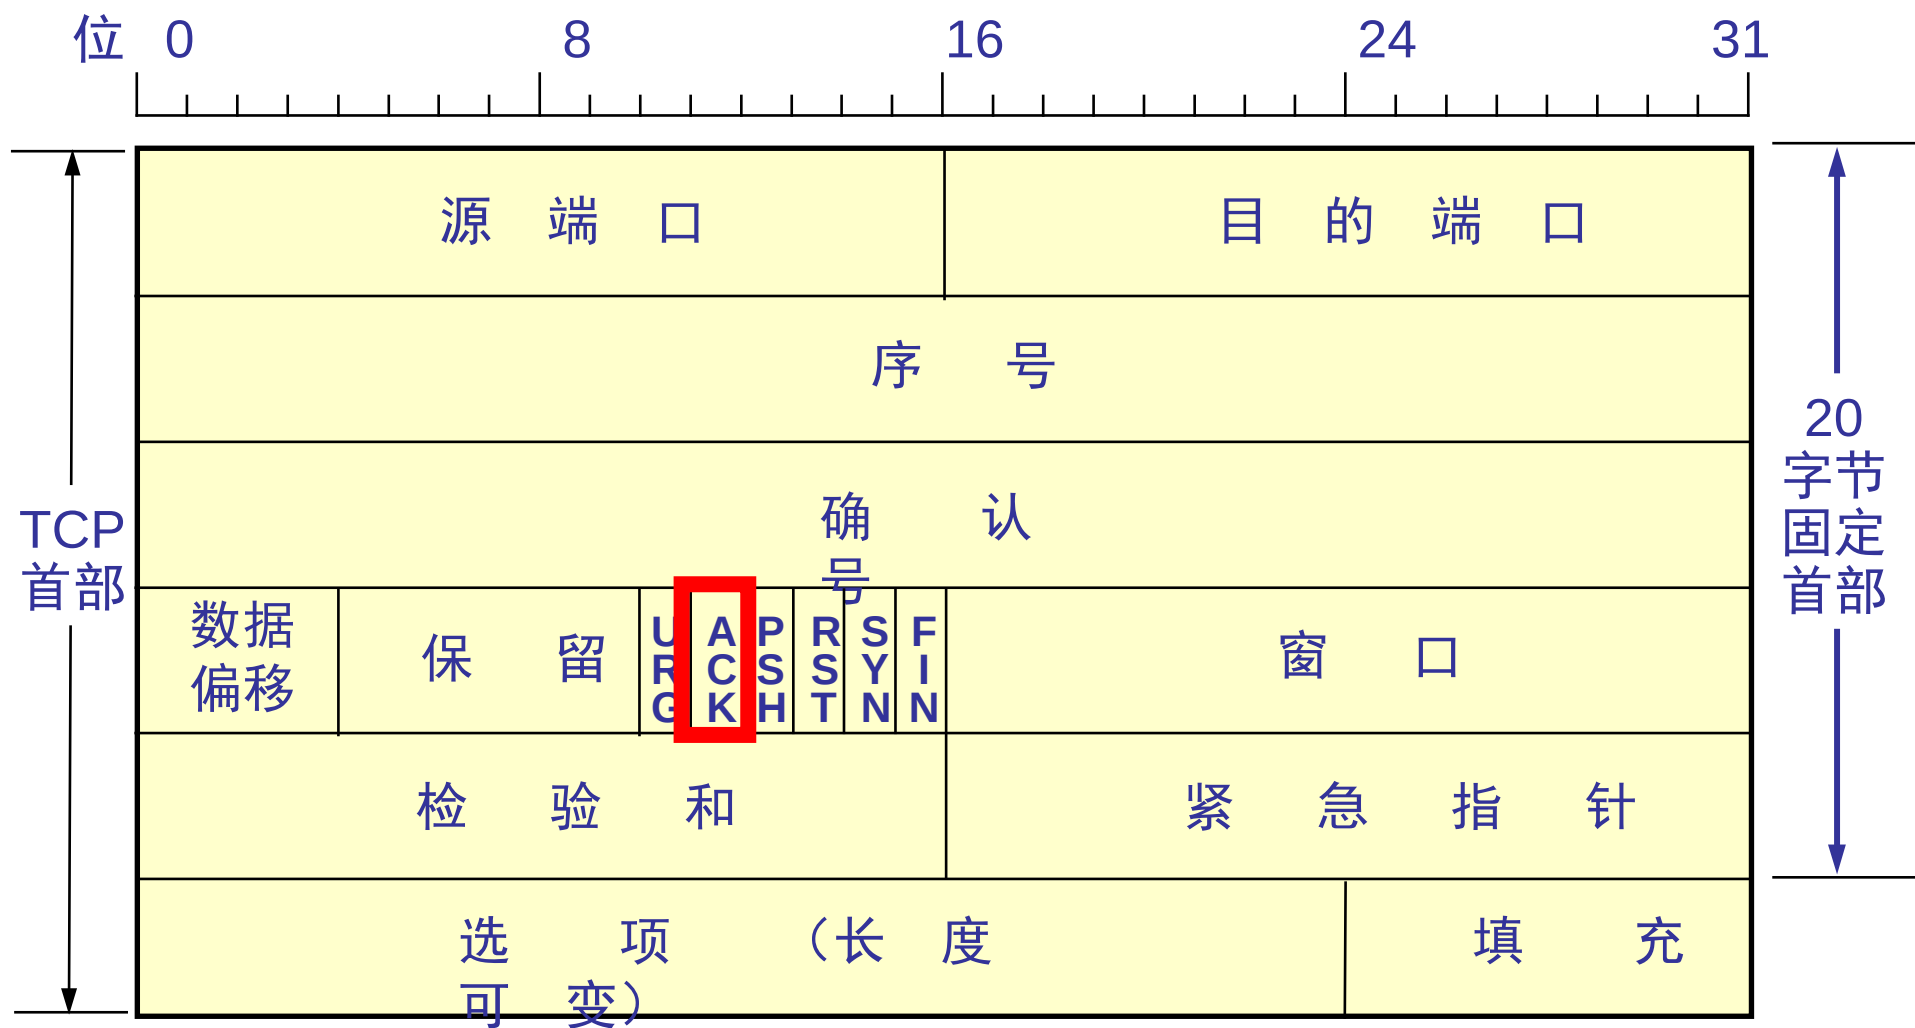
数据偏移（即首部长度的）——占 4 位，它指出 TCP 报文段的数据起始处距离 TCP 报文段的起始处有多远。
“数据偏移”的单位是 32 位字（以 4 字节为计算单位）。



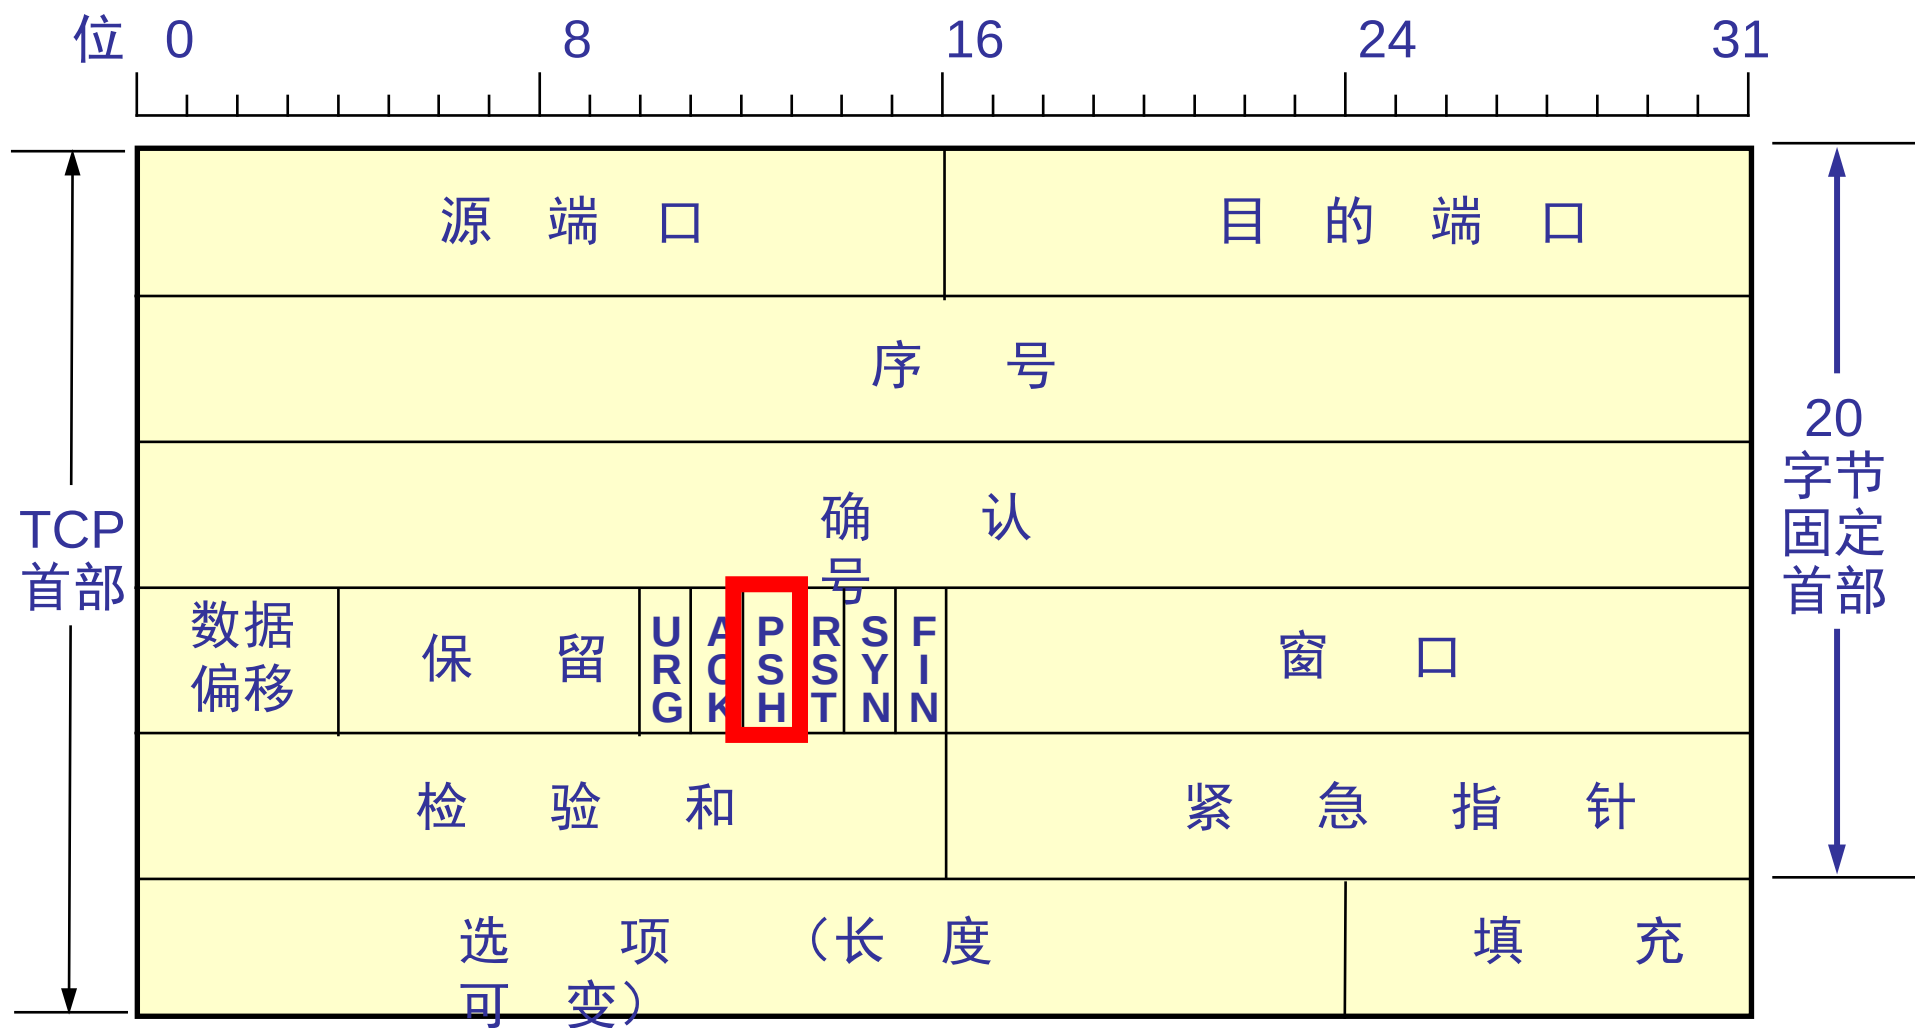
保留字段——占 6 位，保留为今后使用，但目前应置为 0。



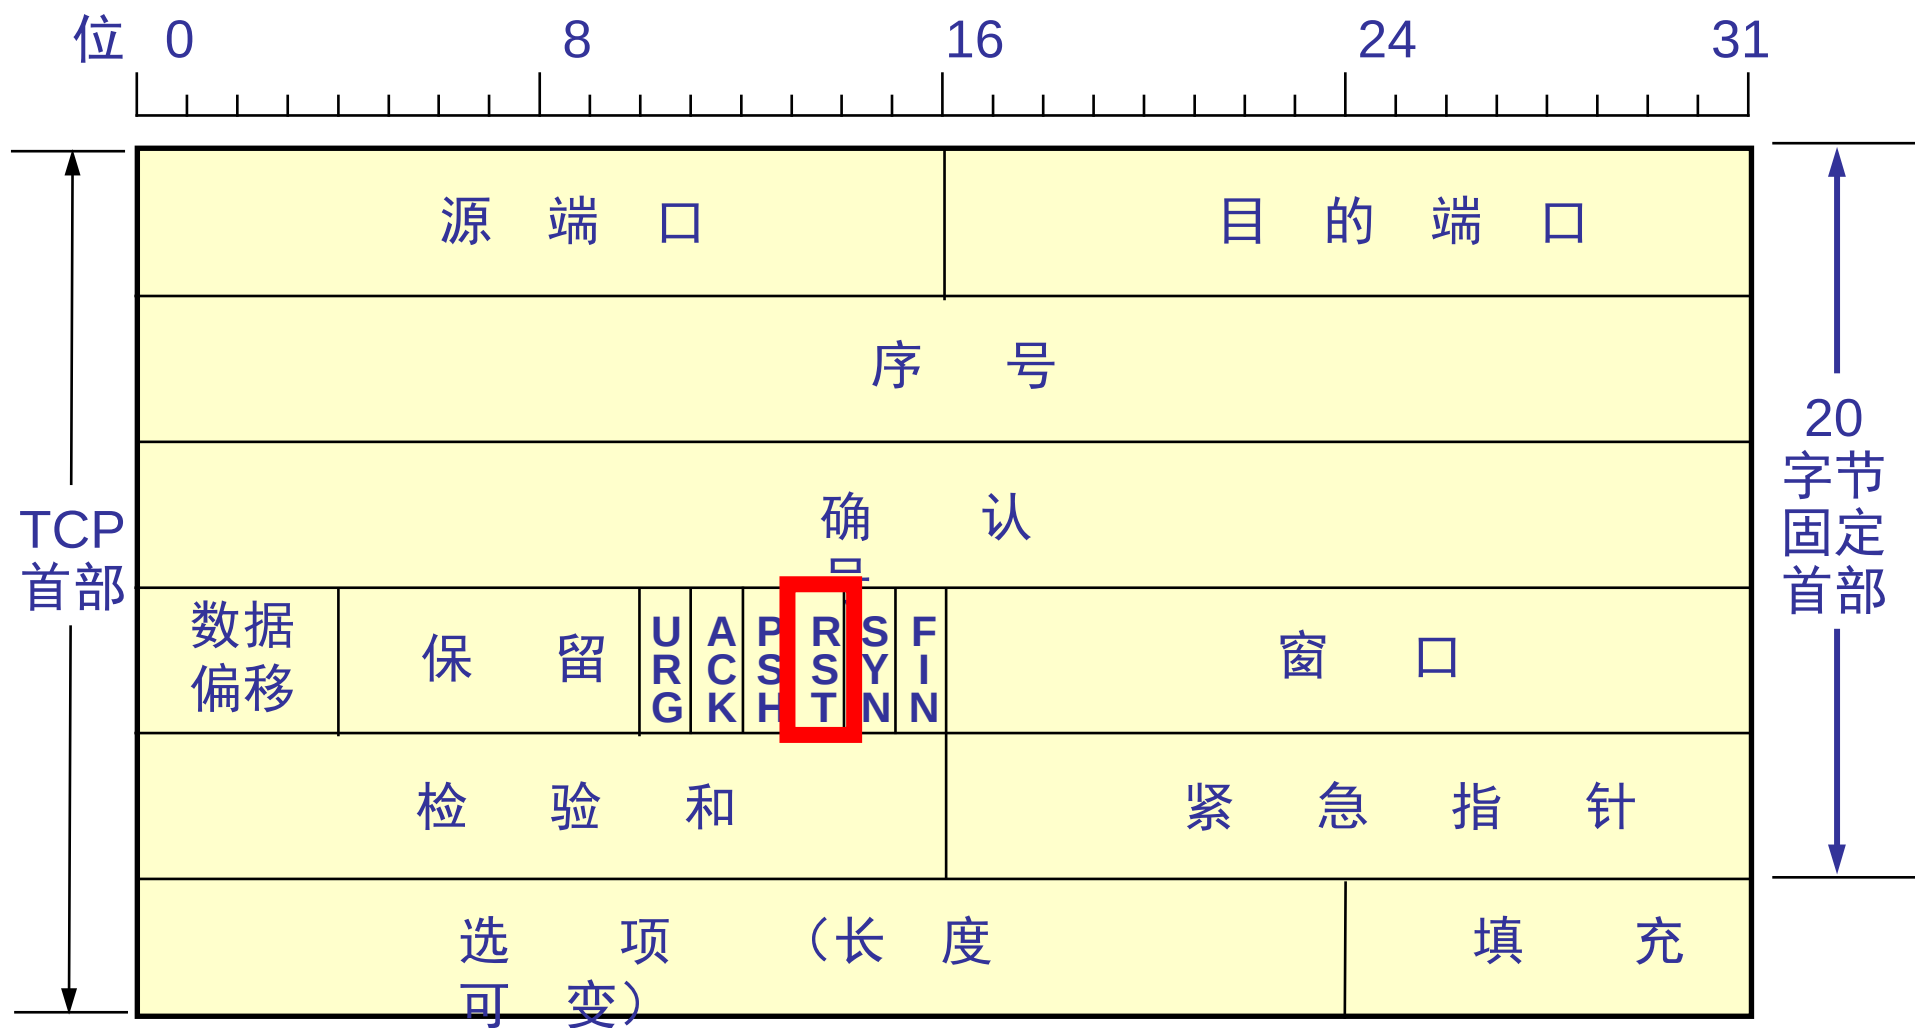
紧急 URG —— 当 $URG = 1$ 时，表明紧急指针字段有效。它告诉系统此报文段中有紧急数据，应尽快传送（相当于高优先级的数据）。



确认 ACK —— 只有当 $ACK = 1$ 时确认号字段才有效。当 $ACK = 0$ 时，确认号无效。



推送 PSH (PuSH) —— 接收 TCP 收到 PSH = 1 的报文段，就尽快地交付接收应用进程，而不再等到整个缓存都填满了后再向上交付。



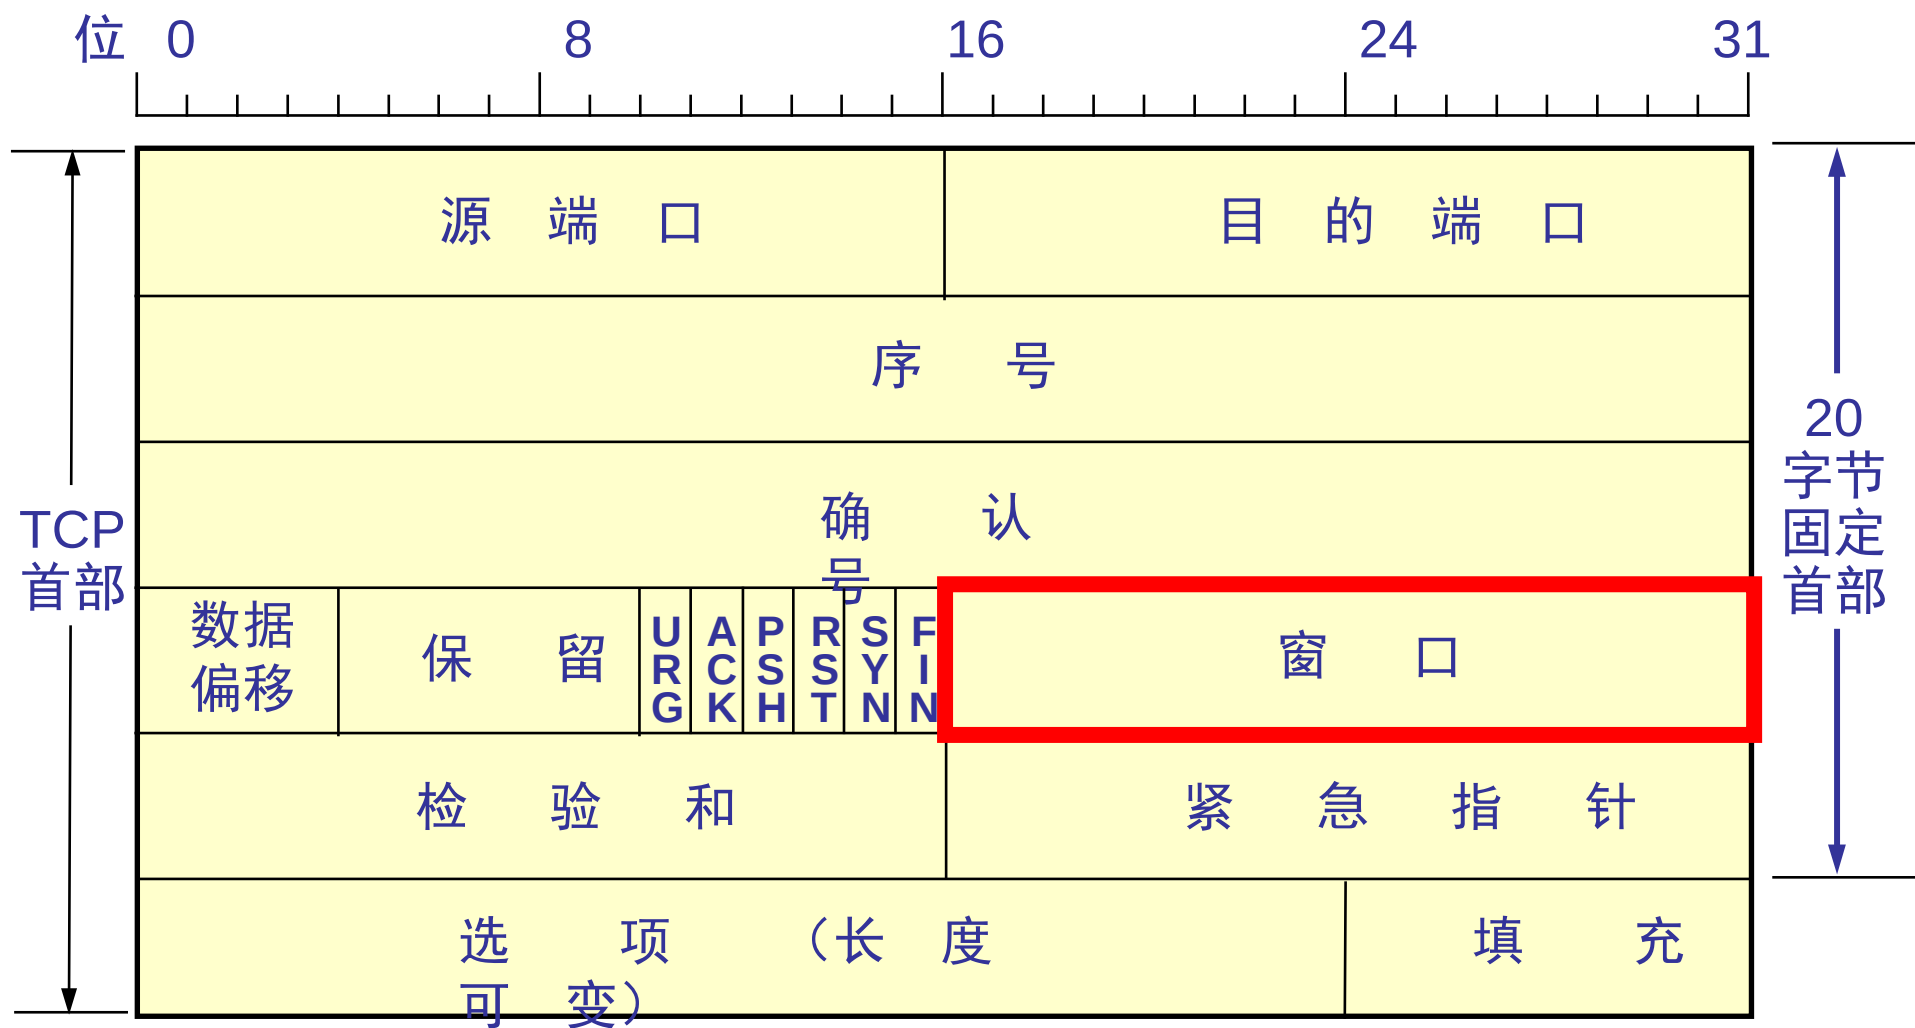
复位 RST (ReSeT) —— 当 $RST = 1$ 时, 表明 TCP 连接中出现严重差错 (如由于主机崩溃或其他原因), 必须释放连接, 然后再重新建立运输连接。



同步 SYN —— 同步 SYN = 1 表示这是一个连接请求或连接接受报文。



终止 FIN (FINis) —— 用来释放一个连接。FIN = 1 表明此报文段的发送端的数据已发送完毕，并要求释放运输连接。



窗口字段 —— 占 2 字节，用来让对方设置发送窗口的依据，单位为字节。




检验和 —— 占 2 字节。检验和字段检验的范围包括首部和数据这两部分。在计算检验和时，要在 TCP 报文段的前面加上 12 字节的伪首部。



紧急指针字段 —— 占 16 位，指出在本报文段中紧急数据共有多少个字节（紧急数据放在本报文段数据的最前面）。

MSS (Maximum Segment Size)
是 TCP 报文段中的**数据字段**的最大长度。
数据字段加上 TCP 首部
才等于整个的 TCP 报文段。

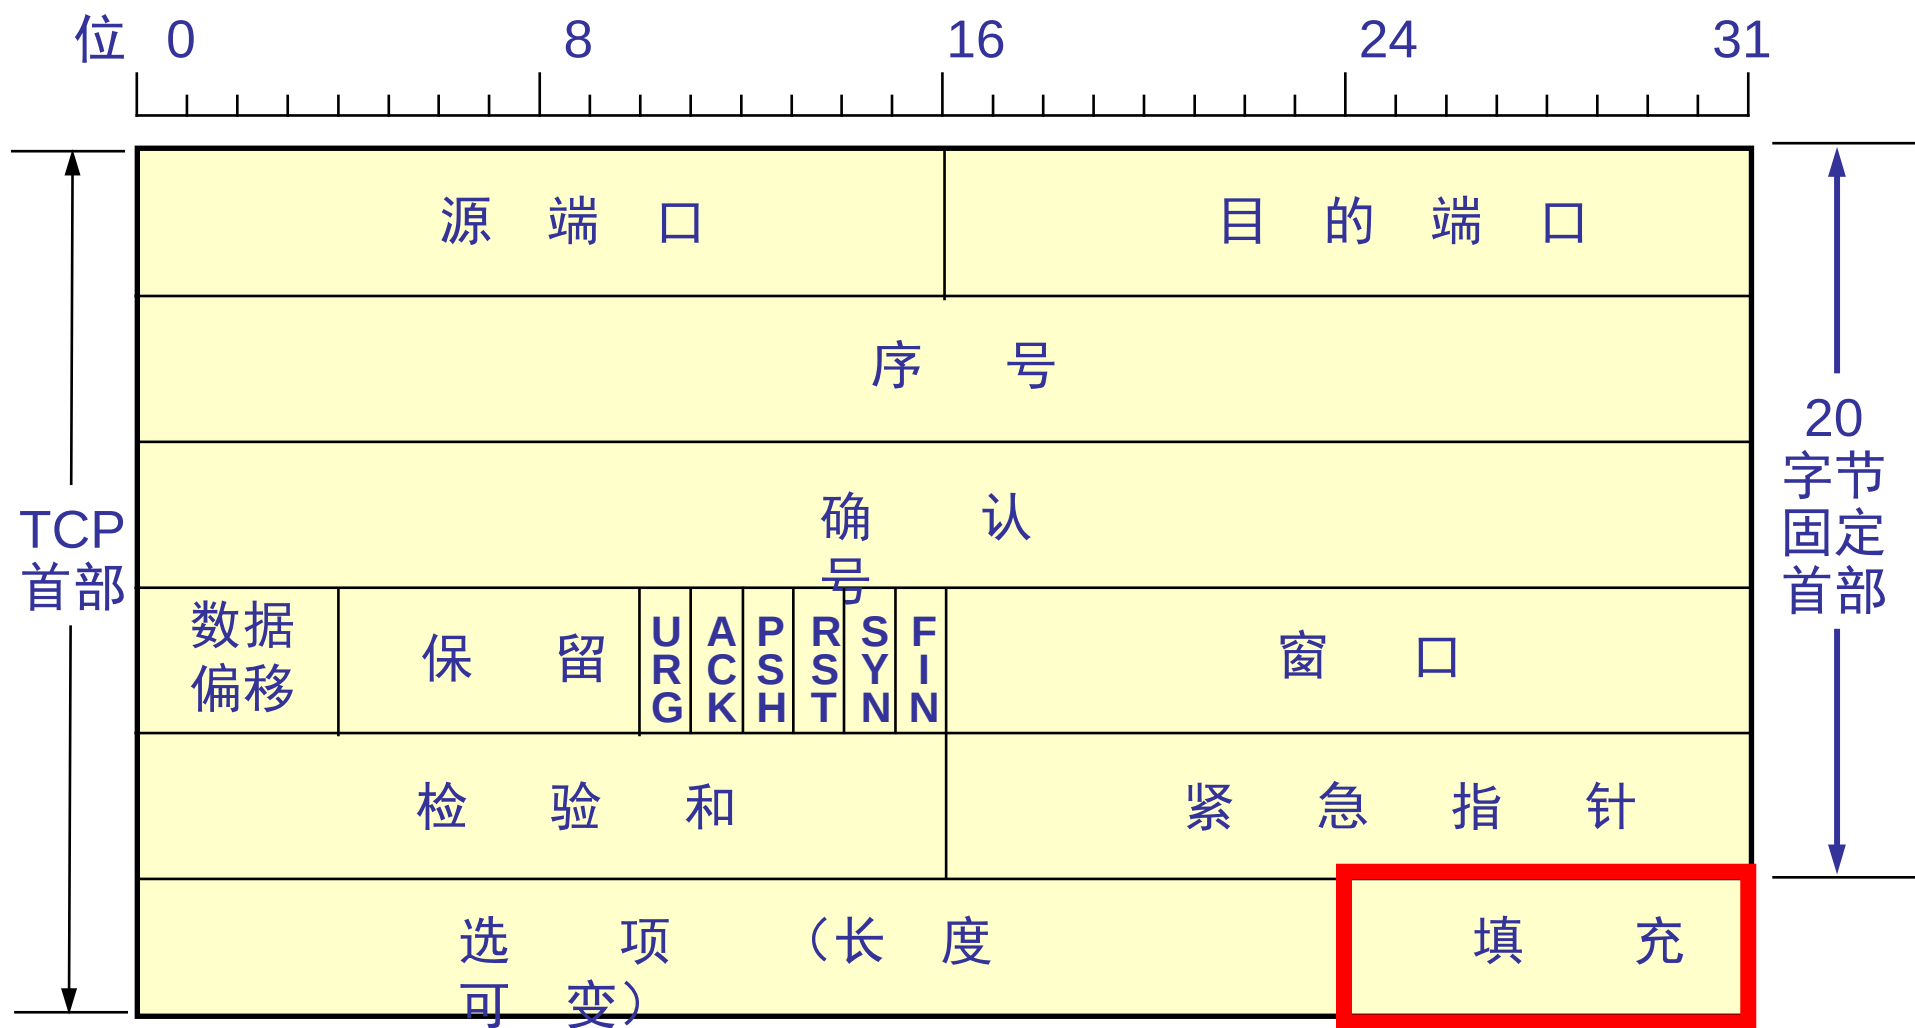


选项字段 —— 长度可变。TCP 最初只规定了一种选项，即**最大报文段长度** MSS。MSS 告诉对方 TCP：“我的缓存所能接收的报文段的数据字段的最大长度是 MSS 个字节。”



其他选项

- 窗口扩大选项 ——占 3 字节，其中有一个字节表示移位值 S 。新的窗口值等于 TCP 首部中的窗口位数增大到 $(16 + S)$ ，相当于把窗口值向左移动 S 位后获得实际的窗口大小。
- 时间戳选项——占 10 字节，其中最主要的字段时间戳值字段（4 字节）和时间戳回送回答字段（4 字节）。
- 选择确认选项——在后面的 5.6.3 节介绍。

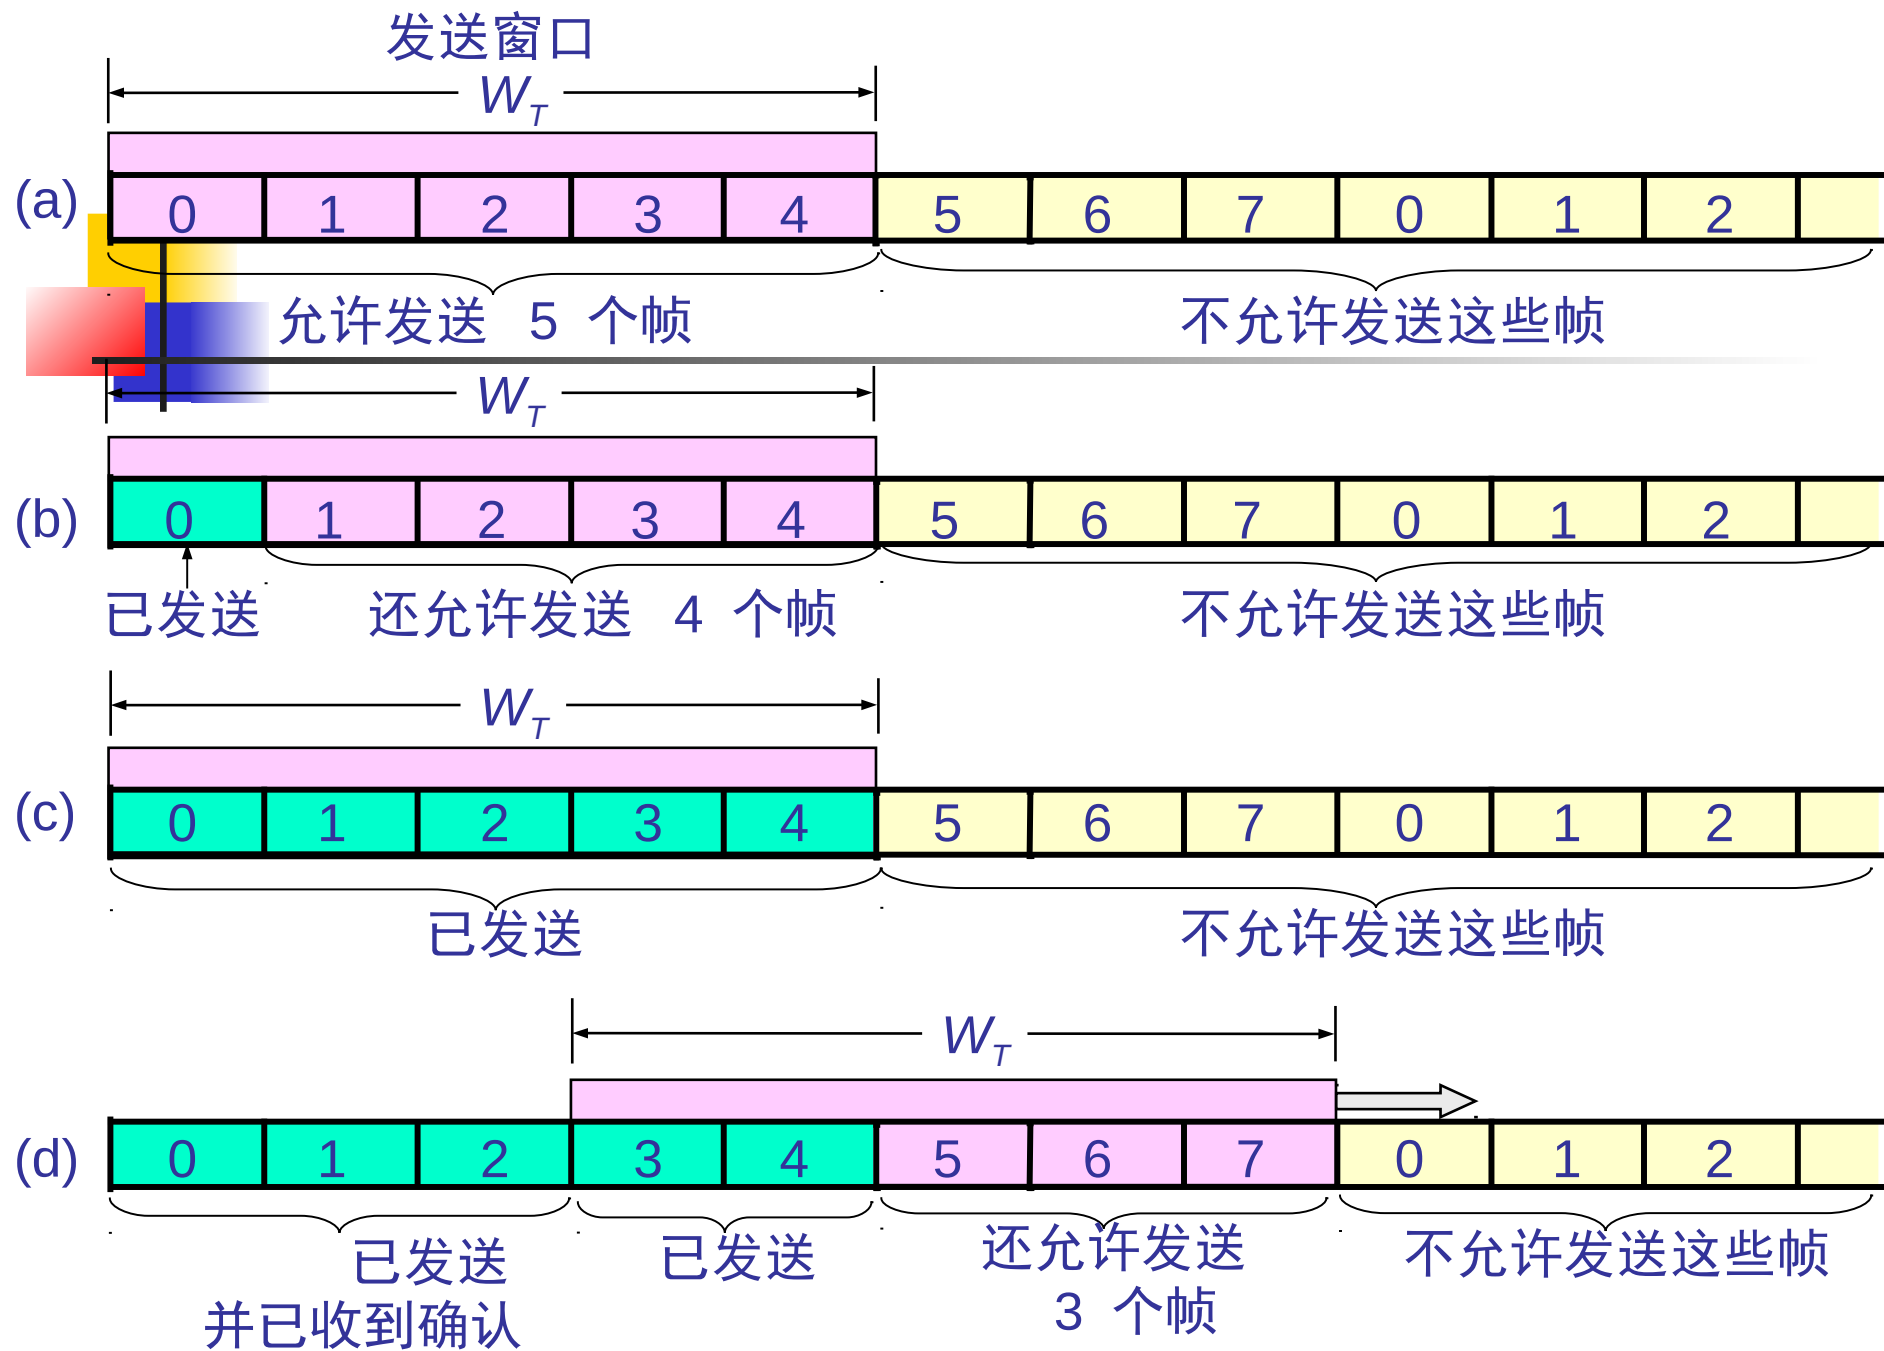


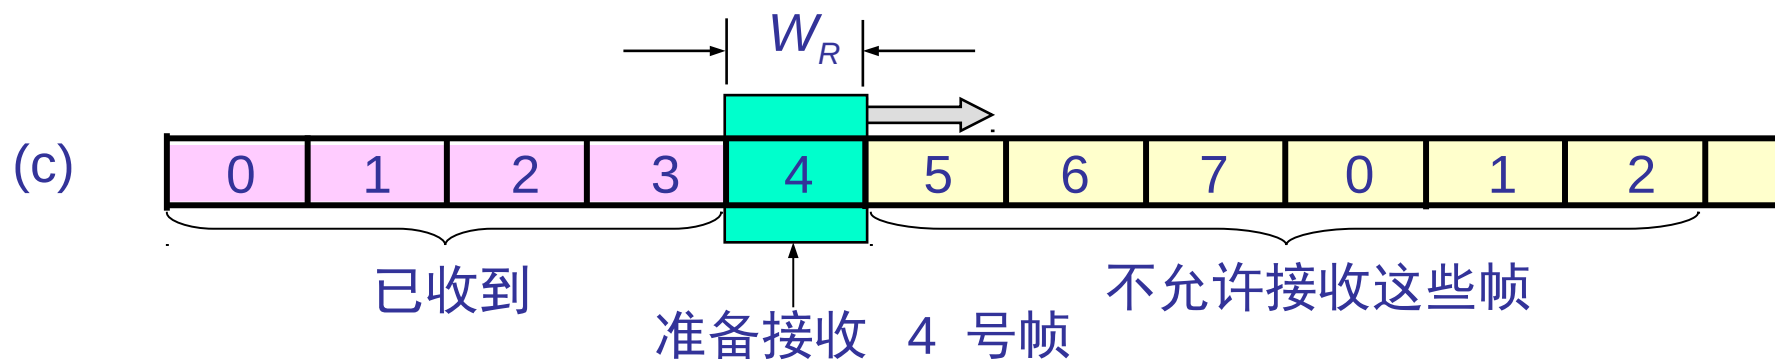

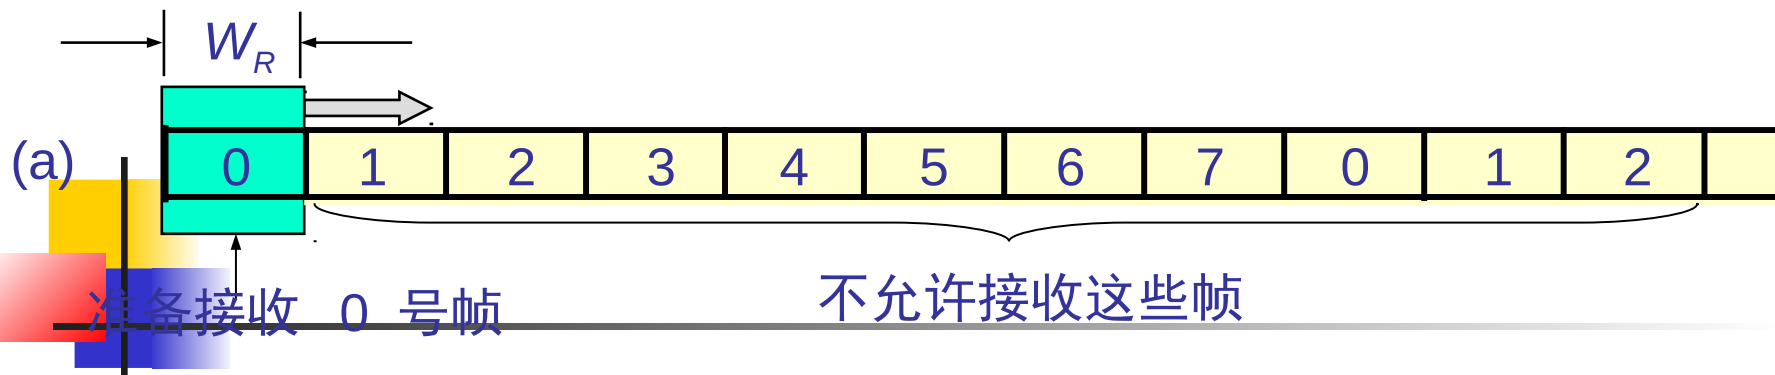
填充字段 —— 这是为了使整个首部长度的 4 字节的整数倍。

5.6 TCP 可靠传输的实现

5.6.1 以字节为单位的滑动窗口

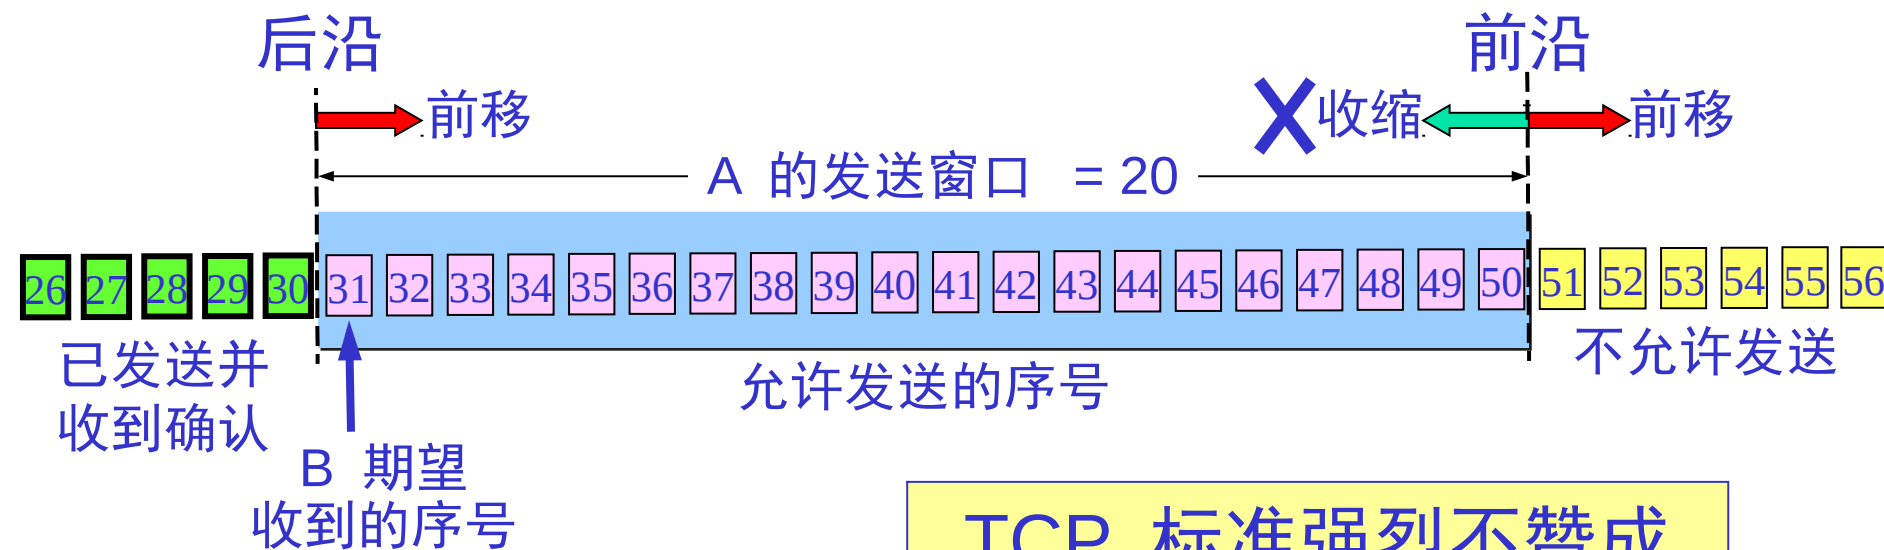
- TCP 采用大小可变的滑动窗口进行流量控制。窗口大小的单位是字节。
- 在 TCP 报文段首部的窗口字段写入的数值就是当前给对方设置的发送窗口数值的上限。
- 发送窗口在连接建立时由双方商定。但在通信的过程中，接收端可根据自己的资源情况，随时动态地调整对方的发送窗口上限值（可增大或减小）。





以字节为单位的滑动窗口

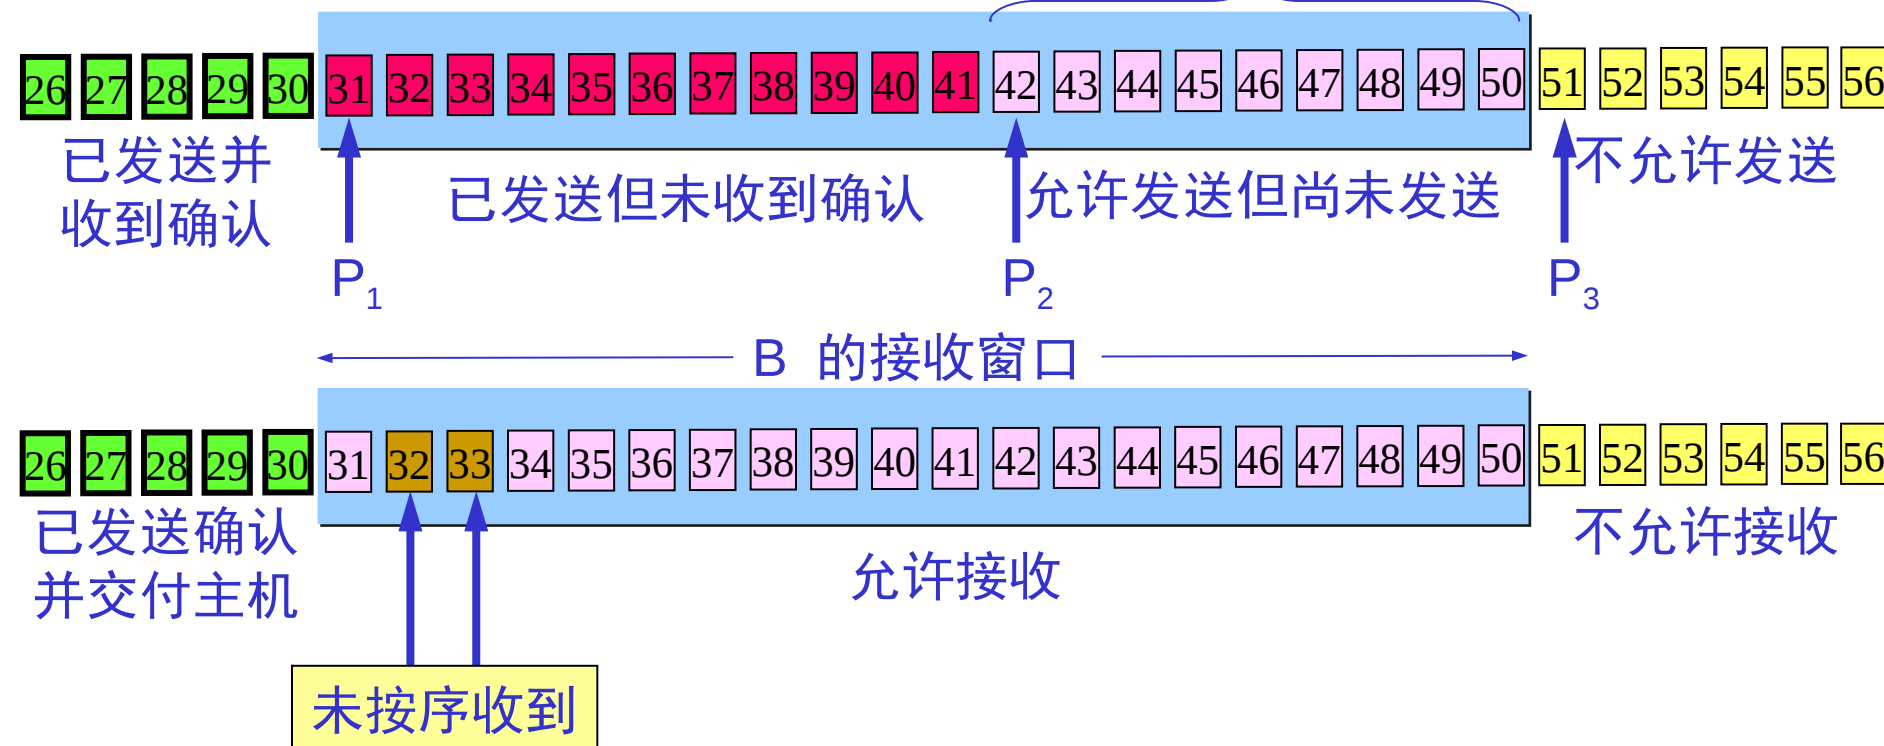
根据 B 给出的窗口值
A 构造出自己的发送窗口



TCP 标准强烈不赞成
发送窗口前沿向后收缩

A 发送了 11 个字节的数据

可用窗口



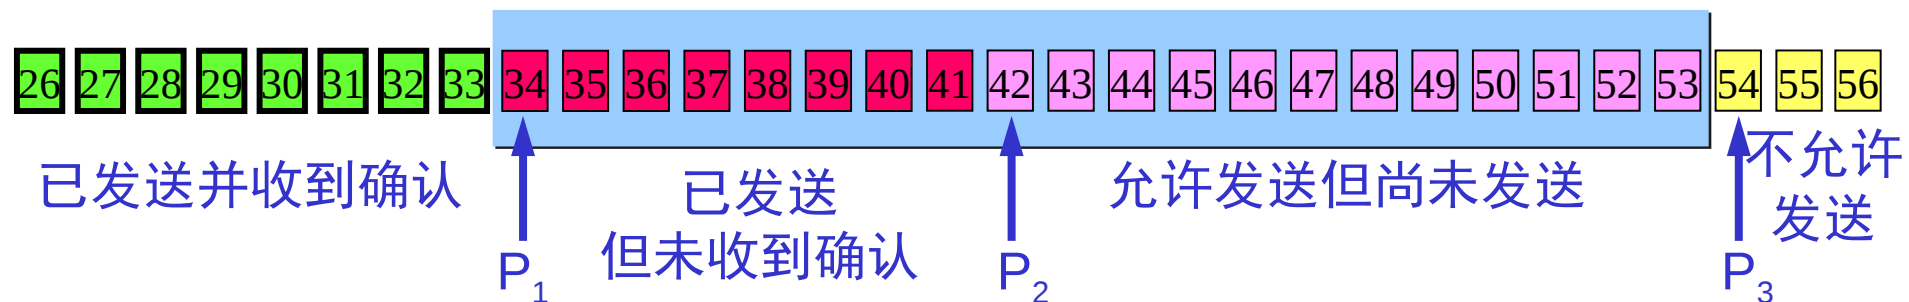
$P_3 - P_1 = A$ 的发送窗口 (又称为通知窗口)

$P_2 - P_1 =$ 已发送但尚未收到确认的字节数

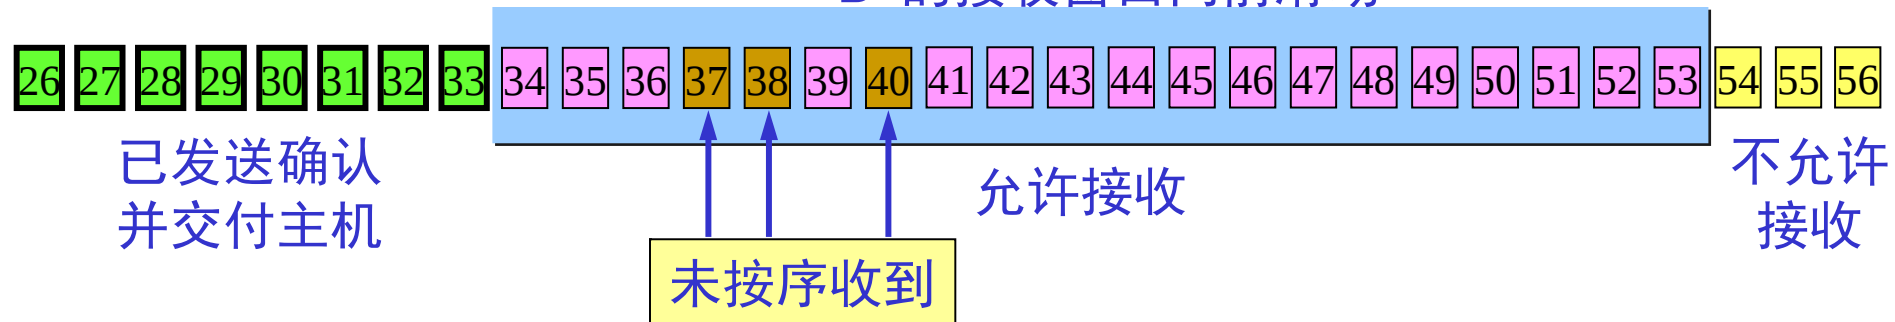
$P_3 - P_2 =$ 允许发送但尚未发送的字节数 (又称为可用窗口)

A 收到新的确认号，发送窗口向前滑动

A 的发送窗口向前滑动 →



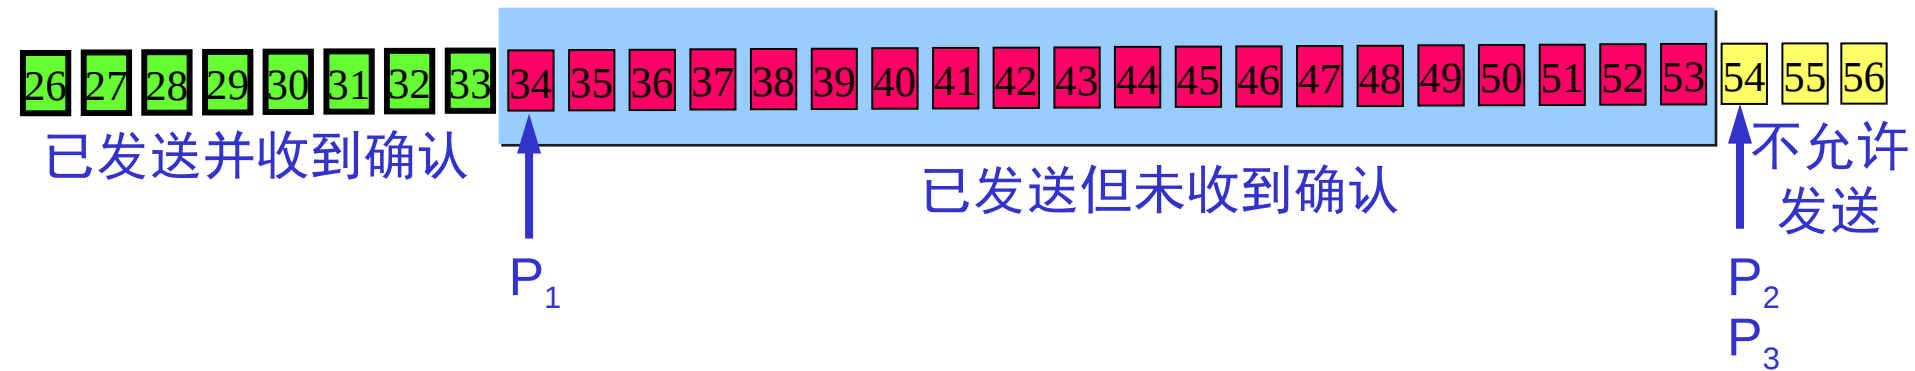
B 的接收窗口向前滑动 →



先存下，等待缺少的数据的到达

A 的发送窗口内的序号都已用完，
但还没有再收到确认，必须停止发送。

A 的发送窗口已满，有效窗口为零



发送缓存

发送应用程序

TCP

发送缓存

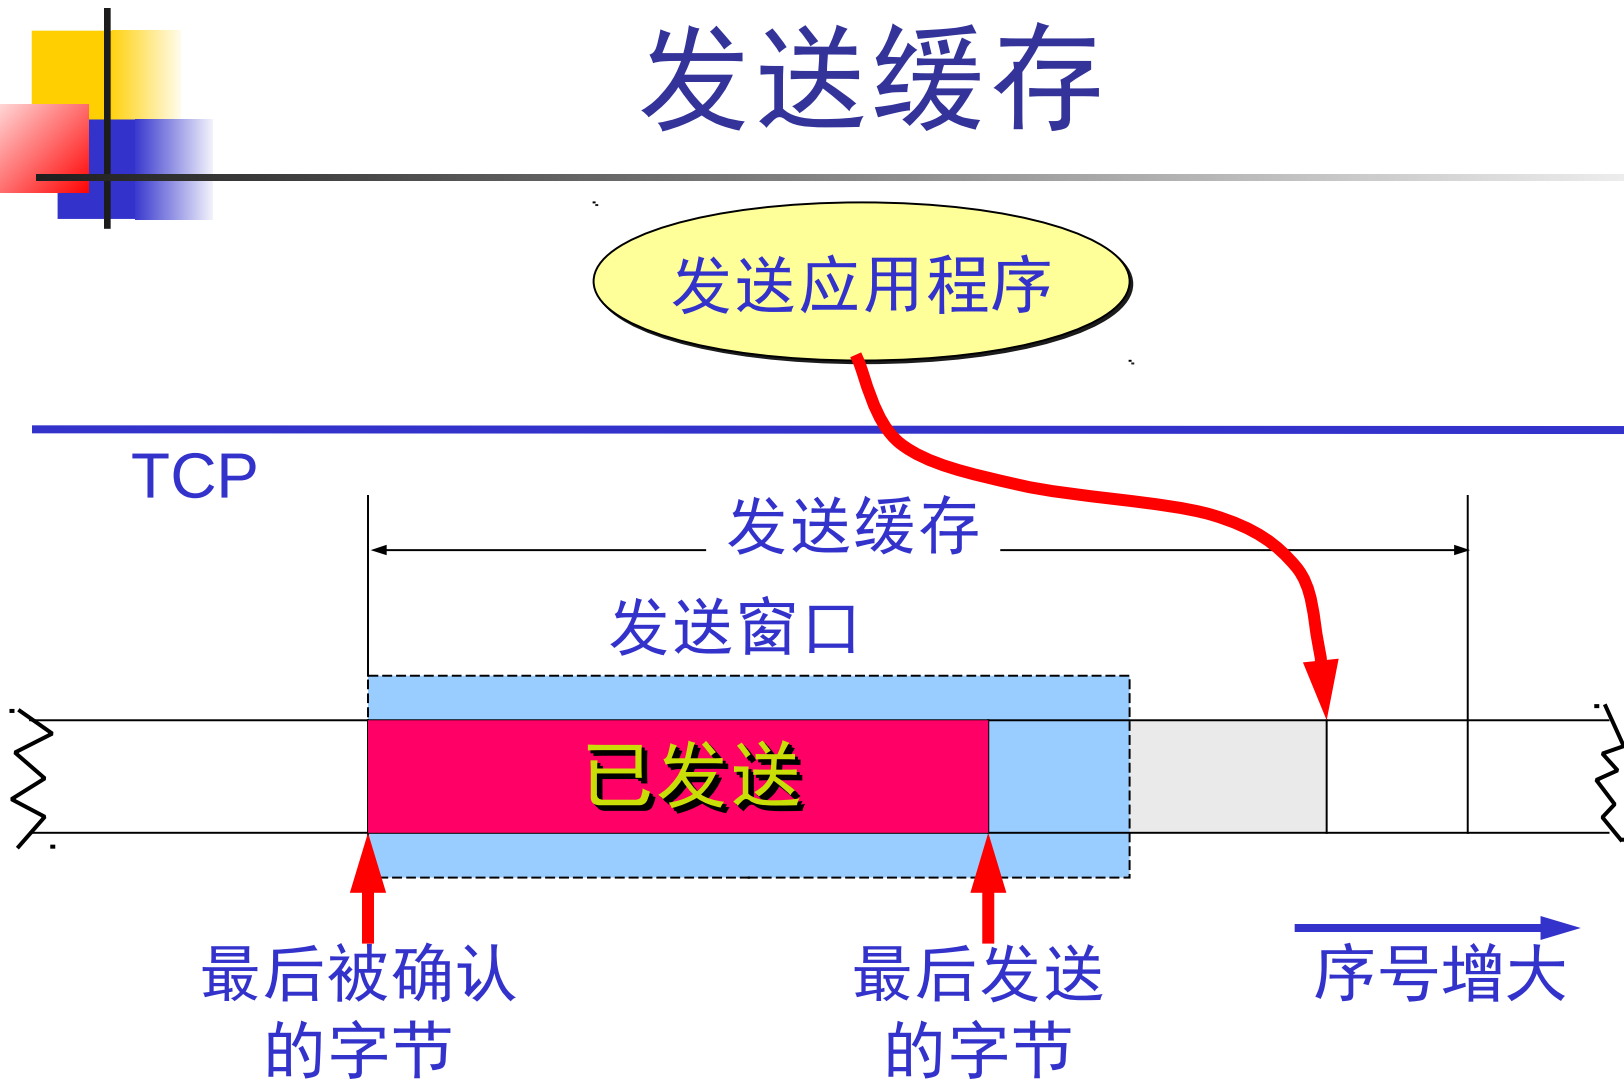
发送窗口

已发送

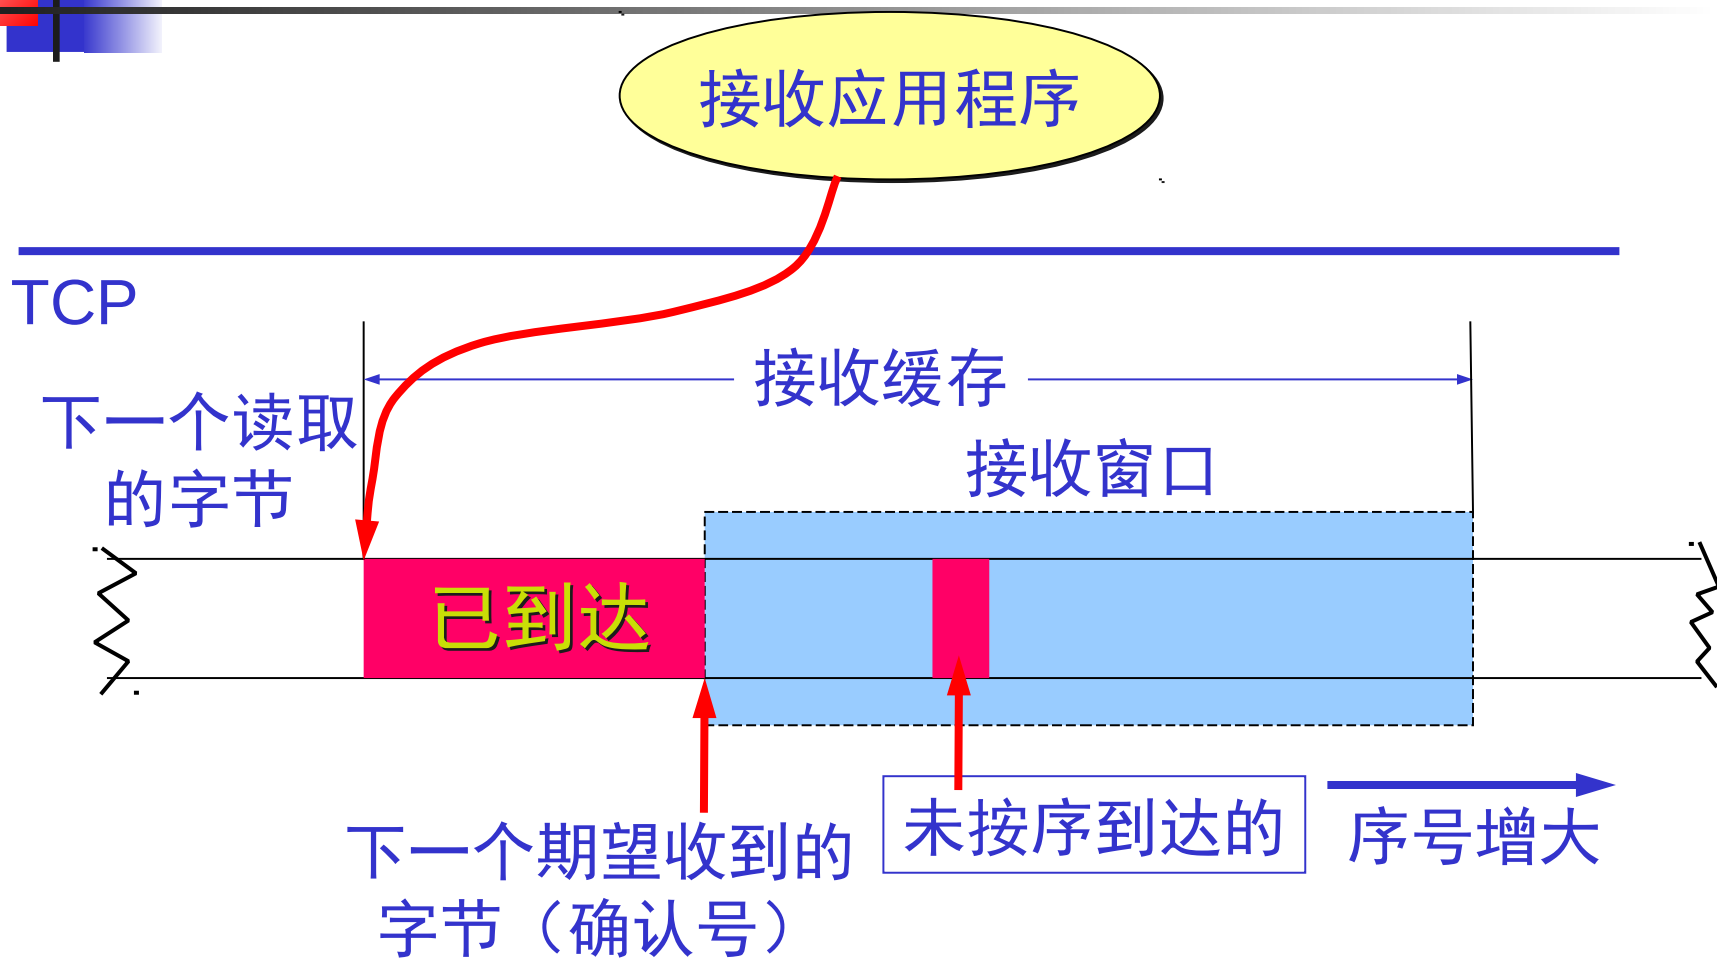
最后被确认
的字节

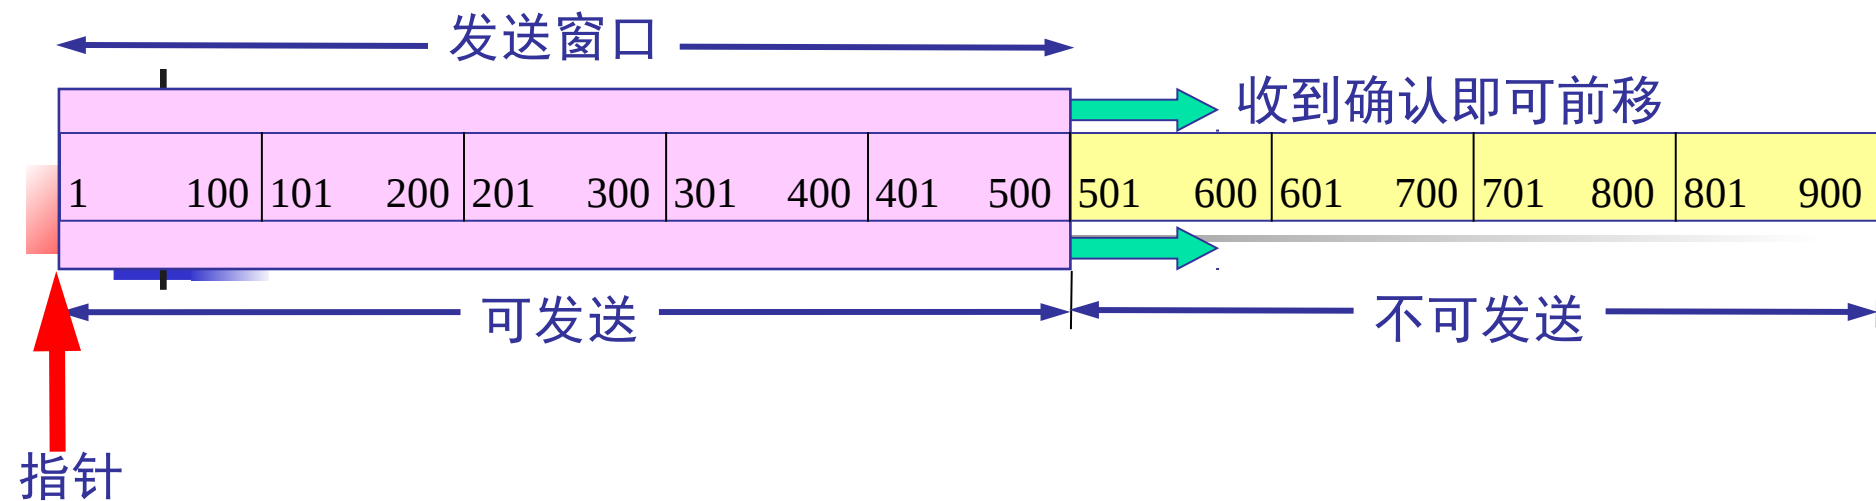
最后发送
的字节

序号增大

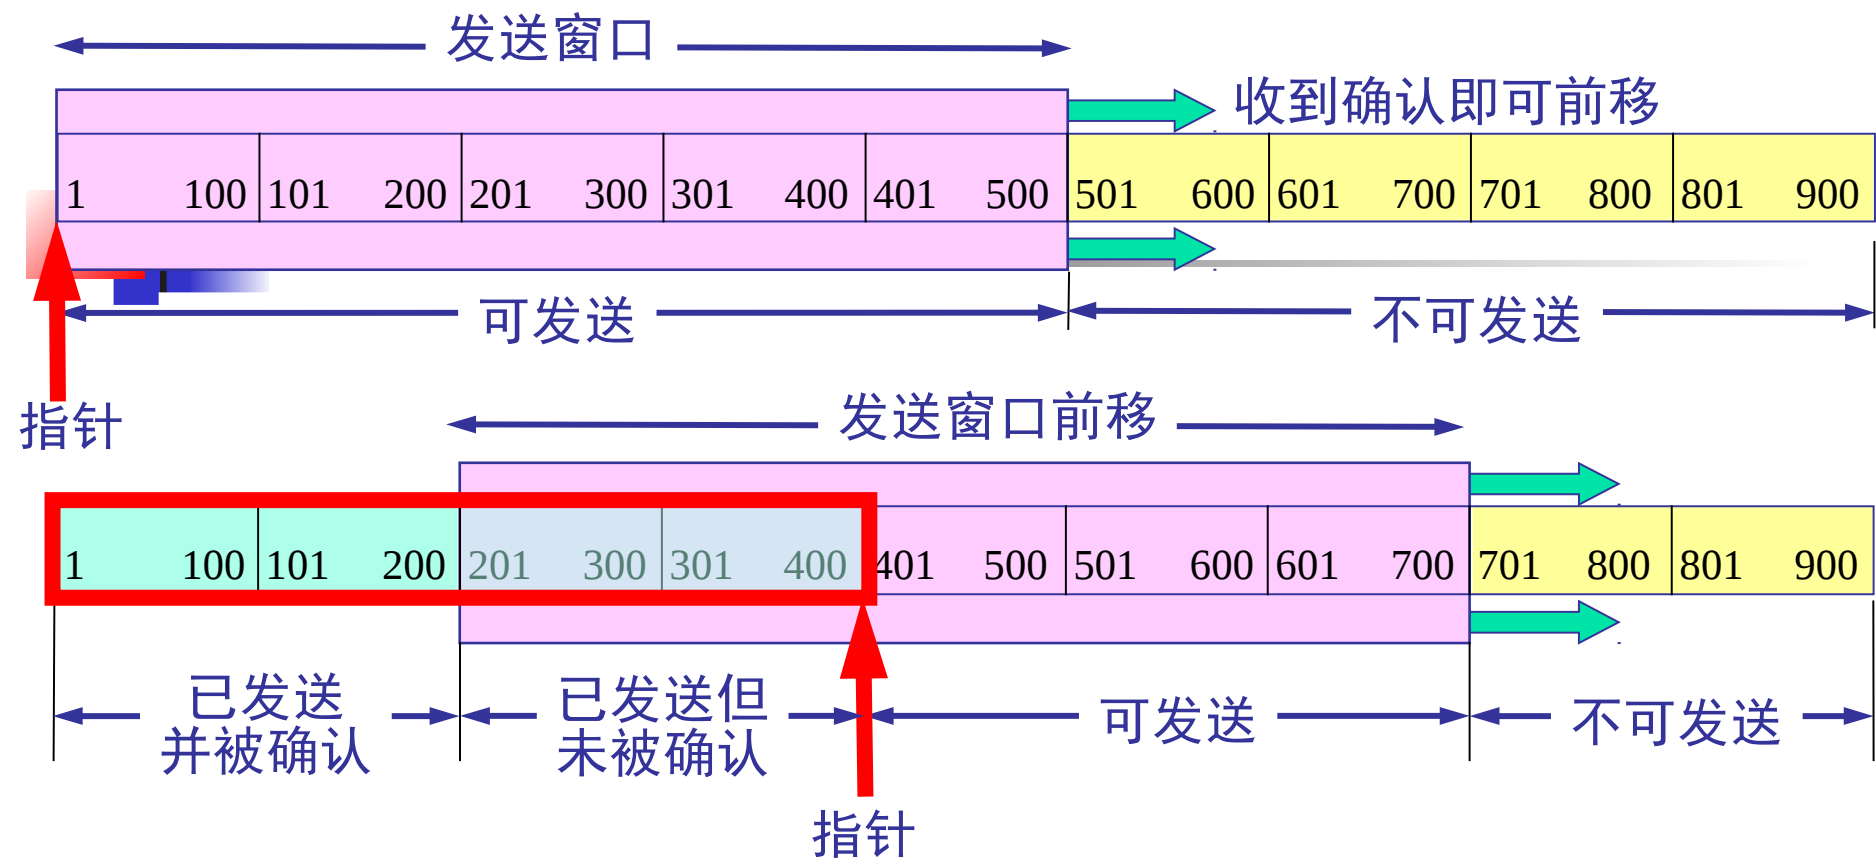


接收缓存



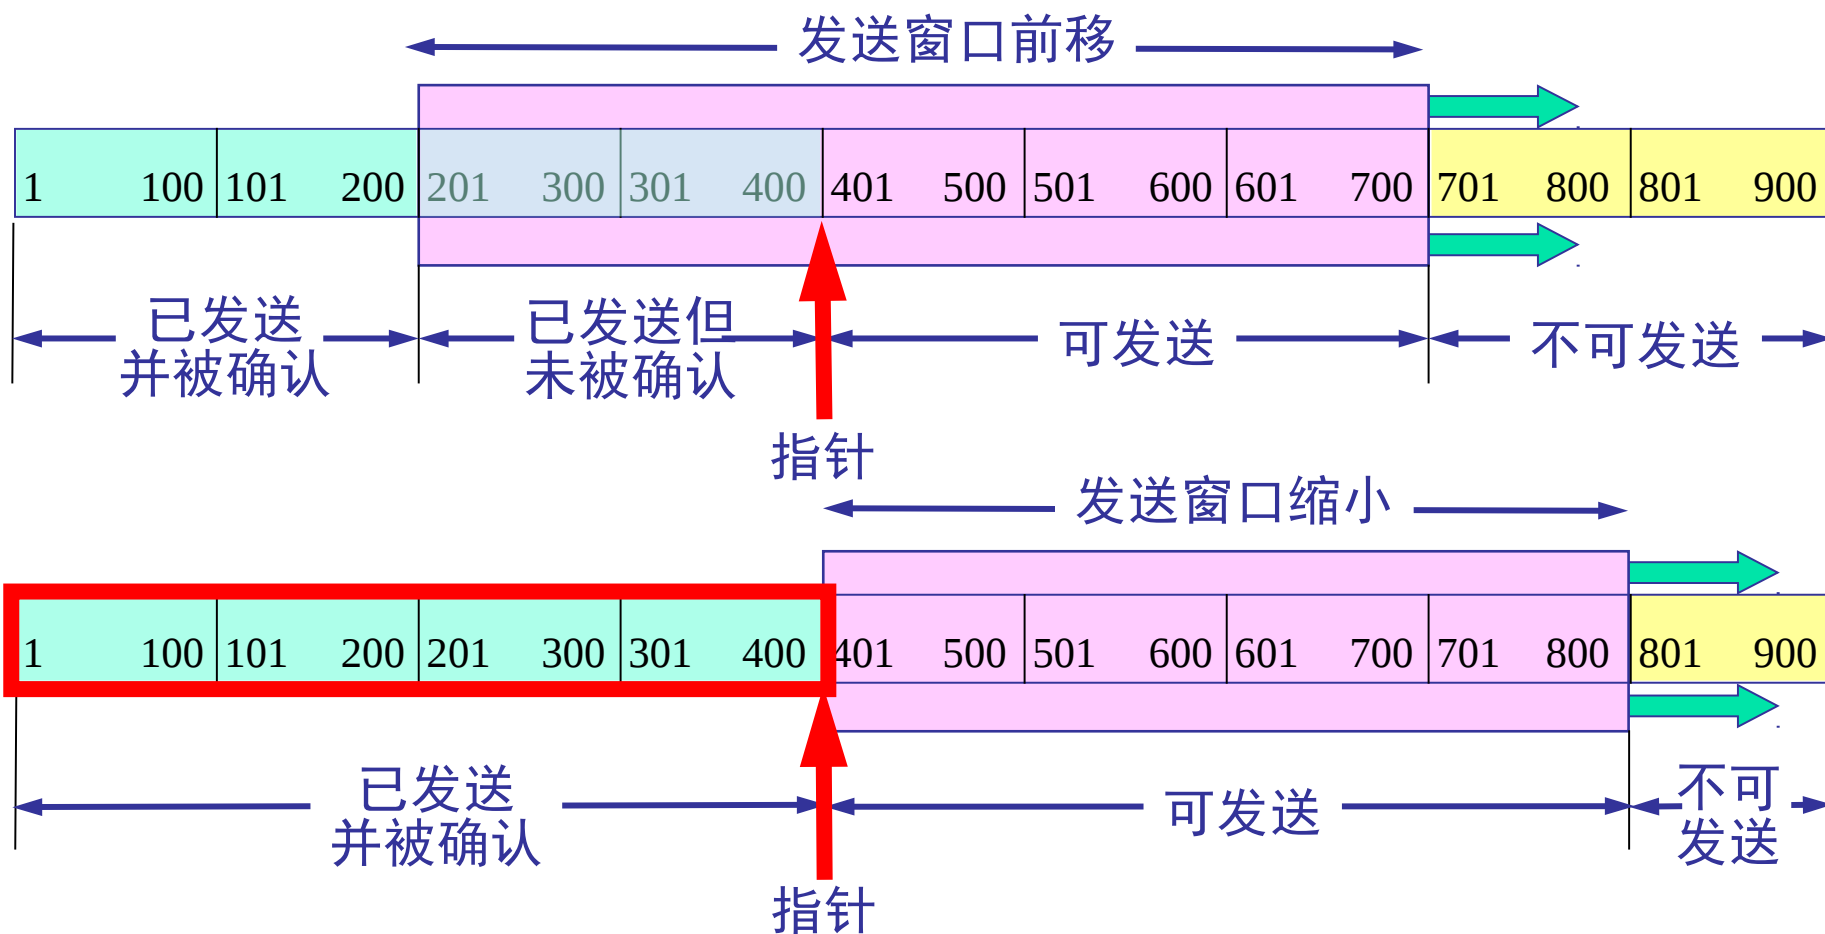


- 发送端要发送 900 字节长的数据，划分为 9 个 100 字节长的报文段，而发送窗口确定为 500 字节。
- 发送端只要收到了对方的确认，发送窗口就可前移。
- 发送 TCP 要维护一个指针。每发送一个报文段，指针就向前移动一个报文段的距离。



- 发送端已发送了 400 字节的数据，但只收到对前 200 字节数据的确认，同时窗口大小不变。
- 现在发送端还可发送 300 字节。

- 发送端收到了对方对前 400 字节数据的确认，但对方通知发送端必须把窗口减小到 400 字节。
- 现在发送端最多还可发送 400 字节的数据。





发送缓存与接收缓存的作用

- 发送缓存用来暂时存放：
 - 发送应用程序传送给发送方 TCP 准备发送的数据；
 - TCP 已发送出但尚未收到确认的数据。
- 接收缓存用来暂时存放：
 - 按序到达的、但尚未被接收应用程序读取的数据；
 - 不按序到达的数据。



需要强调三点

- A 的发送窗口并不总是和 B 的接收窗口一样大（因为有一定的时间滞后）。
- TCP 标准没有规定对不按序到达的数据应如何处理。通常是先临时存放在接收窗口中，等到字节流中所缺少的字节收到后，再按序交付上层的应用进程。
- TCP 要求接收方必须有**累积确认**的功能，这样可以减小传输开销。




5.6.2 超时重传时间的选择

- **重传机制**是 TCP 中最重要和最复杂的问题之一。
- TCP 每发送一个报文段，就对这个报文段设置一次计时器。只要计时器设置的重传时间到但还没有收到确认，就要重传这一报文段。

往返时延的方差很大

- 由于 TCP 的下层是一个互联网环境，IP 数据报所选择的路由变化很大。因而运输层的往返时间的方差也很大。





加权平均往返时间

- TCP 保留了 RTT 的一个加权平均往返时间 RTT_s （这又称为平滑的往返时间）。
- 第一次测量到 RTT 样本时， RTT_s 值就取为所测量到的 RTT 样本值。以后每测量到一个新的 RTT 样本，就按下式重新计算一次 RTT_s ：

$$\begin{aligned} \text{新的 } RTT_s = & (1 - \alpha) \times (\text{旧的 } RTT_s) \\ & + \alpha \times (\text{新的 RTT 样本}) \end{aligned} \quad (5-4)$$

- 式中， $0 \leq \alpha < 1$ 。若 α 很接近于零，表示 RTT 值更新较慢。若选择 α 接近于 1，则表示 RTT 值更新较快。
- RFC 2988 推荐的 α 值为 $1/8$ ，即 0.125。



超时重传时间 RTO

(RetransmissionTime-Out)

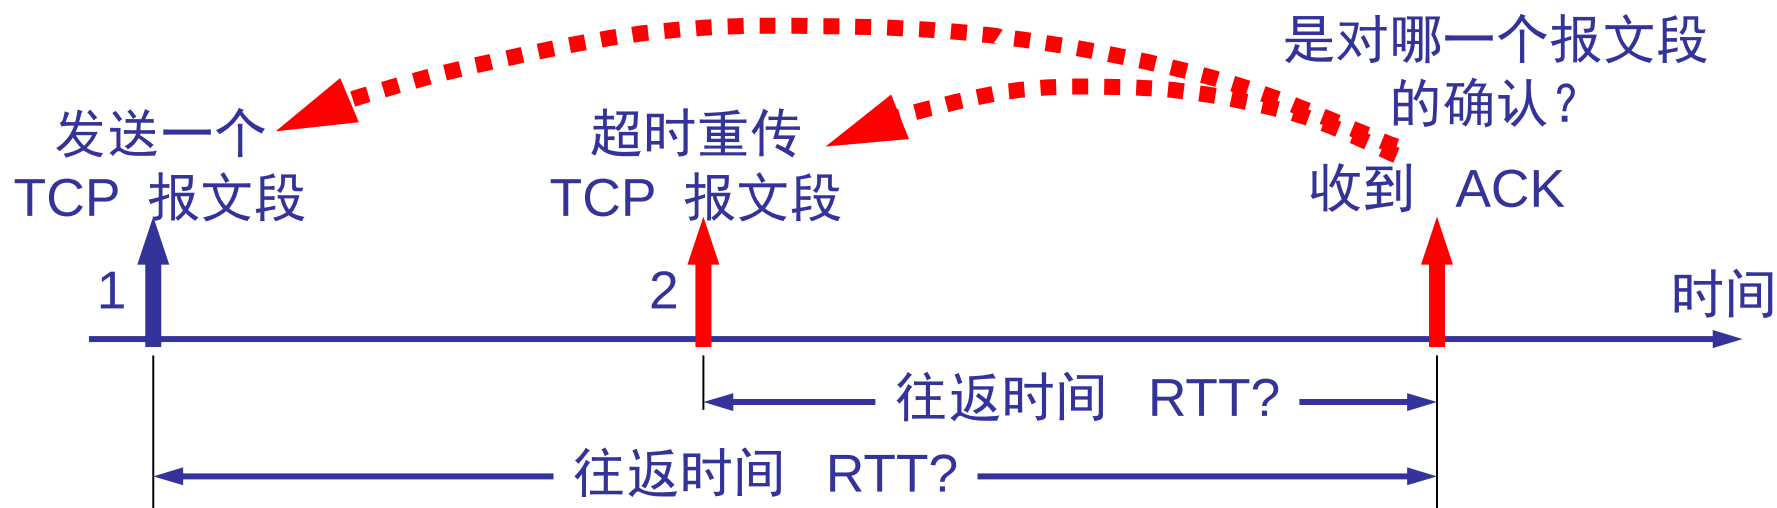
- RTO 应略大于上面得出的加权平均往返时间 RTT_S 。
- RFC 2988 建议使用下式计算 RTO :
- $$RTO = RTT_S + 4 \times RTT_D \quad (5-5)$$
- RTT_D 是 **RTT 的偏差的加权平均值**。
- RFC 2988 建议这样计算 RTT_D 。第一次测量时, RTT_D 值取**为测量到的 RTT 样本值的一半**。在以后的测量中, 则使用下式计算加权平均的 RTT_D :

$$\begin{aligned} \text{新的 } RTT_D = & (1 - \beta) \times (\text{旧的 } RTT_D) \\ & + \beta \times |RTT_S - \text{新的 } RTT \text{ 样本}| \end{aligned} \quad (5-6)$$

- β 是个小于 1 的系数, 其推荐值是 $1/4$, 即 0.25。

往返时间的测量相当复杂

- TCP 报文段 1 没有收到确认。重传（即报文段 2）后，收到了确认报文段 ACK。
- 如何判定此确认报文段是对原来的报文段 1 的确认，还是对重传的报文段 2 的确认？





Karn 算法

- 在计算平均往返时间 RTT 时，只要报文段重传了，就不采用其往返时间样本。
 -
- 这样得出的加权平均往返时间 RTT_s 和超时重传时间 RTO 就较准确。
- 但问题是：超时重传的时间就无法更新。
 -



修正的 Karn 算法

- 报文段每重传一次，就把 RTO 增大一些：

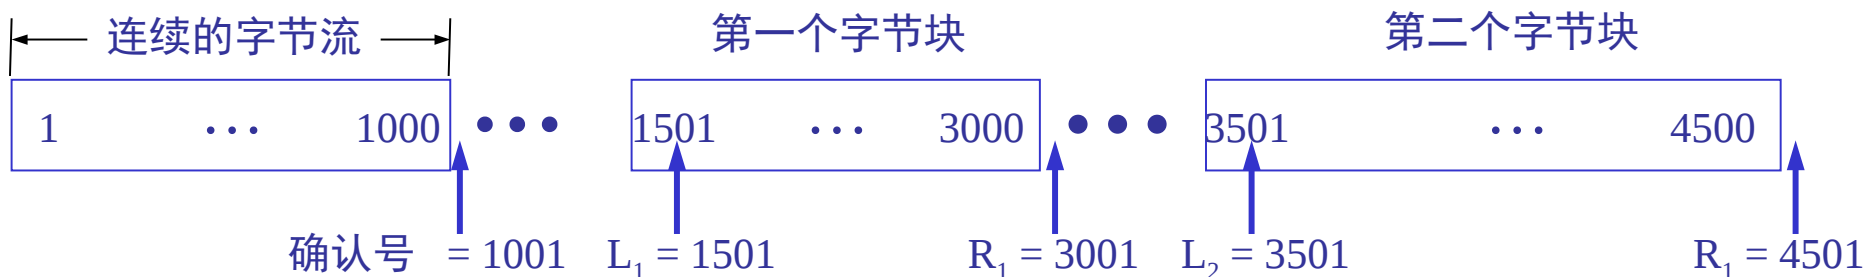
$$\text{新的 RTO} = \gamma \times (\text{旧的 RTO})$$

- 系数 γ 的典型值是 2。
- 当不再发生报文段的重传时，才根据报文段的往返时延更新平均往返时延 RTT 和超时重传时间 RTO 的数值。
- 实践证明，这种策略较为合理。

5.6.3 选择确认 SACK (Selective ACK)

- 接收方收到未按序号到达的信息，若收到了和前面的字节流不连续的两个字节块，那么发送方能否只传输缺少的数据。
- 如果这些字节的序号都在接收窗口之内，那么接收方就先收下这些数据，但要把这些信息准确地告诉发送方，使发送方不要再重复发送这些已收到的数据。

接收到的字节流序号不连续



- 和前后字节不连续的每一个字节块都有两个边界：左边界和右边界。图中用四个指针标记这些边界。
- 第一个字节块的左边界 $L_1 = 1501$ ，但右边界 $R_1 = 3001$ 。
- 左边界指出字节块的第一个字节的序号，但右边界减 1 才是字节块中的最后一个序号。
- 第二个字节块的左边界 $L_2 = 3501$ ，而右边界 $R_2 = 4501$ 。



RFC 2018 的规定

- 如果要使用选择确认，那么在建立 TCP 连接时，就要在 TCP 首部的选项中加入“允许 SACK”的选项，而双方必须都事先商定好。
- 如果使用选择确认，那么原来首部中的“确认号字段”的用法仍然不变。只是以后在 TCP 报文段的首部中都增加了 SACK 选项，以便报告收到的不连续的字节块的边界。
- 由于首部选项的长度最多只有 40 字节，而指明一个边界就要用掉 4 字节（序号 32 位），因此在选项中最多只能指明 4 个字节块的边界信息。



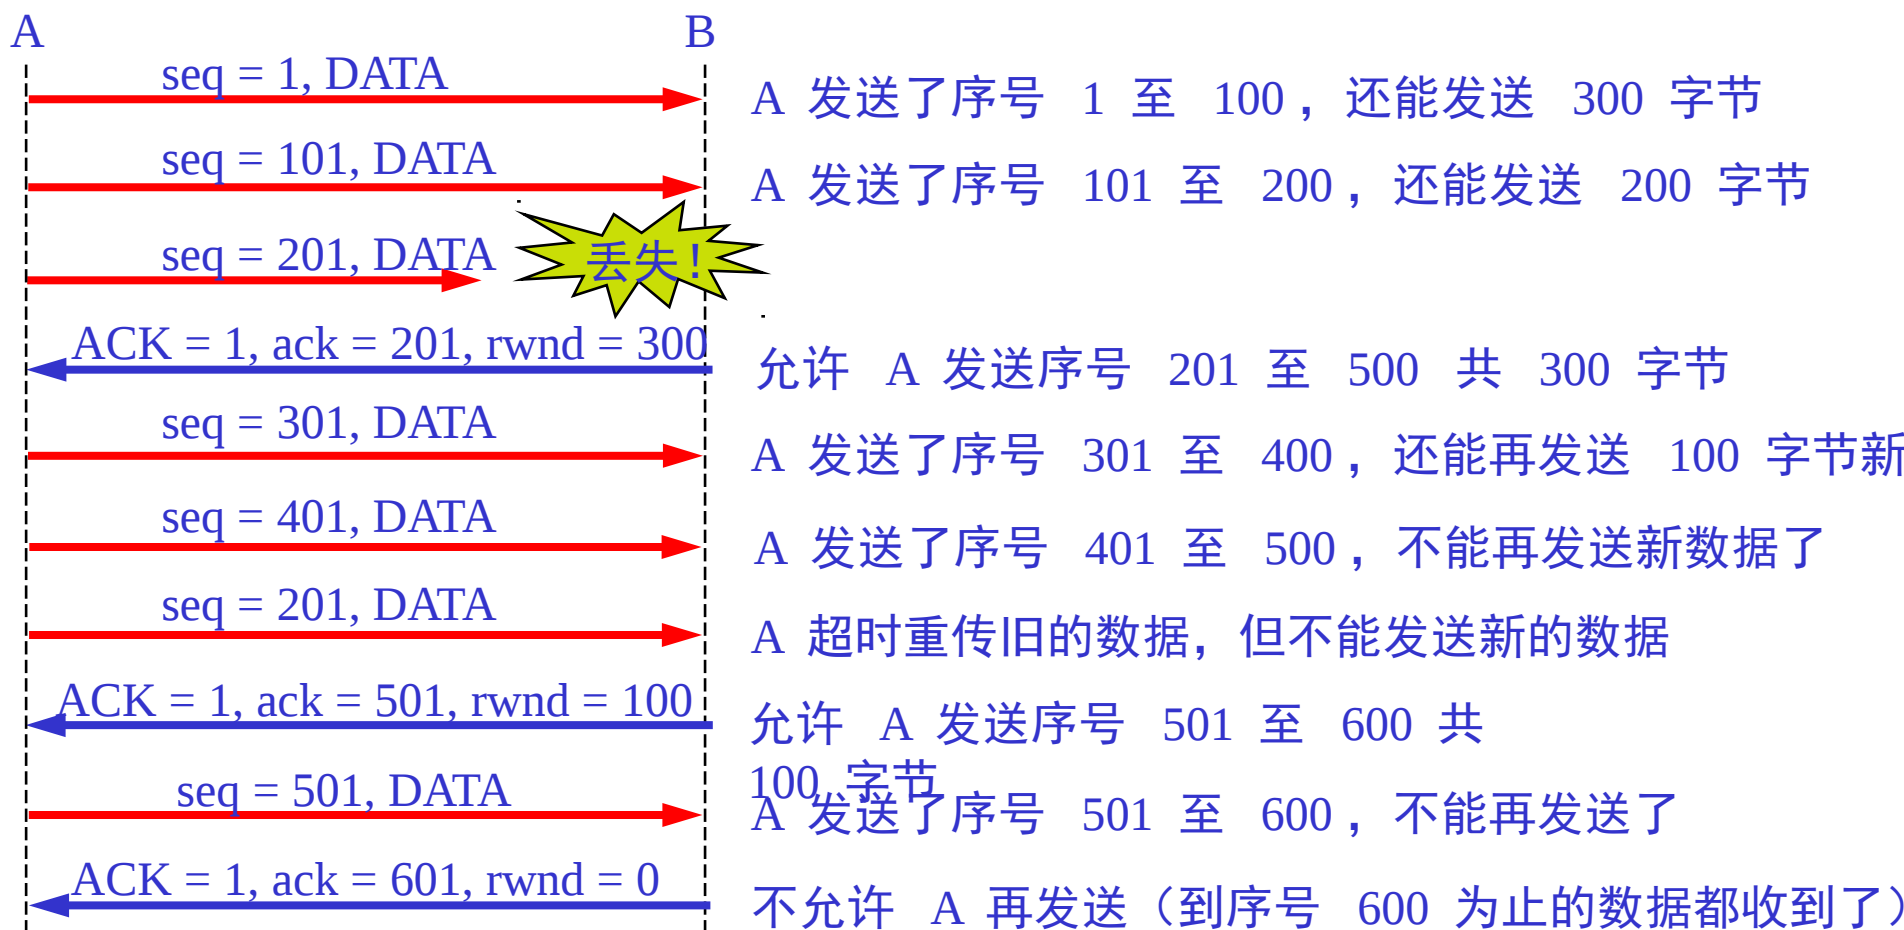
5.7 TCP 的流量控制

5.7.1 利用滑动窗口实现流量控制

- 但如果发送方把数据发送得过快，接收方就可能来不及接收，这就会造成数据的丢失。
- **流量控制** (flow control) 就是让发送方的发送速率不要太快，既要让接收方来得及接收，也不要使网络发生拥塞。
- 利用**滑动窗口机制**可以很方便地在 TCP 连接上实现流量控制。

利用可变窗口大小进行流量控制

A 向 B 发送数据。在连接建立时，B 告诉 A：“我的接收窗
rwnd = 400（字节），报文长度 100 字节，序号初始值 1”。





持续计时器 (persistence timer)

- TCP 为每一个连接设有一个持续计时器。
- 只要 TCP 连接的一方收到对方的零窗口通知，就启动持续计时器。
- 若持续计时器设置的时间到期，就发送一个零窗口探测报文段（仅携带 1 字节的数据），而对方就在确认这个探测报文段时给出了现在的窗口值。
- 若窗口仍然是零，则收到这个报文段的一方就重新设置持续计时器。
- 若窗口不是零，则死锁的僵局就可以打破了。



5.7.2 必须考虑传输效率

- 可以用不同的机制来控制 TCP 报文段的发送时机：
- 第一种机制是 TCP 维持一个变量，它等于最大报文段长度 MSS。只要缓存中存放的数据达到 MSS 字节时，就组装成一个 TCP 报文段发送出去。
- 第二种机制是由发送方的应用进程指明要求发送报文段，即 TCP 支持的推送 (push) 操作。
- 第三种机制是发送方的一个计时器期限到了，这时就把当前已有的缓存数据装入报文段（但长度不能超过 MSS）发送出去。

5.8 TCP 的拥塞控制

5.8.1 拥塞控制的一般原理

- 在某段时间，若对网络中某资源的需求超过了该资源所能提供的可用部分，网络的性能就要变坏——产生**拥塞** (congestion)。

- 出现资源拥塞的条件：

对资源需求的总和 > 可用资源

(5-7)


- 若网络中有许多资源同时产生拥塞，网络的性能就要明显变坏，整个网络的吞吐量将随输入负荷的增大而下降。



拥塞控制与流量控制的关系

- **拥塞控制**所要做的都有一个前提，就是网络能够承受现有的网络负荷。
- 拥塞控制是一个全局性的过程，涉及到所有的主机、所有的路由器，以及与降低网络传输性能有关的所有因素。
- **流量控制**往往指在给定的发送端和接收端之间的点对点通信量的控制。
- 流量控制所要做的就是抑制发送端发送数据的速率，以便使接收端来得及接收。

拥塞控制所起的作用





拥塞控制的一般原理

- 拥塞控制是很难设计的，因为它是一个动态的（而不是静态的）问题。
- 当前网络正朝着高速化的方向发展，这很容易出现缓存不够大而造成分组的丢失。但分组的丢失是网络发生拥塞的征兆而不是原因。
- 在许多情况下，甚至正是拥塞控制本身成为引起网络性能恶化甚至发生死锁的原因。这点应特别引起重视。



开环控制和闭环控制

- **开环控制**方法就是在设计网络时事先将有关发生拥塞的因素考虑周到，力求网络在工作时不产生拥塞。
- **闭环控制**是基于反馈环路的概念。属于闭环控制的有以下几种措施：
 - 监测网络系统以便检测到拥塞在何时、何处发生。
 - 将拥塞发生的信息传送到可采取行动的地方。
 - 调整网络系统的运行以解决出现的问题。

5.8.2 几种拥塞控制方法

1. 慢开始和拥塞避免


- 发送方维持一个叫做**拥塞窗口 cwnd** (congestion window) 的状态变量。拥塞窗口的大小取决于网络的拥塞程度，并且动态地在变化。
- 发送方让自己的发送窗口等于拥塞窗口。如再考虑到接收方的接收能力，则发送窗口还可能小于拥塞窗口。
- **发送方控制拥塞窗口的原则**是：只要网络没有出现拥塞，拥塞窗口就再增大一些，以便把更多的分组发送出去。但只要网络出现拥塞，拥塞窗口就减小一些，以减少注入到网络中的分组数。



慢开始算法的原理

- 在主机刚刚开始发送报文段时可先设置拥塞窗口 $cwnd = 1$ ，即设置为一个最大报文段 MSS 的数值。
- 在每收到一个对新的报文段的确认后，将拥塞窗口加 1，即增加一个 MSS 的数值。
- 用这样的方法逐步增大发送端的拥塞窗口 $cwnd$ ，可以使分组注入到网络的速率更加合理。

发送方每收到一个对新报文段的确认
(重传的不算在内) 就使 cwnd 加 1。





传输轮次 (transmission round)

- 使用慢开始算法后，每经过一个**传输轮次**，拥塞窗口 $cwnd$ 就加倍。
- 一个传输轮次所经历的时间其实就是往返时间 RTT。
- **“传输轮次”** 更加强调：把拥塞窗口 $cwnd$ 所允许发送的报文段都连续发送出去，并收到了对已发送的最后一个字节的确认。
- 例如，拥塞窗口 $cwnd = 4$ ，这时的往返时间 RTT 就是发送方连续发送 4 个报文段，并收到这 4 个报文段的确认，总共经历的时间。



设置慢开始门限状态变量 ssthresh


- 慢开始门限 **ssthresh** 的用法如下：
- 当 $cwnd < ssthresh$ 时，使用慢开始算法。
- 当 $cwnd > ssthresh$ 时，停止使用慢开始算法而改用拥塞避免算法。
- 当 $cwnd = ssthresh$ 时，既可使用慢开始算法，也可使用拥塞避免算法。
- 拥塞避免算法的思路是让拥塞窗口 $cwnd$ 缓慢地增大，即每经过一个往返时间 RTT 就把发送方的拥塞窗口 $cwnd$ 加 1，而不是加倍，使拥塞窗口 $cwnd$ 按线性规律缓慢增长。



当网络出现拥塞时

- 无论在慢开始阶段还是在拥塞避免阶段，只要发送方判断网络出现拥塞（其根据就是没有按时收到确认），就要把慢开始门限 `ssthresh` 设置为出现拥塞时的发送方窗口值的一半（但不能小于 2）。
- 然后把拥塞窗口 `cwnd` 重新设置为 1，执行慢开始算法。
- 这样做的目的就是要迅速减少主机发送到网络中的分组数，使得发生拥塞的路由器有足够时间把队列中积压的分组处理完毕。


慢开始和拥塞避免算法的实现举例



当 TCP 连接进行初始化时，将拥塞窗口置为 1。图中的窗口单位不使用字节而使用**报文段**。


慢开始门限的初始值设置为 16 个报文段，即 $\text{ssthresh} = 16$ 。

慢开始和拥塞避免算法的实现举例




发送端的发送窗口不能超过拥塞窗口 cwnd 和接收端窗口 rwnd 中的最小值。我们假定接收端窗口足够大，因此现在发送窗口的数值等于拥塞窗口的数值。

慢开始和拥塞避免算法的实现举例




在执行慢开始算法时，拥塞窗口 cwnd 的初始值为 1，发送第一个报文段 M_0 。

慢开始和拥塞避免算法的实现举例




发送端每收到一个确认，就把 cwnd 加 1。于是发送端可以接着发送 M_1 和 M_2 两个报文段。

慢开始和拥塞避免算法的实现举例




接收端共发回两个确认。发送端每收到一个对新报文段的确认，就把发送端的 cwnd 加 1。现在 cwnd 从 2 增大到 4，并可接着发送后面的 4 个报文段。

慢开始和拥塞避免算法的实现举例




发送端每收到一个对新报文段的确认，就把发送端的拥塞窗口加 1，因此拥塞窗口 cwnd 随着传输轮次按指数规律增长。

慢开始和拥塞避免算法的实现举例




当拥塞窗口 $cwnd$ 增长到慢开始门限值 $sssthresh$ 时（即当 $cwnd = 16$ 时），就改为执行拥塞避免算法，拥塞窗口按线性规律增长。

慢开始和拥塞避免算法的实现举例




假定拥塞窗口的数值增长到 24 时，网络出现超时，表明网络拥塞了。

慢开始和拥塞避免算法的实现举例



更新后的 ssthresh 值变为 12（即发送窗口数值 24 的一半），拥塞窗口再重新设置为 1，并执行慢开始算法。

慢开始和拥塞避免算法的实现举例



当 $cwnd = 12$ 时改为执行拥塞避免算法，拥塞窗口按按线性规律增长，每经过一个往返时延就增加一个 MSS 的大小。

乘法减小

(multiplicative decrease)

- “乘法减小”是指不论在慢开始阶段还是拥塞避免阶段，只要出现一次超时（即出现一次网络拥塞），就把慢开始门限值 `ssthresh` 设置为当前的拥塞窗口值乘以 0.5。
- 当网络频繁出现拥塞时，`ssthresh` 值就下降得很快，以大大减少注入到网络中的分组数。



加法增大

(additive increase)

- “加法增大”是指执行拥塞避免算法后，在收到对所有报文段的确认后（即经过一个往返时间），就把拥塞窗口 `cwnd` 增加一个 `MSS` 大小，使拥塞窗口缓慢增大，以防止网络过早出现拥塞。



必须强调指出


- “拥塞避免”并非指完全能够避免了拥塞。利用以上的措施要完全避免网络拥塞还是不可能的。
- “拥塞避免”是说在拥塞避免阶段把拥塞窗口控制为按线性规律增长，使网络比较不容易出现拥塞。



2. 快重传和快恢复

- **快重传算法**首先要求接收方每收到一个失序的报文段后就立即发出**重复确认**。这样做可以让发送方及早知道有报文段没有到达接收方。
- 发送方只要一连收到三个重复确认就应当立即重传对方尚未收到的报文段。
- 不难看出，快重传并非取消重传计时器，而是在某些情况下可更早地重传丢失的报文段。

快重传举例






快恢复算法

- (1) 当发送端收到连续三个重复的确认时，就执行“乘法减小”算法，把慢开始门限 `ssthresh` 减半。但接下去不执行慢开始算法。
- (2) 由于发送方现在认为网络很可能没有发生拥塞，因此现在不执行慢开始算法，即拥塞窗口 `cwnd` 现在不设置为 1，而是设置为慢开始门限 `ssthresh` (`cwnd` 减半后的数值)，然后开始执行拥塞避免算法（“加法增大”），使拥塞窗口缓慢地线性增大。

从连续收到三个重复的确认 转入拥塞避免





发送窗口的上限值

- 发送方的发送窗口的上限值应当取为接收方窗口 $rwnd$ 和拥塞窗口 $cwnd$ 这两个变量中较小的一个，即应按以下公式确定：

$$\text{发送窗口的上限值} = \text{Min} [rwnd, cwnd] \quad (5-8)$$

- 当 $rwnd < cwnd$ 时，是接收方的接收能力限制发送窗口的最大值。
- 当 $cwnd < rwnd$ 时，则是网络的拥塞限制发送窗口的最大值。




7.4.6 随机早期丢弃 RED (Random Early Discard)

- 网络层路由器的分组丢弃对 TCP 拥塞控制产生重大的影响。
- 路由器的队列通常按照“先进先出”的规则来处理到来的分组。当队列已满后续到达的分组按“尾部丢弃策略”丢弃。
- 但路由器的尾部丢弃，可能导致多条通过此路由器的 TCP 连接在同一时间突然都进入慢开始状态，这种现象称为全局同步。全局同步使网络的通信量突然大副下降。

随机早期丢弃 RED

- 使路由器的队列维持两个参数，即队列长度最小门限 TH_{min} 和最大门限 TH_{max} 。
- RED 对每一个到达的数据报都先计算平均队列长度 L_{AV} 。
- 若平均队列长度小于最小门限 TH_{min} ，则将新到达的数据报放入队列进行排队。
- 若平均队列长度超过最大门限 TH_{max} ，则将新到达的数据报丢弃。
- 若平均队列长度在最小门限 TH_{min} 和最大门限 TH_{max} 之间，则按照某一概率 p 将新到达的数据报丢弃。


RED 将路由器的到达队列划分成为三个区域




丢弃概率 p 与 TH_{\min} 和 Th_{\max} 的关系

- 当 $L_{AV} < Th_{\min}$ 时, 丢弃概率 $p = 0$ 。
- 当 $L_{AV} > Th_{\max}$ 时, 丢弃概率 $p = 1$ 。
- 当 $TH_{\min} < L_{AV} < TH_{\max}$ 时, $0 < p < 1$ 。

例如, 按线性规律变化, 从 0 变到 p_{\max} 。



瞬时队列长度和 平均队列长度的区别





随机早期丢弃 RED 的好处

- 当平均队列长度超过门限值 Th_{min} 时，就会以概率 p 丢弃少量分组，少部分 TCP 连接会减少其窗口值，到达路由器的分组数量就会减少，平均队列长度也就减少了，因此避免了拥塞控制的发生，但网络的吞吐量依然保存在较高的数值。

5-9 TCP 的运输连接管理

1. 运输连接的三个阶段

- 运输连接就有三个阶段，即：**连接建立**、**数据传送**和**连接释放**。运输连接的管理就是使运输连接的建立和释放都能正常地进行。
- 连接建立过程中要解决以下三个问题：
 - 要使每一方能够确知对方的存在。
 - 要允许双方协商一些参数（如最大报文段长度，最大窗口大小，服务质量等）。
 - 能够对运输实体资源（如缓存大小，连接表中的项目等）进行分配。




客户服务器方式

- TCP 连接的建立都是采用客户服务器方式。
- 主动发起连接建立的应用进程叫做**客户** (client) 。
- 被动等待连接建立的应用进程叫做**服务器** (server) 。

5.9.1 TCP 的连接建立


用三次握手建立 TCP 连接



A 的 TCP 向 B 发出连接请求报文段，其首部中的同步位 **SYN = 1**，并选择序号 **seq = x**，表明传送数据时的第一个数据字节的序号是 x 。

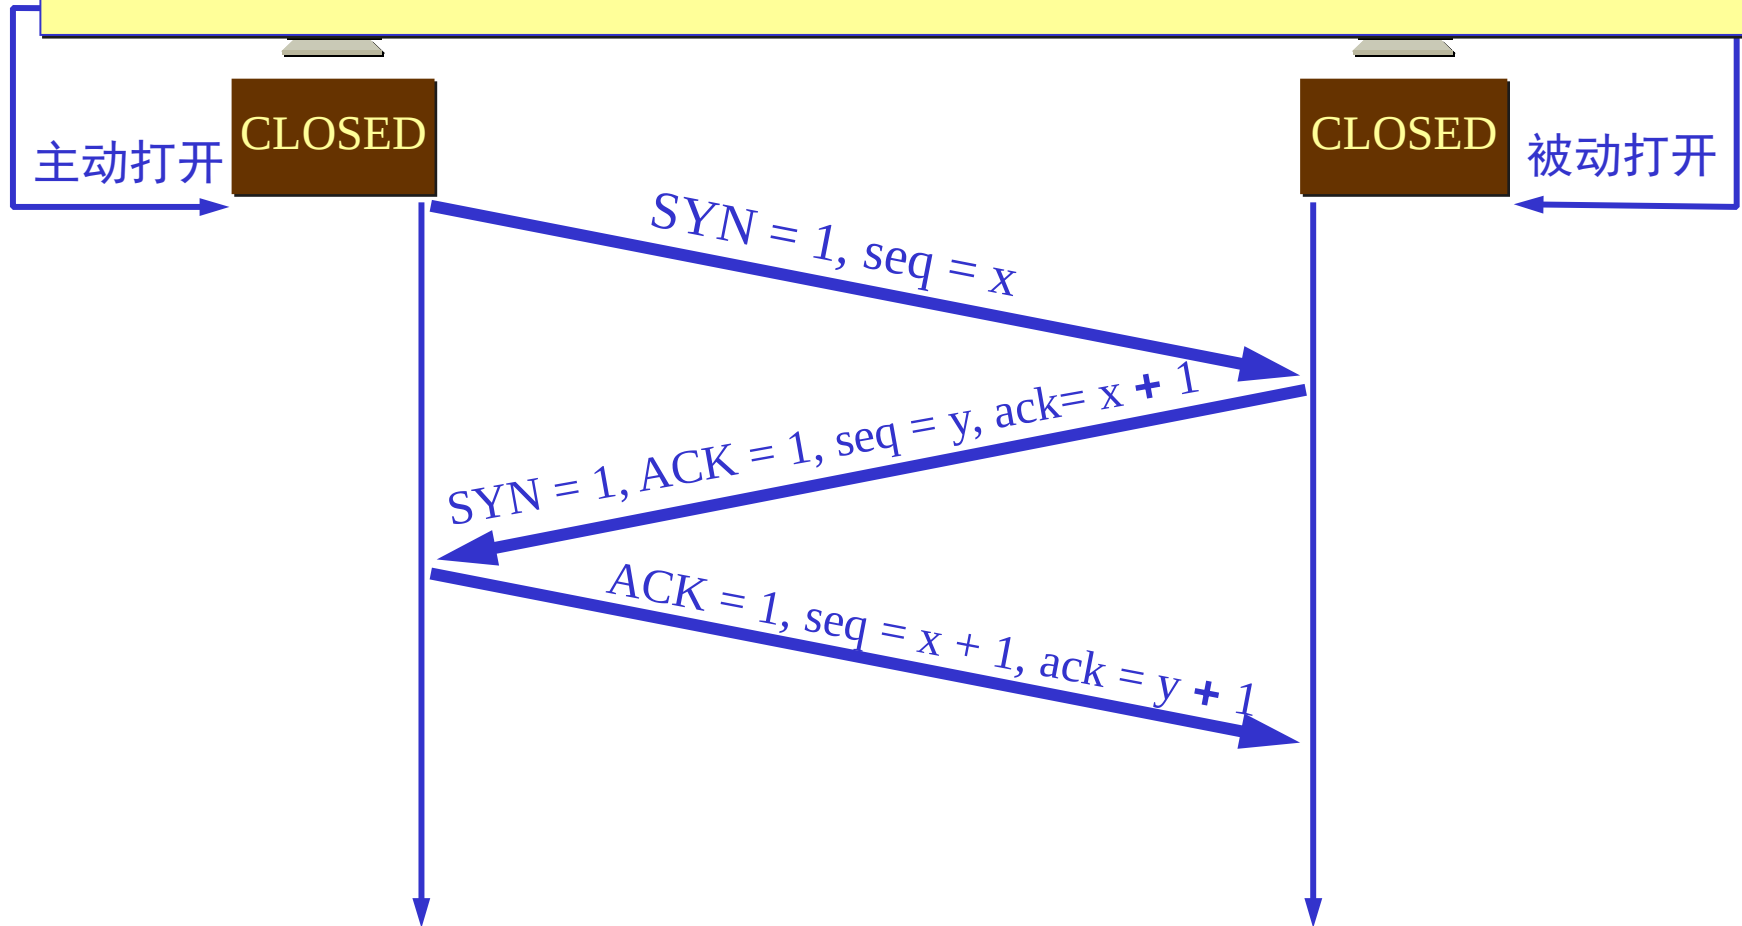
5.9.1 TCP 的连接建立

用三次握手建立 TCP 连接




- B 的 TCP 收到连接请求报文段后，如同意，则发回确认。
- B 在确认报文段中应使 $SYN = 1$ ，使 $ACK = 1$ ，其确认号 $ack = x + 1$ ，自己选择的序号 $seq = y$ 。

- A 收到此报文段后向 B 给出确认，其 **ACK = 1**，
确认号 **ack = y + 1**。
- A 的 TCP 通知上层应用进程，连接已经建立。



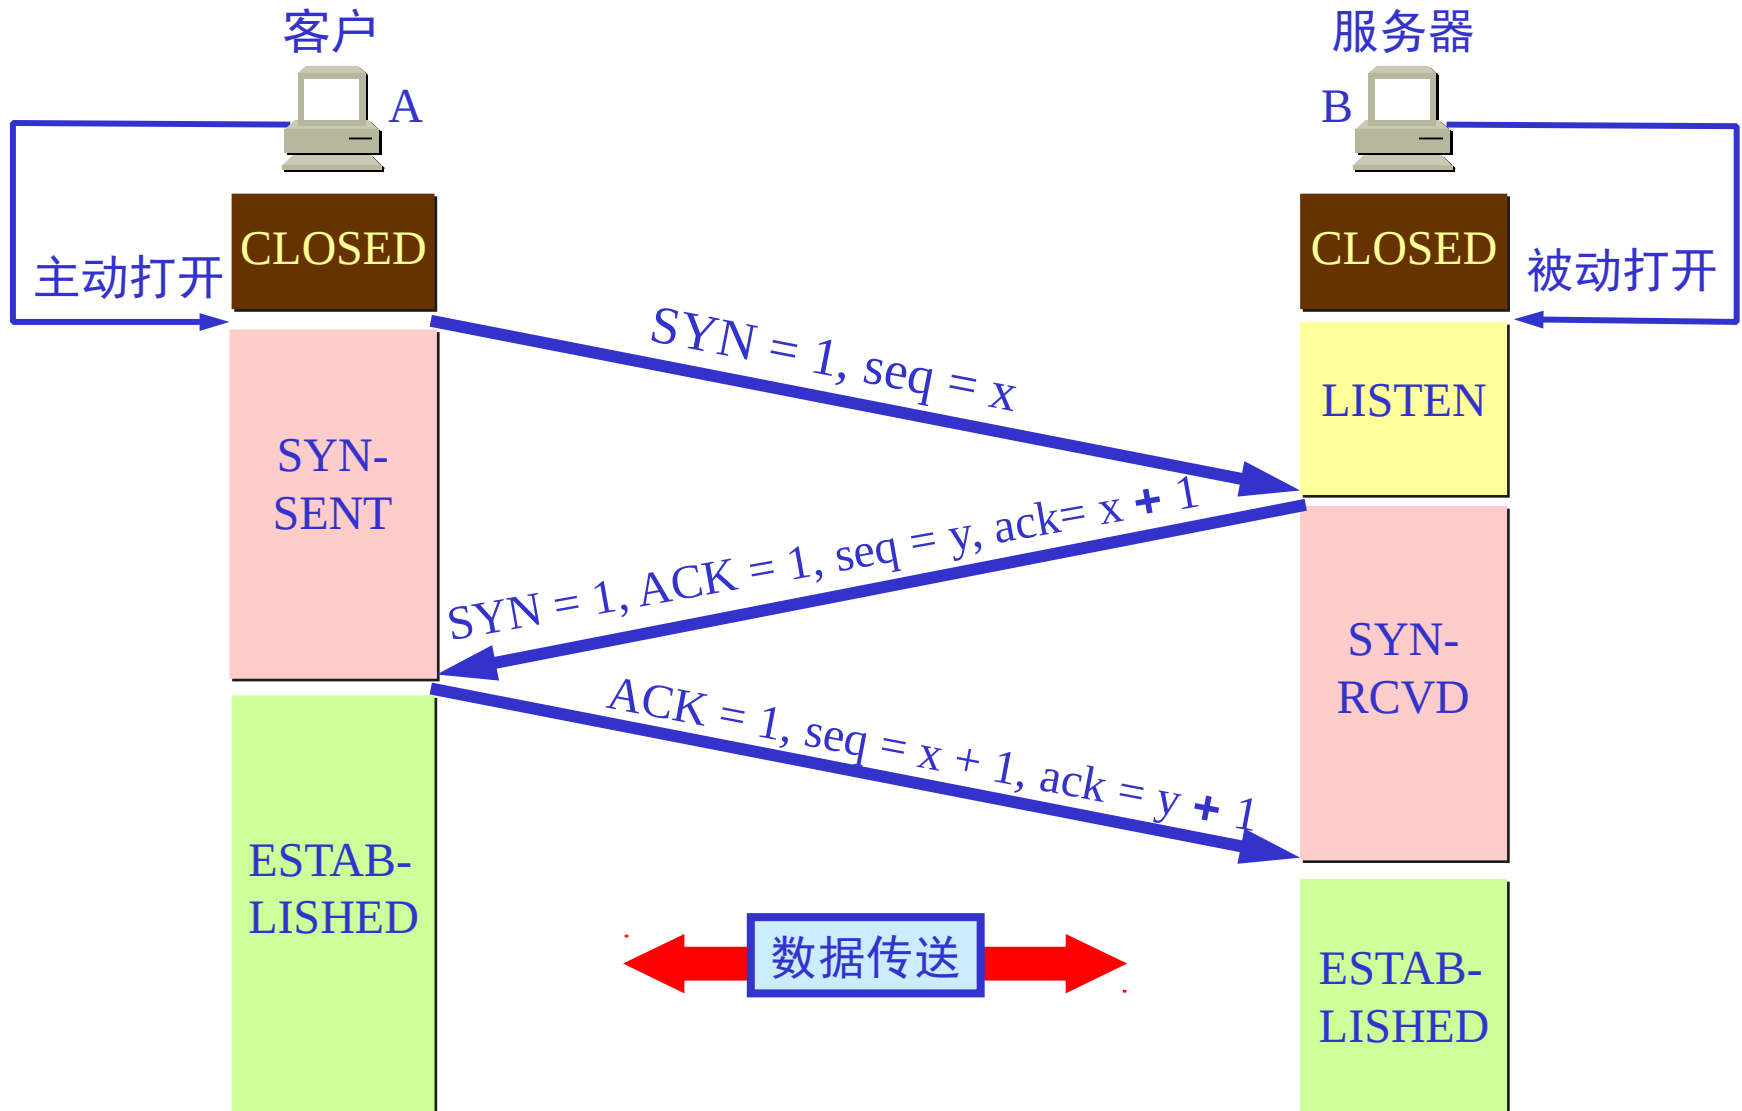
- B 的 TCP 收到主机 A 的确认后，也通知其上层

应用进程：TCP 连接已经建立。

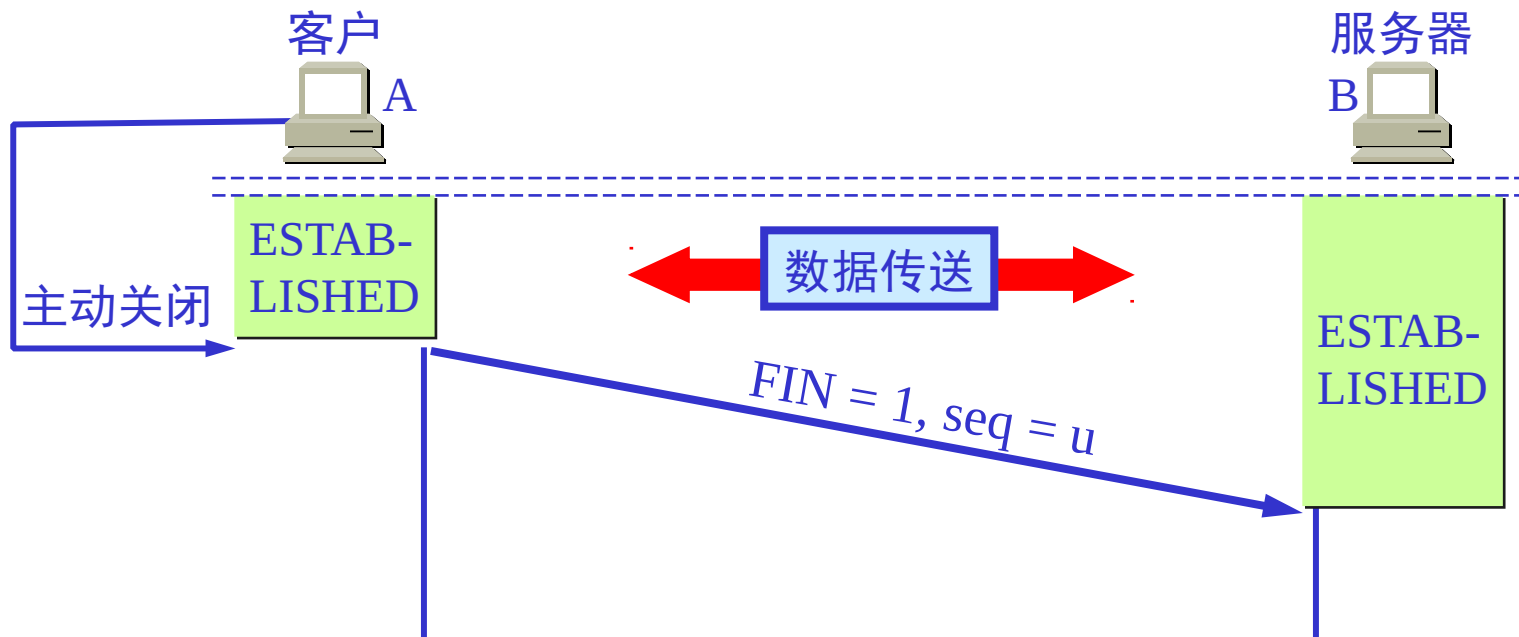


5.9.1 TCP 的连接建立

用三次握手建立 TCP 连接各状态




5.9.2 TCP 的连接释放



- 数据传输结束后，通信的双方都可释放连接。现在 A 的应用进程先向其 TCP 发出连接释放报文段，并停止再发送数据，主动关闭 TCP 连接。
- A 把连接释放报文段首部的 **FIN = 1**，其序号 **seq = u**，等待 B 的确认。

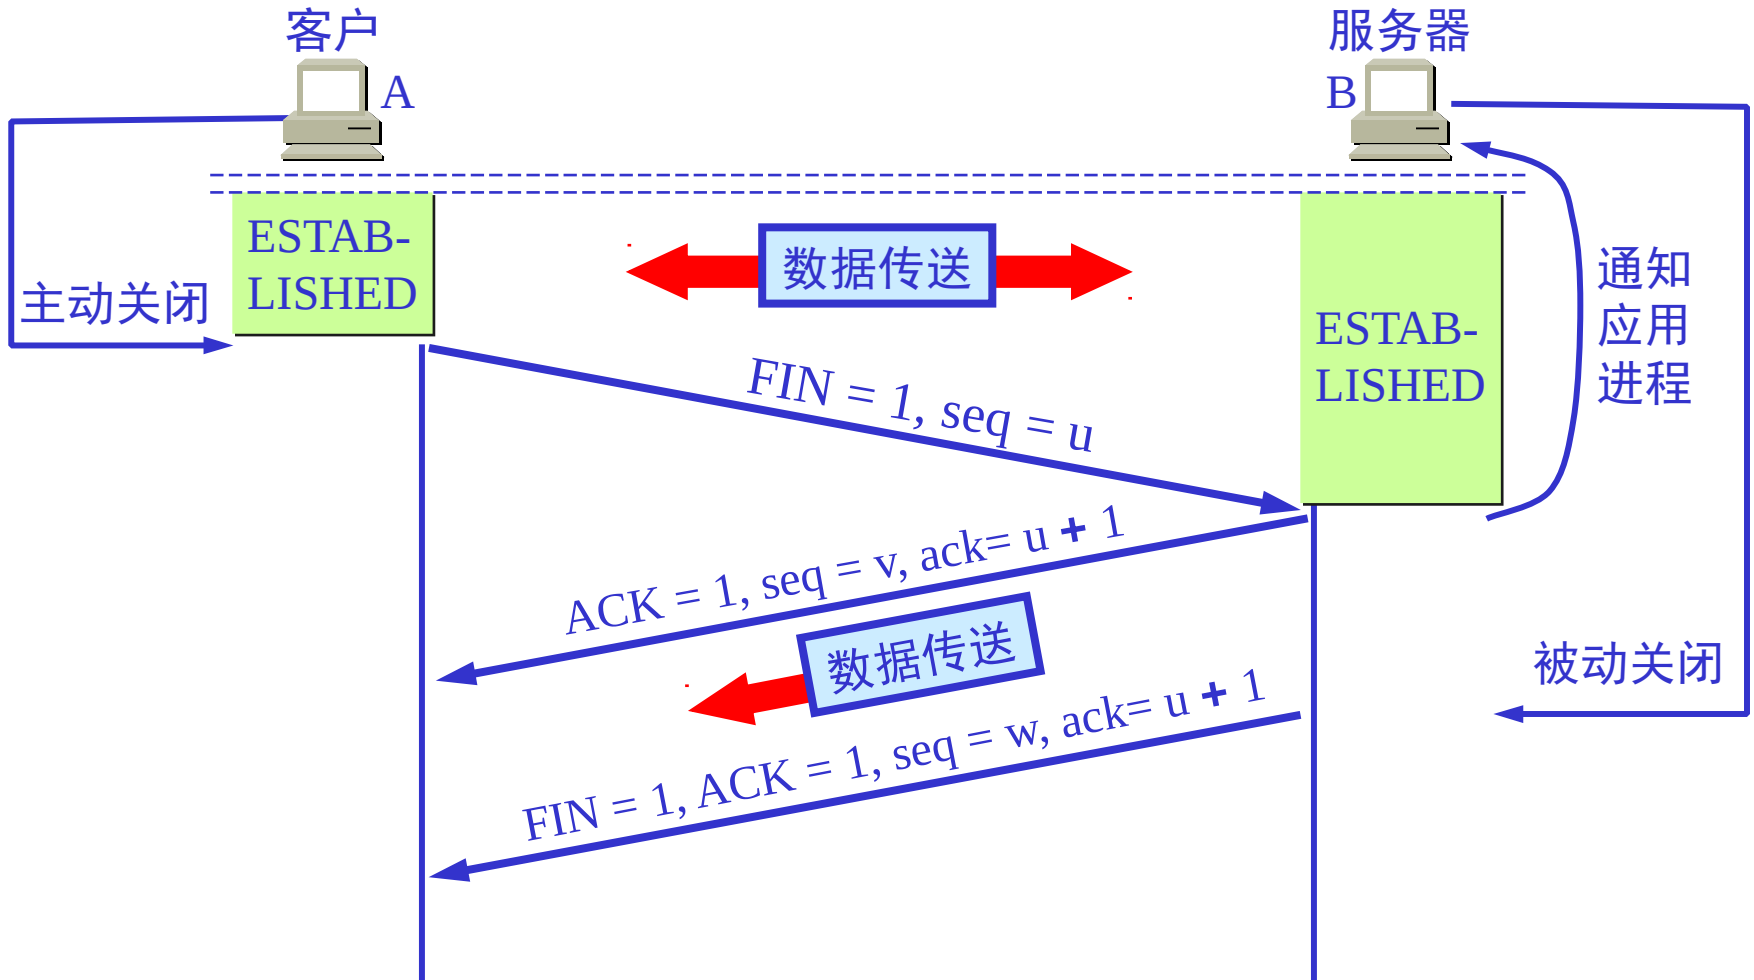
CLOSED

5.9.2 TCP 的连接释放



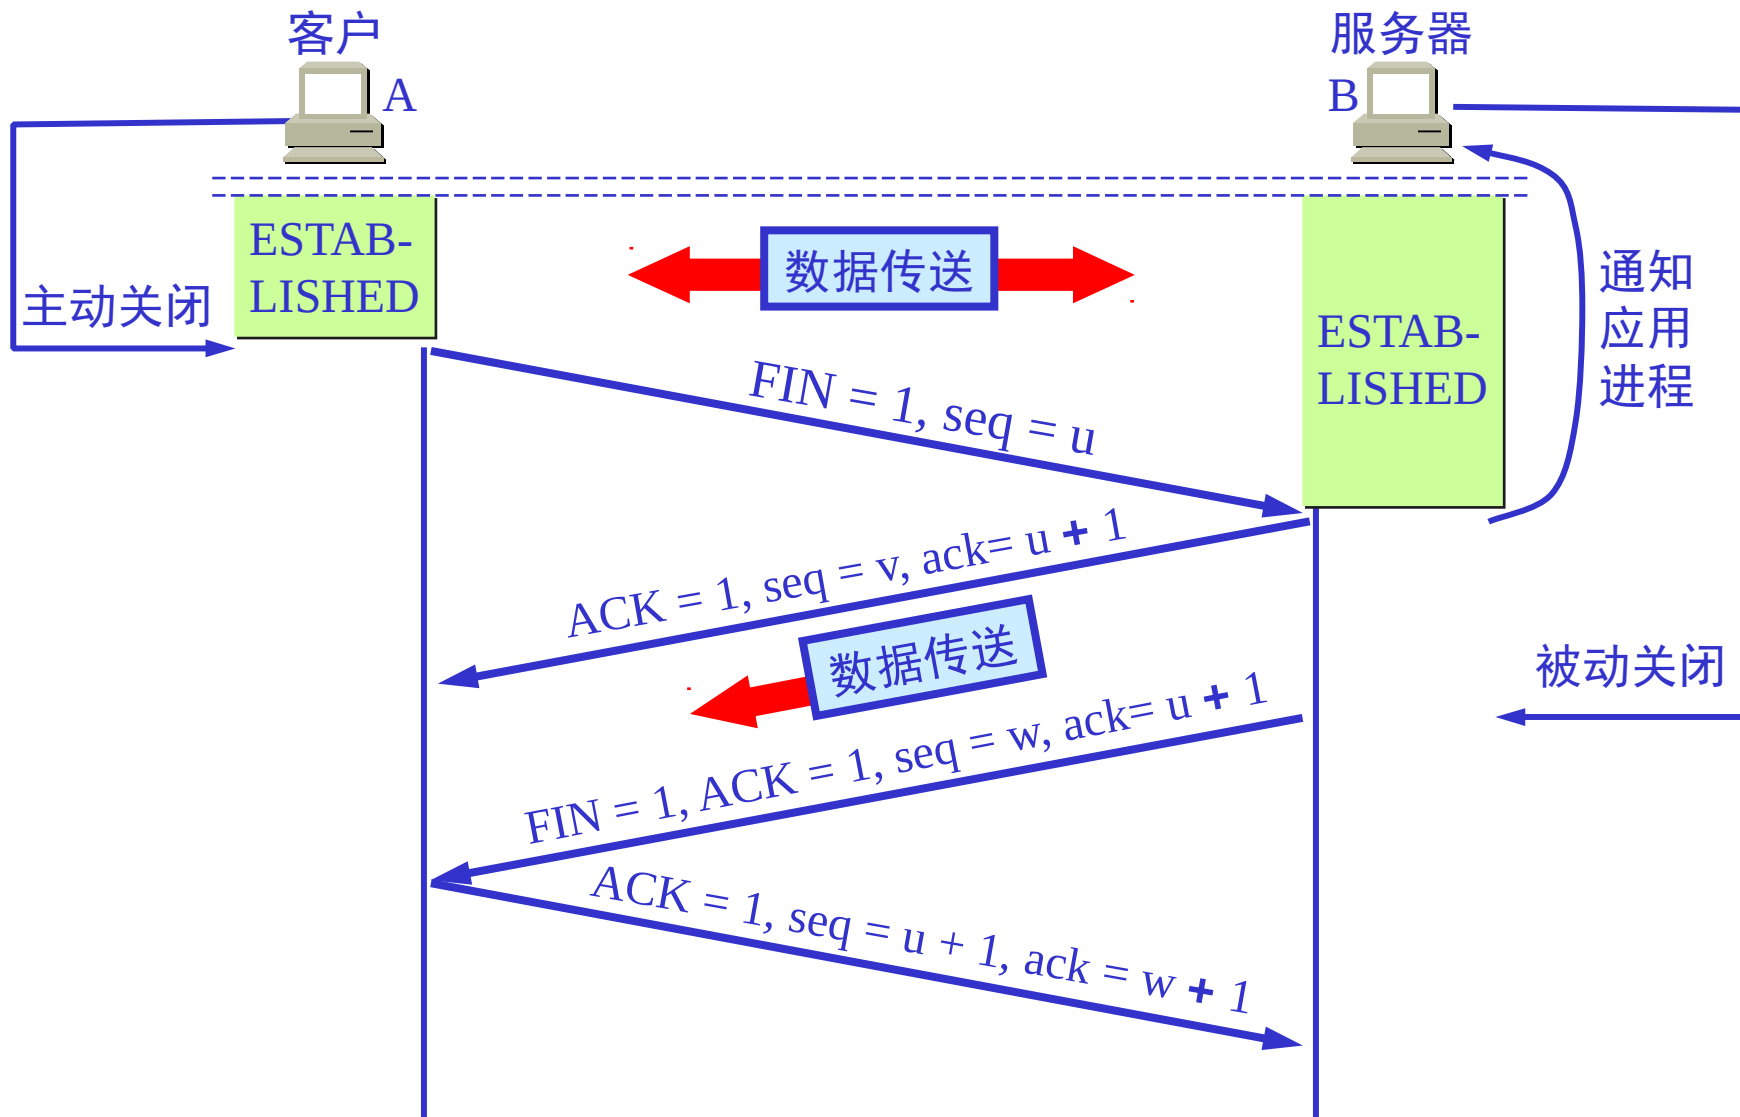
- B 发出确认，确认号 $ack = u + 1$ ，而这个报文段自己的序号 $seq = v$ 。
- TCP 服务器进程通知高层应用进程。
- 从 A 到 B 这个方向的连接就释放了，TCP 连接处于半关闭状态。B 若发送数据，A 仍要接收。

5.9.2 TCP 的连接释放



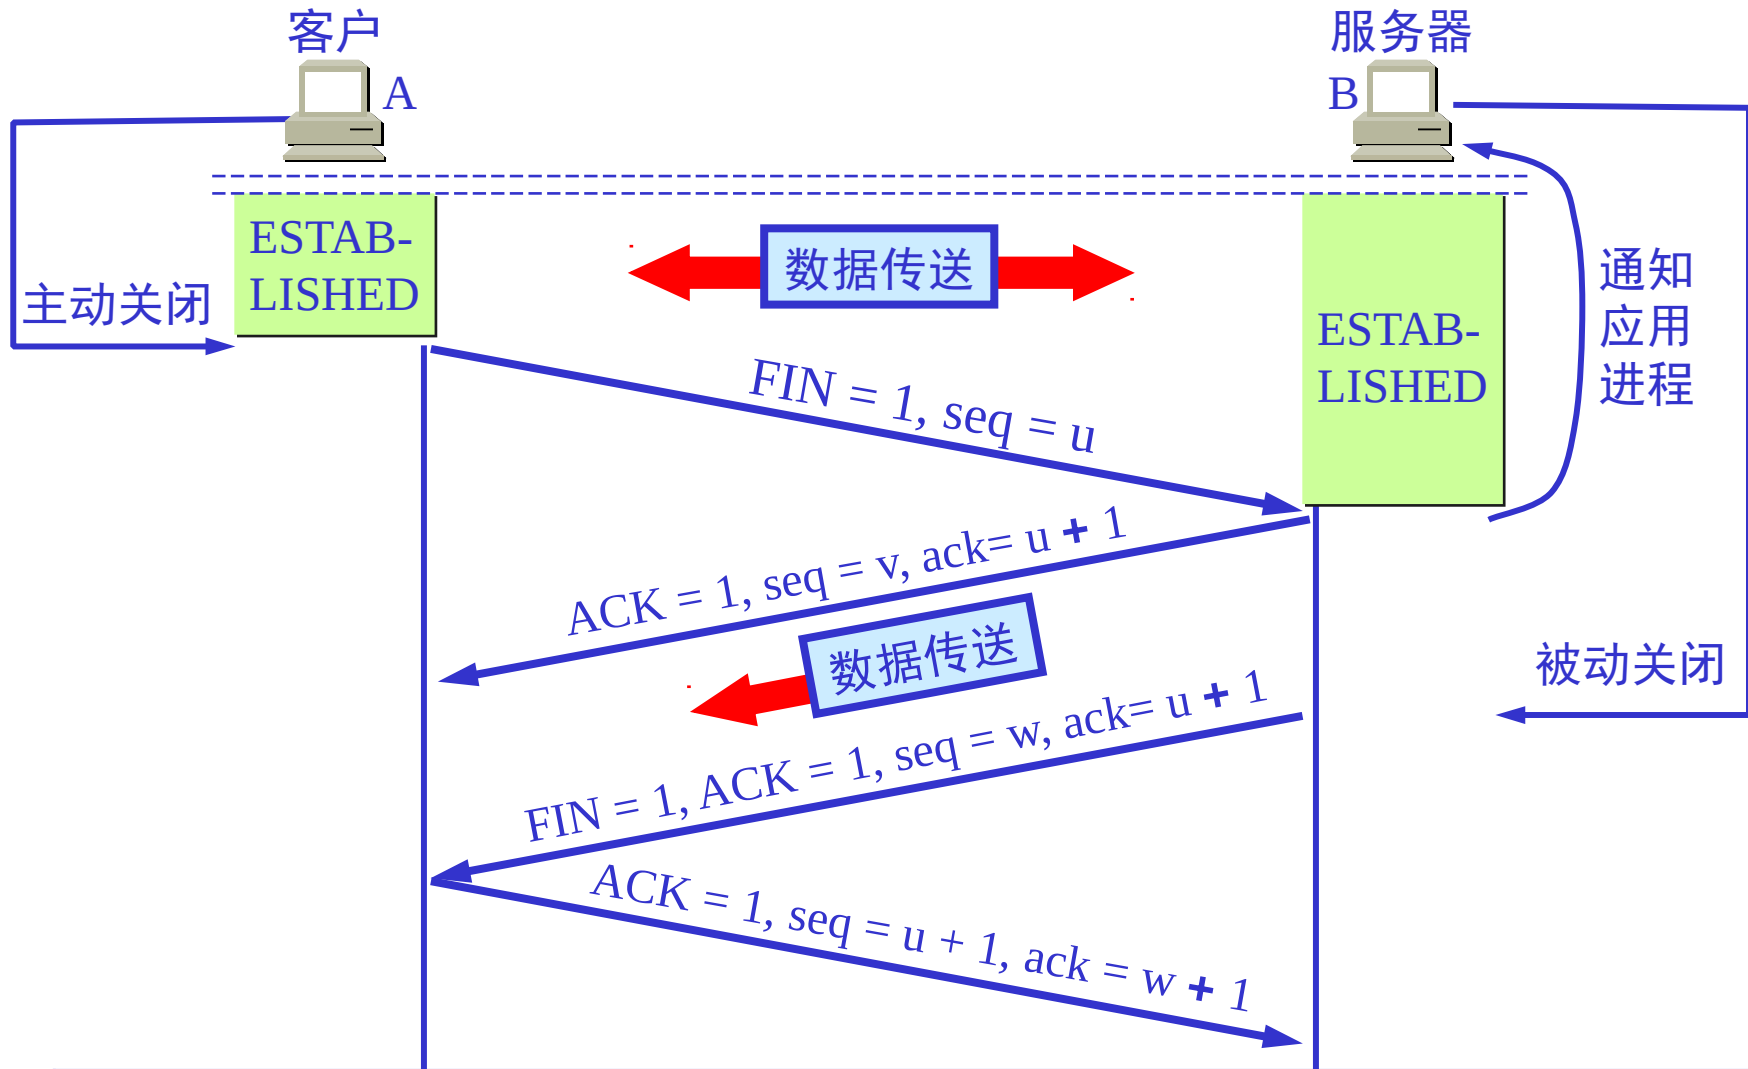
- 若 B 已经没有要向 A 发送的数据, 其应用进程就通知 TCP 释放连接。

5.9.2 TCP 的连接释放



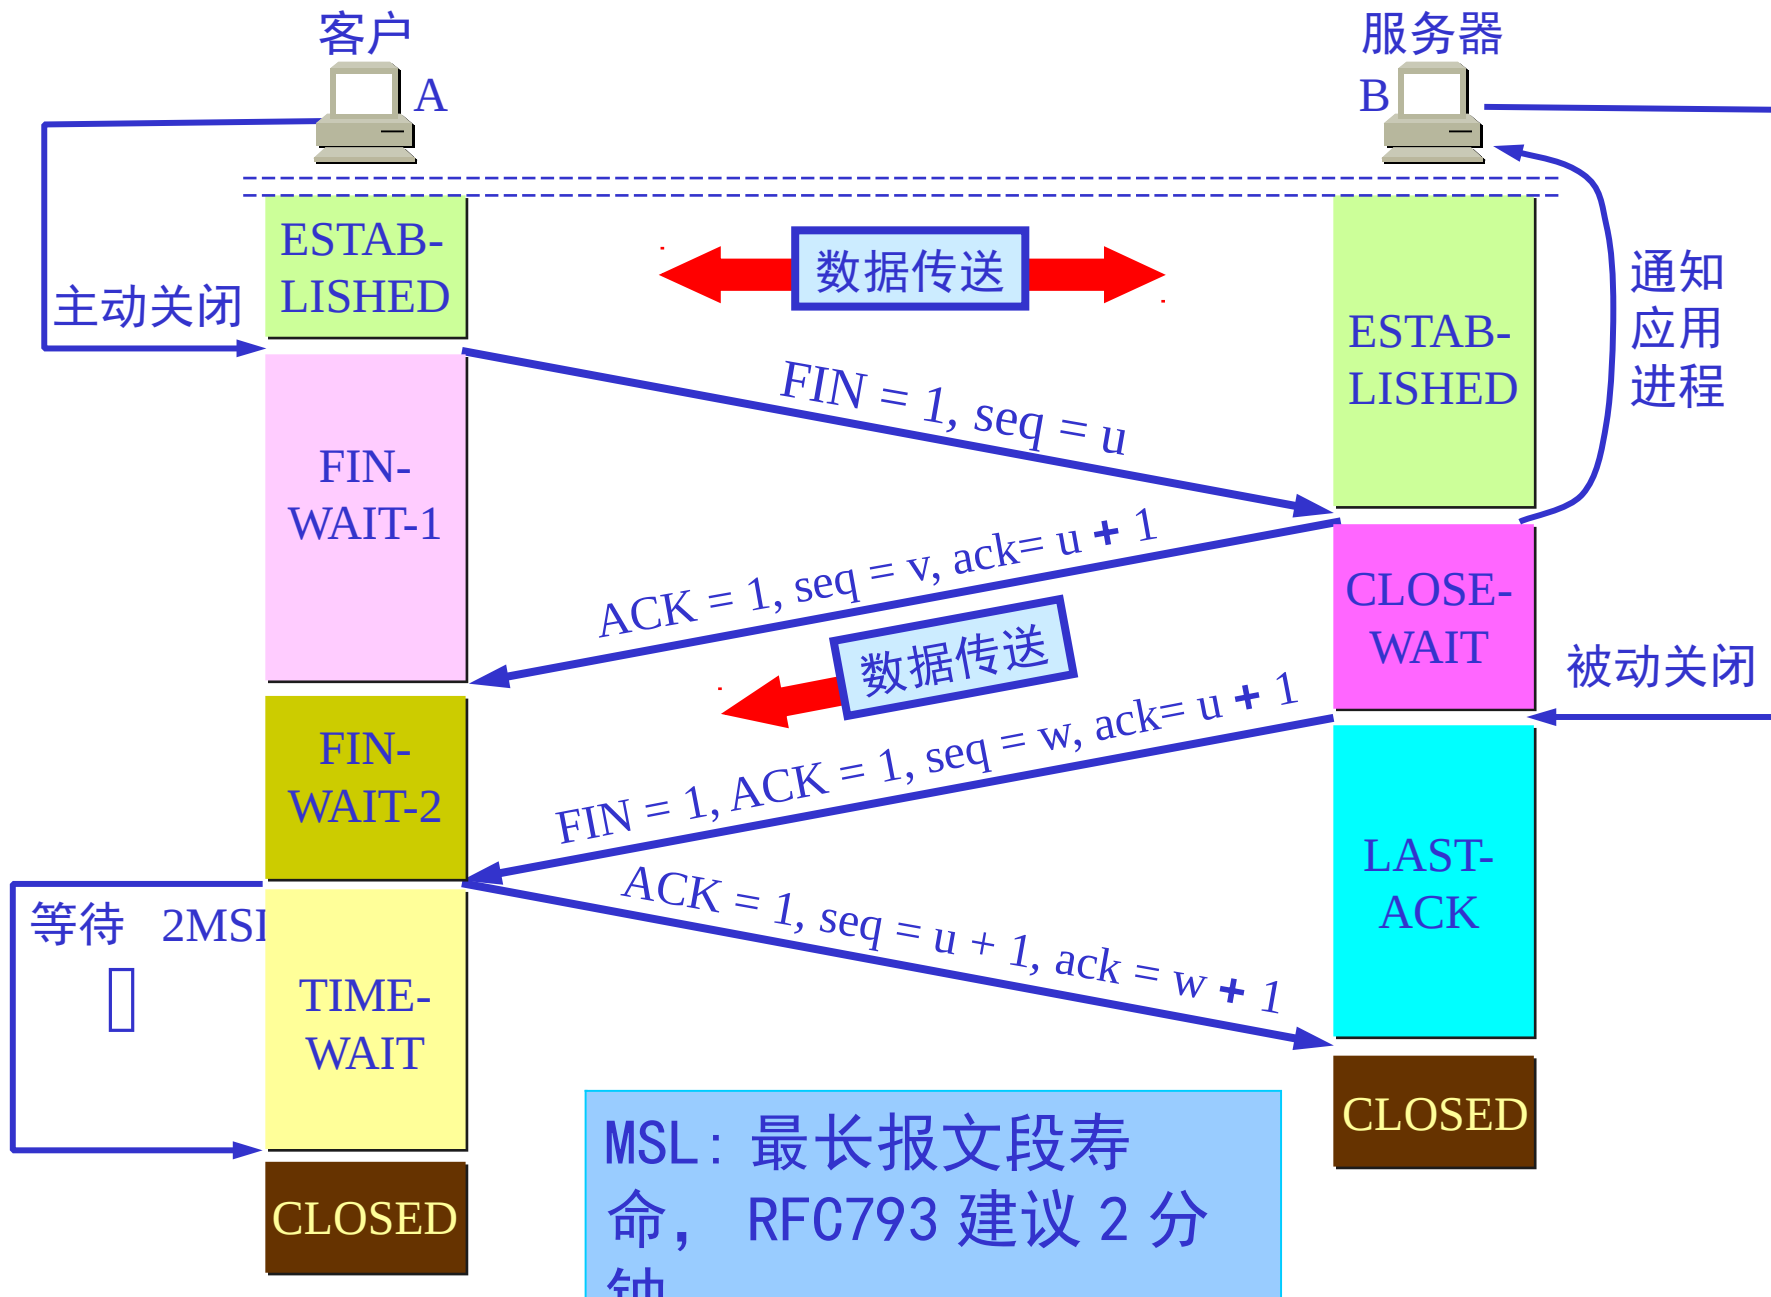
- A 收到连接释放报文段后，必须发出确认。

5.9.2 TCP 的连接释放



- 在确认报文段中 $ACK = 1$ ，确认号 $ack = w + 1$ 自己的序号 $seq = u + 1$ 。

TCP 连接必须经过时间 2MSL 后才真正释放掉。





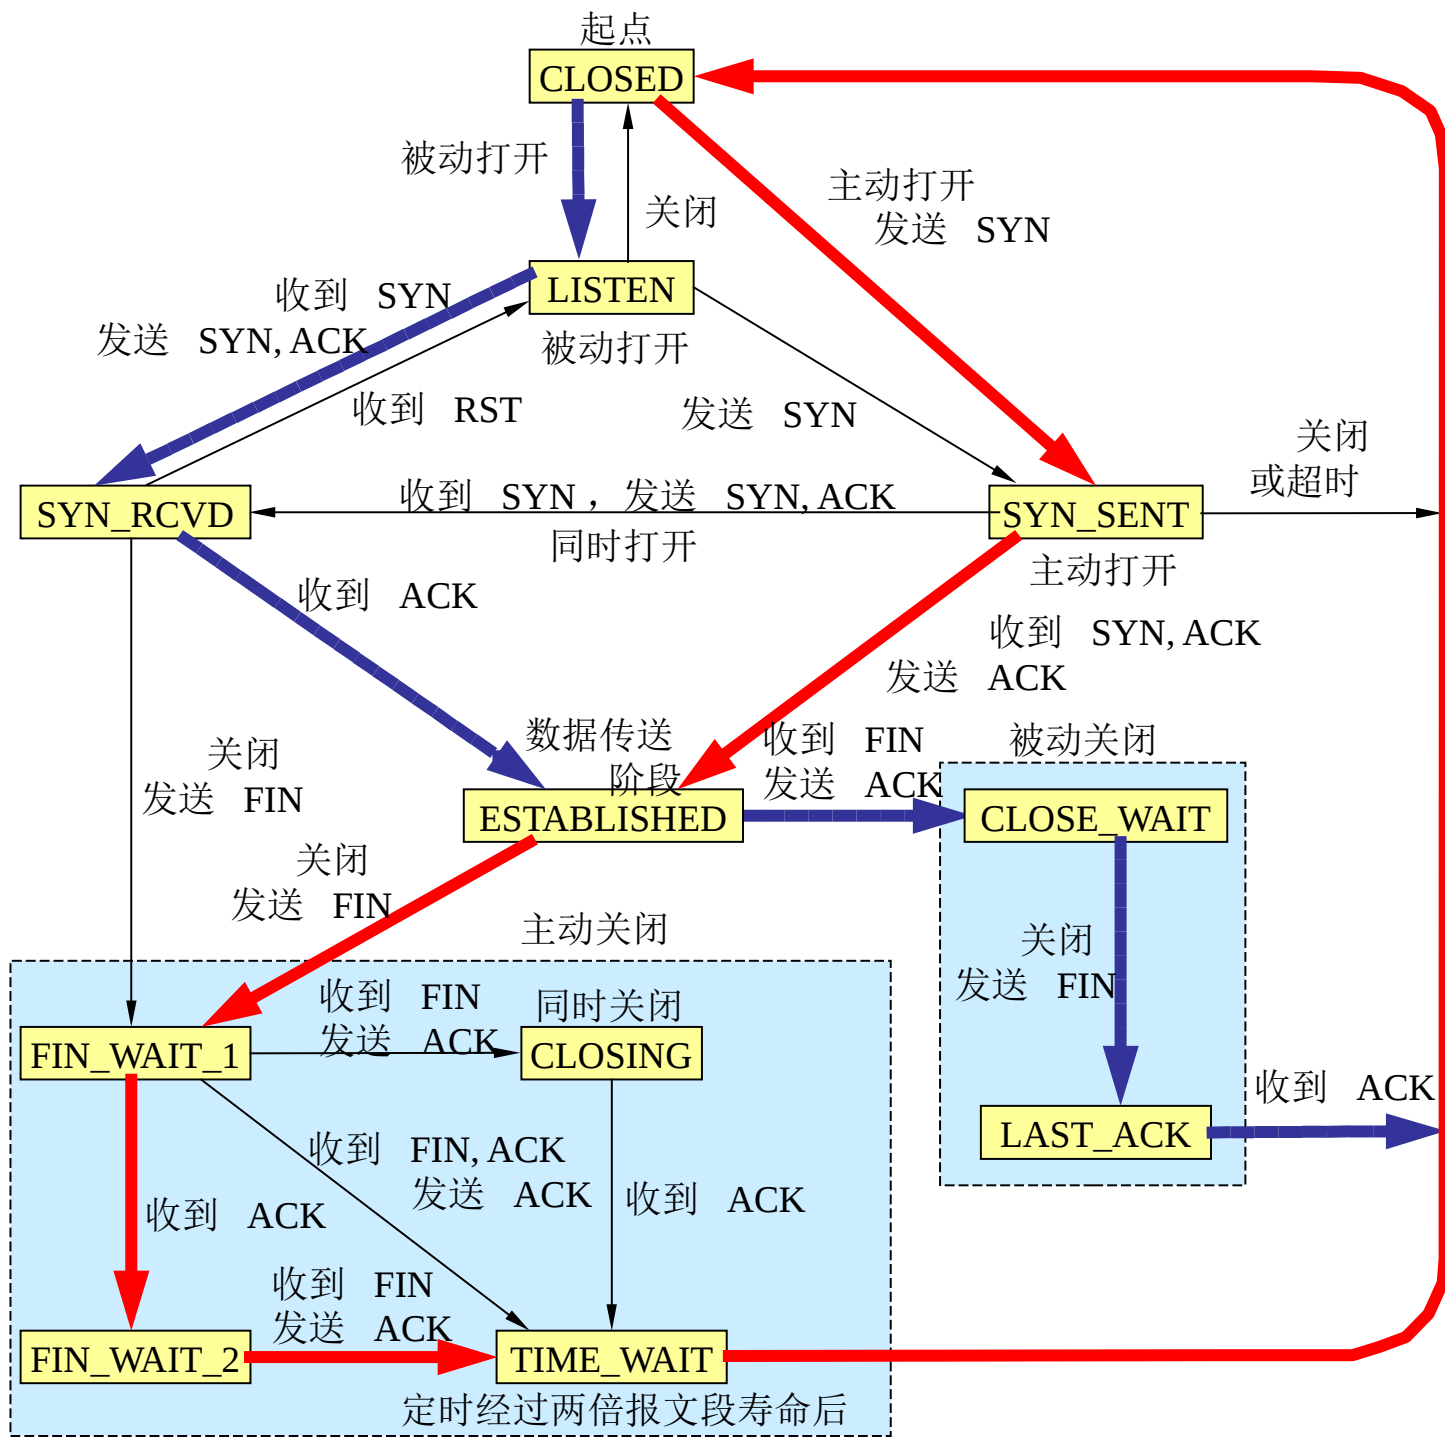
A 必须等待 2MSL 的时间

- 第一，为了保证 A 发送的最后一个 ACK 报文段能够到达 B。
- 第二，防止 “已失效的连接请求报文段” 出现在本连接中。A 在发送完最后一个 ACK 报文段后，再经过时间 2MSL，就可以使本连接持续的时间内所产生的所有报文段，都从网络中消失。这样就可以使下一个新的连接中不会出现这种旧的连接请求报文段。

5.9.3 TCP 的有限状态机

- TCP 有限状态机的图中每一个方框都是 TCP 可能具有的状态。
- 每个方框中的大写英文字符串是 TCP 标准所使用的 TCP 连接状态名。状态之间的箭头表示可能发生的状态变迁。
- 箭头旁边的字，表明引起这种变迁的原因，或表明发生状态变迁后又出现什么动作。
- 图中有三种不同的箭头。
 - 粗实线箭头表示对客户进程的正常变迁。
 - 粗虚线箭头表示对服务器进程的正常变迁。
 - 另一种细线箭头表示异常变迁。

TCP 的有限状态机



TCP 的正常的连接建立和关闭

客户进程

服务器进程

